


Стохастический градиентный спуск

Виктор Китов

v.v.kitov@yandex.ru



Содержание

- 1 Свойства градиента функции
- 2 Метод градиентного спуска
- 3 Стохастический градиентный спуск
- 4 Метод стохастического градиентного спуска с инерцией
- 5 Регуляризация

Градиент

- Для любой функции $f(x)$, зависящей от $x = (x_1, \dots, x_D)^T$ градиент

$$\nabla f(x) := \begin{pmatrix} \frac{\partial f(x)}{\partial x_1} \\ \frac{\partial f(x)}{\partial x_2} \\ \dots \\ \frac{\partial f(x)}{\partial x_D} \end{pmatrix}$$

- Если функция $f(x, y)$ еще зависит от y , то градиент ∇_x состоит только из производных по x :

$$\nabla_x f(x, y) := \begin{pmatrix} \frac{\partial f(x)}{\partial x_1} \\ \frac{\partial f(x)}{\partial x_2} \\ \dots \\ \frac{\partial f(x)}{\partial x_D} \end{pmatrix}$$

Направленный градиент

Определение 1

Рассмотрим дифференцируемую ф-цию $f : \mathbb{R}^D \rightarrow \mathbb{R}$.
Производная по направлению d , $\|d\| = 1$ равна

$$f'(x, d) = \lim_{\lambda \rightarrow 0} \frac{f(x + \lambda d) - f(x)}{\lambda}$$

Теорема 2

$$f'(x, d) = \nabla f(x)^T d$$

Доказательство. Используя разложение Тейлора 1-го порядка, получаем

$$\begin{aligned} f(x + \lambda d) &= f(x) + \nabla f(x)^T (\lambda d) + o(\lambda) \\ \frac{f(x + \lambda d) - f(x)}{\lambda} &= \nabla f(x)^T d + o(1) \xrightarrow{\lambda \rightarrow 0} \nabla f(x)^T d \end{aligned}$$

Направление максимального увеличения/уменьшения

Теорема 3

Для дифференцируемой ф-ции $f(x)$ локально в точке x :

- $\frac{\nabla f(x)}{\|\nabla f(x)\|}$ направление максимального увеличения.
- $-\frac{\nabla f(x)}{\|\nabla f(x)\|}$ направление максимального уменьшения.

Доказательство. Разложение Тейлора 1-го порядка

$$f(x + \lambda d) = f(x) + \nabla f(x)^T (\lambda d) + o(\lambda), \quad \lambda > 0$$

Из неравенства Коши-Буняковского при $\|d\| = 1$:

$$\left| \nabla f(x)^T d \right| \leq \|\nabla f(x)\| \|d\| = \|\nabla f(x)\|$$

Равенство достигается при $d \propto \nabla f(x)$, т.е.

$$d = \pm \nabla f(x) / \|\nabla f(x)\|.$$



Содержание

- 1 Свойства градиента функции
- 2 Метод градиентного спуска
- 3 Стохастический градиентный спуск
- 4 Метод стохастического градиентного спуска с инерцией
- 5 Регуляризация

Напоминание

- Минимизация эмпирического риска


$$L(w) = \frac{1}{N} \sum_{n=1}^N \mathcal{L}_w(x_n, y_n) \rightarrow \min_w$$

- Проблемы:
 - для произвольных \mathcal{L} и прогнозирующих ф-ций нет аналитического решения
 - $\hat{\beta} = (X^T X)^{-1} X^T Y$ - вычислительная сложность $O(D^3)$ велика при больших D .
 - хотим решить неточно, но быстро

Метод градиентного спуска (gradient descent, GD)

- Метод градиентного спуска - итеративное смещение по направлениям максимального уменьшения функции:

$$w := w - \varepsilon \nabla_w L(w), \quad \varepsilon > 0 - \text{шаг спуска}$$



- Если $\mathcal{L}(u)$ -выпуклая $\Rightarrow L(w)$ -выпуклая \Rightarrow локальный оптимум является глобальным, сходится из любой точки.

Алгоритм

ВХОД:

- * $\varepsilon > 0$: шаг одной итерации, контролирующий скорость сходимости
- * правило остановки

АЛГОРИТМ:

инициализировать $t = 0$, а w_0 случайно.

ПОКА правило остановки не выполнено:

$$w_{t+1} := w_t - \varepsilon \nabla_w L(w_t)$$


$$t := t + 1$$

ВЕРНУТЬ w_n


Возможные правила остановки: $|L(w_t) - L(w_{t-1})| < H_1$ или $\|w_t - w_{t-1}\| < H_2$ или достигнуто нужное число итераций.

Выбор шага градиентного спуска

- Малое $\varepsilon \Rightarrow$ медленная сходимость
- Большое $\varepsilon \Rightarrow$ алгоритм расходится.
- Вариант применения: начать с большого ε , потом уменьшить.



Large learning rate: Overshooting.




Small learning rate: Many iterations until convergence and trapping in local minima.

Нормализация признаков ускоряет сходимость

Проблема "вытянутых долин":

- градиент ортогонален линиям уровня
- вдоль одного направления резкие изменения, ε должно быть мало
- вдоль другого - плавные изменения, медленно сходимся с малым ε

"Вытянутые долины" можно частично распрямить, приведя признаки к одинаковой шкале.



Проблема градиентного спуска

ВХОД:

- * $\varepsilon_t > 0$: динамика уменьшения шага
- * правило остановки

АЛГОРИТМ:

инициализировать $t = 0$, а w_0 случайно

ПОКА не выполнено правило остановки:

$$w_{t+1} := w_t - \varepsilon_t \frac{1}{N} \sum_{i=1}^N \nabla_w \mathcal{L}(x_i, y_i | w_n)$$
$$t := t + 1$$

ВЕРНУТЬ w_n

Проблема: сложность расчета градиента на каждом шаге $O(N)$.

- нужна ли такая сложность на начальных итерациях?
- если информация в объектах дублируется, то необязательно усреднять по всем объектам.

Содержание

- 1 Свойства градиента функции
- 2 Метод градиентного спуска
- 3 Стохастический градиентный спуск**
- 4 Метод стохастического градиентного спуска с инерцией
- 5 Регуляризация

Стохастический градиентный спуск

ВХОД:

- * $\varepsilon_t > 0$: динамика уменьшения шага
- * правило остановки

АЛГОРИТМ:

инициализировать $t = 0$, а w_0 случайно

ПОКА не выполнено правило остановки:

 случайно выбрать K объектов $I = \{n_1, \dots, n_K\}$ из $\{1, 2, \dots, N\}$

$w_{t+1} := w_t - \varepsilon_t \frac{1}{K} \sum_{n \in I} \nabla_w \mathcal{L}(x_n, y_n | w_t)$

$t := t + 1$

ВЕРНУТЬ w_t

$$\frac{1}{N} \sum_{n=1}^N \mathcal{L}(x_n, y_n | w) \approx \frac{1}{K} \sum_{n \in I} \mathcal{L}(x_n, y_n | w)$$



один шаг $O(K)$, $K \ll N$.

Комментарии

- Генерация объектов: перед каждым проходом по обучающей выборке перемешаем её и пройдем последовательно.
- Сходится даже при $K = 1$.
- $\frac{1}{K} \sum_{i \in I} \nabla_w \mathcal{L}(x_i, y_i | w_n)$ может вычисляться за $O(1)$ при параллельных векторных вычислениях.
- Англ: stochastic gradient descent, SGD.

Выбор шага

При фиксированном шаге: ε -велико \Rightarrow расходимость, ε -мало \Rightarrow сходимость в окрестность решения.



- Условия сходимости к оптимуму:


$$\sum_t \varepsilon_t = +\infty \quad \text{достигаем произвольной точки}$$

$$\sum_t \varepsilon_t^2 < +\infty \quad \varepsilon_t \text{ сходится к нулю достаточно быстро}$$

Мониторинг сходимости SGD

Мониторинг сходимости SGD:

- $\frac{1}{N} \sum_{n=1}^N \mathcal{L}(x_n, y_n | w)$ вычисляется за $O(N)$.
- $\frac{1}{K} \sum_{n \in I} \mathcal{L}(x_n, y_n | w)$ вычисляется за $O(K)$, но дает шумную оценку:
 - нужно сгладить ряд



Экспоненциальное сглаживание

- Экспоненциального сглаживание усредняет по всем предшествующим наблюдениям с экспоненциально затухающими весами^{1,2}.

$$\begin{cases} s_1 = z_1 \\ s_{t+1} = \alpha z_{t+1} + (1 - \alpha)s_t \end{cases} \quad \begin{array}{l} \alpha \in (0, 1) - \text{степень сглаживания} \\ \text{перевычисляется за } O(1) \end{array}$$

- Альтернатива: усреднять по последним P наблюдениям.
 - можно пересчитывать за $O(1)$ вместо $O(P)$.

¹Чему нужно брать α_t (изменяемый), чтобы получить в качестве s_t равномерное среднее по всем предшествующим наблюдениям?

²Как α влияет на сглаживание?

Обсуждение SGD

Преимущества

- Простой
- Работает для потоковых данных
- Небольшого числа объектов может быть достаточно для хорошего решения

Обсуждение SGD

Преимущества

- Простой
- Работает для потоковых данных
- Небольшого числа объектов может быть достаточно для хорошего решения

Недостатки

- Оптимизация, используя 2-ые производные сходится за меньшее #итераций (но надо матрицу обращать).
- Необходимость выбора ε_t :
 - большое: расхожимость
 - малое: медленная сходимость

- Если $\mathcal{L}(\cdot)$ выпуклая \Rightarrow сходимость к глобальному оптимуму из любого начального приближения.
- Если $\mathcal{L}(\cdot)$ невыпуклая \Rightarrow нужно запускать алгоритм из разных начальных приближений, выбрать лучшее решение.

Содержание

- 1 Свойства градиента функции
- 2 Метод градиентного спуска
- 3 Стохастический градиентный спуск
- 4 Метод стохастического градиентного спуска с инерцией
- 5 Регуляризация

Переформулируем SGD

ВХОД:

- * $\varepsilon_t > 0$: динамика уменьшения шага
- * условие остановки

АЛГОРИТМ:

инициализируем $t = 0$, а w_0 случайно

ПОКА не выполнено условие остановки:

 сэмплируем случайные объекты $I = \{n_1, \dots, n_K\}$ из $\{1, 2, \dots, N\}$

$$\Delta w_{t+1} = \frac{1}{K} \sum_{n \in I} \nabla_w \mathcal{L}(x_n, y_n | w_t)$$

$$w_{t+1} := w_t - \varepsilon_t \Delta w_{t+1}$$

$$t := t + 1$$

ВЕРНУТЬ w_n

SGD с инерцией (momentum)

ВХОД:

- * $\varepsilon_t > 0$: динамика уменьшения шага
- * $\alpha \in (0, 1]$: степень сглаживания градиентов
- * условие остановки

АЛГОРИТМ:

инициализируем $t = 0$, а w_0 случайно

ПОКА не выполнено условие остановки:

сэмплируем случайные объекты $I = \{n_1, \dots, n_K\}$ из $\{1, 2, \dots, N\}$

$$\Delta w_{t+1} = (1 - \alpha)\Delta w_t + \alpha \frac{1}{K} \sum_{n \in I} \nabla_w \mathcal{L}(x_n, y_n | w_t)$$

$$w_{t+1} := w_t - \varepsilon_t \Delta w_{t+1}$$

$$t := t + 1$$

ВЕРНУТЬ w_n

Можем $\uparrow \varepsilon_t$ за счет более точных сглаженных оценок градиента

Инерция Нестерова - стратегия "заглядывания вперед":

$$\Delta w_{t+1} = (1 - \alpha)\Delta w_t + \alpha \frac{1}{K} \sum_{n \in I} \nabla_w \mathcal{L}(x_n, y_n | w_t - (1 - \alpha)\Delta w_t)$$

Другие возможные улучшения

Другие улучшения SGD существуют:

- использовать 2-ую производную
- Adam, RMSProp, AdaGrad, Adadelta
 - настройка ε_t вдоль каждой оси независимо.
 - $\downarrow \varepsilon_t$ для осей с резким изменением критерия
 - $\uparrow \varepsilon_t$ для осей с плавным изменением критерия

Содержание

- 1 Свойства градиента функции
- 2 Метод градиентного спуска
- 3 Стохастический градиентный спуск
- 4 Метод стохастического градиентного спуска с инерцией
- 5 Регуляризация

Регуляризация

В машинном обучении мы решаем задачу:

$$L(w) = \frac{1}{N} \sum_{n=1}^N \mathcal{L}_w(x_n, y_n) \rightarrow \min_w$$

При добавлении регуляризации критерий меняется:

$$\tilde{L}(w) = \frac{1}{N} \sum_{n=1}^N \mathcal{L}_w(x_n, y_n) + \lambda R(w) = L(w) + \lambda R(w) \rightarrow \min_w$$

где $R(w)$ штрафует сложность модели, а $\lambda \geq 0$ контролирует силу регуляризации.

L_1 регуляризация

$$\tilde{L}(w) = L(w) + \lambda \sum_{d=1}^D |w_d|$$

$$\frac{\partial \tilde{L}(w)}{\partial w_i} = \frac{\partial L(w)}{\partial w_i} + \lambda \text{sign } w_i$$

$$\lambda \text{sign } w_i \nrightarrow 0 \text{ при } w_i \rightarrow 0$$

- Если $\lambda > \max_w \left| \frac{\partial L(w)}{\partial w_i} \right|$, то становится оптимальным задать $w_i = 0$
- Для более высоких λ больше весов обнуляются.

L_2 регуляризация

$$\tilde{L}(w) = L(w) + \lambda \sum_{d=1}^D w_d^2$$

$$\frac{\partial L(w)}{\partial w_i} = \frac{\partial L(w)}{\partial w_i} + 2\lambda w_i$$

$$2\lambda w_i \rightarrow 0 \text{ при } w_d \rightarrow 0$$

- Сила регуляризации $\rightarrow 0$, когда веса $\rightarrow 0$.
- Поэтому L_2 лишь уменьшает веса, не делая их равными 0.

Продвинутая регуляризация: multi-task lasso


- T задач: $Y \in \mathbb{R}^{N \times T}$
- $\hat{Y} = X\hat{B}$, $X \in \mathbb{R}^{N \times D}$, $\hat{B} \in \mathbb{R}^{D \times T}$
 - индивидуальный набор весов для каждой задачи
- Хотим:
 - исключить лишние признаки
 - чтобы одинаковый набор признаков влиял на все прогнозы
 - например, одни и те же признаки должны определять стоимость акций и выручку компании
- Достигается специальной регуляризацией:

$$\frac{1}{2N} \|XB - Y\|_2^2 + \lambda \|B\|_{21} \rightarrow \min_B$$


$$\|B\|_{21} = \sum_d \sqrt{\sum_t \beta_{dt}^2}$$

Пример

Прогнозы точнее, если действительно важен одинаковый набор признаков:



Влияет один и тот же набор признаков (коэффициенты при них обозначены черным):



Объяснение

$$R(B) = \sum_d \sqrt{\sum_t \beta_{dt}^2}$$

$$\frac{\partial R}{\partial \beta_{dt}} = \frac{1}{2\sqrt{\sum_t \beta_{dt}^2}} 2\beta_{dt} = \frac{\beta_{dt}}{\sqrt{\sum_t \beta_{dt}^2}}$$

Если скорость стремления к нулю одинакова, то

- $\frac{\beta_{dt}}{\sqrt{\sum_t \beta_{dt}^2}} \rightarrow 0$ при $\beta_{dt} \rightarrow 0$, если $\exists t' \neq t : \beta_{dt'} \not\rightarrow 0$.
- $\frac{\beta_{dt}}{\sqrt{\sum_t \beta_{dt}^2}} \not\rightarrow 0$ при $\beta_{dt} \rightarrow 0$, если $\beta_{dt} \rightarrow 0 \quad \forall t$.

Локально квадратичная аппроксимация (метод Ньютона)

- Рассмотрим минимизацию $L(w) \rightarrow \min_w$
- Пусть $w^* = \arg \min_w L(w)$
- Тогда $L'(w^*) = 0$
- Разложение Тейлора $L'(w)$ относительно w в точке w^* :

$$L'(w^*) = 0 = L'(w) + L''(w)(w^* - w) + o(\|w - w^*\|)$$

откуда

$$w^* - w = -[L''(w)]^{-1} L'(w) + o(\|w - w^*\|)$$

- Получаем правило обновления весов:

$$w \leftarrow w - [L''(w)]^{-1} L'(w)$$

- использовалась локальная квадратичная аппроксимация
 - для квадратичного функционала сходится за 1 итерацию
- представляет собой отмасштабированный шаг GD

Заключение

- Метод градиентного спуска итеративно уменьшает $L(w)$ в направлении локального максимального уменьшения.
 - один шаг требует $O(N)$ операций
 - ε должно аккуратно выбираться
- Метод стохастического градиентного спуска приближает $\nabla L(w)$.
 - один шаг требует $O(K)$ операций, сходится даже при $K = 1$
 - необходимо $\varepsilon_t \rightarrow 0$ для сходимости.
- Нормализация признаков и инерция ускоряет сходимость.