


Линейная классификация

Виктор Китов

victorkitov.github.io



Курс поддержан
фондом
'Интеллект'



Победитель
конкурса VK среди
курсов по IT



Содержание

- 1 Виды классификаторов
- 2 Геометрическая интерпретация
- 3 Оценка параметров
- 4 Регуляризация
- 5 Логистическая регрессия
- 6 Многоклассовая классификация бинарными классификаторами
- 7 Связь с вероятностными подходами

Многоклассовый классификатор

- Определим дискриминантные функции $g_c(x)$ для классов $c = \overline{1, C}$.
- Классификация - предсказывается класс с максимальным рейтингом:

$$\hat{y}(x) = \arg \max_c g_c(x)$$

- Граница между классами i и j :

$$\{x : g_i(x) = g_j(x)\}$$

- Отступ измеряет качество классификации:

$$M(x, y) = g_y(x) - \max_{c \neq y} g_c(x)$$

Бинарный классификатор

- $y \in \{+1, -1\}$, поэтому есть только $g_{+1}(x)$ и $g_{-1}(x)$.
- Предпочтительность класса $+1$ относительно класса -1 :

$$g(x) = g_{+1}(x) - g_{-1}(x)$$

- Бинарный классификатор:

$$\hat{y}(x) = \arg \max_{c \in \{+1, -1\}} g_c(x) = \text{sign}(g_{+1}(x) - g_{-1}(x)) = \text{sign}(g(x))$$

- Отступ:


$$M(x, y) = g_y(x) - g_{-y}(x) = y(g_{+1}(x) - g_{-1}(x)) = yg(x)$$

Линейный классификатор

- Включим константу 1 в признаки для учета смещения:
 $x = [1, x^1, x^2, \dots, x^D]$.
- Линейный классификатор - все его дискриминантные функции линейны:

$$g_c(x) = w_c^T x, \quad c = \overline{1, C}.$$

- Граница между классами i и j линейна: $\{x : w_i^T x = w_j^T x\}$



Бинарный линейный классификатор

- Дискриминантные функции: $w_{+1}^T x$, $w_{-1}^T x$.
- Определим $w = w_{+1} - w_{-1}$.
- Бинарный линейный классификатор:

$$\hat{y}(x) = \arg \max_{c \in \{+1, -1\}} w_c^T x = \text{sign} \left(w_{+1}^T x - w_{-1}^T x \right) = \text{sign} \left(w^T x \right)$$

- Отступ:

$$M(x, y) = w_y^T x - w_{-y}^T x = y \left(w_{+1}^T x - w_{-1}^T x \right) = y w^T x = w^T x y$$

Содержание

- 1 Виды классификаторов
- 2 Геометрическая интерпретация**
- 3 Оценка параметров
- 4 Регуляризация
- 5 Логистическая регрессия
- 6 Многоклассовая классификация бинарными классификаторами
- 7 Связь с вероятностными подходами

Вектор, ортогональный гиперплоскости

Теорема 1

Вектор w ортогонален гиперплоскости $w^T x + w_0 = 0$

Доказательство. Рассмотрим произвольные $x_A, x_B \in \{x : w^T x + w_0 = 0\}$:

$$w^T x_A + w_0 = 0 \tag{1}$$

$$w^T x_B + w_0 = 0 \tag{2}$$



Вычитая (2) из (1), получим $w^T (x_A - x_B) = 0$, поэтому w ортогонален гиперплоскости.

Расстояние от точки до гиперплоскости

Теорема 2

Расстояние от точки x до гиперплоскости $w^T x + w_0 = 0$ равно $\frac{w^T x + w_0}{\|w\|}$.

Доказательство. Пусть p - проекция x на гиперплоскость, а $h = x - p$ - ортогональное дополнение. Тогда

$$x = p + h$$

Поскольку p лежит на гиперплоскости, то

$$w^T p + w_0 = 0$$

Поскольку h ортогонально гиперплоскости по теореме 1, то

$$h = r \frac{w}{\|w\|}, \quad r \in \mathbb{R} \text{ - расстояние до гиперплоскости.}$$



Расстояние от точки до гиперплоскости

$$x = p + r \frac{w}{\|w\|}$$

После домножения равенства на w и прибавления w_0 :

$$w^T x + w_0 = w^T p + w_0 + r \frac{w^T w}{\|w\|} = r \|w\|,$$

поскольку $w^T p + w_0 = 0$ и $\|w\| = \sqrt{w^T w}$. В итоге получаем

$$r = \frac{w^T x + w_0}{\|w\|}$$

Комментарии:

- С одной стороны гиперплоскости $r > 0 \Leftrightarrow w^T x + w_0 > 0$
- С другой стороны гиперплоскости $r < 0 \Leftrightarrow w^T x + w_0 < 0$.
- Расстояние от начала координат до гиперплоскости $\frac{w_0}{\|w\|}$.

Поэтому w_0 отвечает за смещение.

Бинарный линейный классификатор - интерпретация

- Бинарный линейный классификатор:

$$\hat{y}(x) = \text{sign} \left(w^T x + w_0 \right)$$

разделяет классы гиперплоскостью $w^T x + w_0 = 0$.

- Т.к. расстояние до границы равно $\frac{|w^T x + w_0|}{\|w\|}$, то $|w^T x + w_0| \in [0, +\infty)$ - уверенность классификации.
 - связана с вероятностью класса
- Качество классификации, с учетом верного y :

$$M(x, y) = y \left(w^T x + w_0 \right)$$

Содержание

- 1 Виды классификаторов
- 2 Геометрическая интерпретация
- 3 Оценка параметров**
- 4 Регуляризация
- 5 Логистическая регрессия
- 6 Многоклассовая классификация бинарными классификаторами
- 7 Связь с вероятностными подходами

Оценка вектора весов w

- Прямой подход: выберем w , чтобы минимизировать #ошибок:



$$\sum_{n=1}^N \mathbb{I} \left[w^T x_n y_n < 0 \right] \rightarrow \min_w$$

- Получили кусочно-постоянный критерий, градиент=0 почти везде.
- Для получения невырожденных градиентов, применим убывающую $\mathcal{L}(\cdot)$ к отступу:
 - минимизация нового критерия аппроксимирует минимизацию старого.

$$\sum_{n=1}^N \mathcal{L}(M(x_n, y_n)) = \sum_{n=1}^N \mathcal{L}(w^T x_n y_n) \rightarrow \min_w$$

Популярные функции потерь

$$\begin{aligned}\mathcal{L}_{exp}(M) &= e^{-M} & \mathcal{L}_{perceptron}(M) &= [-M]_+ \\ \mathcal{L}_{hinge}(M) &= [1 - M]_+ & \mathcal{L}_{log}(M) &= \log_2(1 + e^{-M})\end{aligned}$$



Какие из них будут выпуклыми? устойчивыми к выбросам?
улучшать даже безошибочный классификатор?

Учёт матрицы цен

Если определена матрица цен (cost matrix)

$$\lambda(i, j) = \text{cost} \{y = i, \hat{y} = j\},$$

то выгоднее оптимизировать не

$$\frac{1}{N} \sum_{n=1}^N \mathcal{L}(\hat{y}_w(x_n), y_n) \rightarrow \min_w,$$

а взвешенные потери по цене

$$\frac{1}{N} \sum_{n=1}^N \lambda(\hat{y}_w(x_n), y_n) \mathcal{L}(\hat{y}_w(x_n), y_n) \rightarrow \min_w$$

Содержание

- 1 Виды классификаторов
- 2 Геометрическая интерпретация
- 3 Оценка параметров
- 4 Регуляризация**
- 5 Логистическая регрессия
- 6 Многоклассовая классификация бинарными классификаторами
- 7 Связь с вероятностными подходами

Регуляризация

- Хотим не только точную, но и простую модель.
 - простые модели обладают лучшей обобщающей способностью
 - измеряем сложность регуляризатором $R(w)$

$$\sum_{n=1}^N \mathcal{L}(M(x_n, y_n | w) + \lambda R(w) \rightarrow \min_w$$

- $\lambda > 0$ - гиперпараметр¹ (насколько простота важнее точности).
- Популярные варианты $R(w)$:

$$R(\beta) = \|w\|_1$$

L_1 регуляризация

$$R(\beta) = \|w\|_2^2$$

L_2 регуляризация


$$R(\beta) = \alpha \|w\|_1 + (1 - \alpha) \|w\|_2^2$$

ElasticNet $\alpha \in (0, 1)$

¹Как меняется сложность модели при увеличении λ ?

Комментарии

- Зависимость w от λ для L_2 (A) и L_1 (B) регуляризации:



- L_1 может автоматически отбирать признаки.
- λ обычно находится по экспоненциальной шкале $[10^{-6}, 10^{-5}, \dots, 10^5, 10^6]$.
 - можно уточнить по мелкой сетке в окрестности оптимума
- Использование регуляризации позволяет плавно контролировать сложности модели.

ElasticNet

- ElasticNet - линейная комбинация L_1 и L_2 регуляризации:

$$R(\beta) = \alpha \|w\|_1 + (1 - \alpha) \|w\|_2^2 \rightarrow \min_w$$

$\alpha \in [0, 1]$ – гиперпараметр.

- Если два признака x^i и x^j равны:
 - Гребневая регрессия выберет оба с равным весом
 - правильно, т.к. нет априорных предпочтений
 - Лассо регрессия выберет один из них (в общем случае)
 - зато отберет лишние признаки
- ElasticNet обладает обоими преимуществами.

Учет разных признаков с разной силой

- Прогнозы обычного линейного классификатора инвариантны к масштабированию признаков:

$$g(x) = \hat{w}_1 x^1 + \hat{w}_2 x^2 + \dots \xrightarrow{x^1 \rightarrow x^1 / \alpha} (\alpha \hat{w}_1) \left(\frac{x^1}{\alpha} \right) + \hat{w}_2 x^2 + \dots$$

- Но не регуляризованного:

$$\sum_{n=1}^N \mathcal{L}(M(x_n, y_n | w)) + \lambda R(w) \rightarrow \min_w$$

- После изменения масштаба признаков, они будут вносить другой вклад в прогноз.
 - для большего учета признака как нужно изменить его масштаб?

Содержание

- 1 Виды классификаторов
- 2 Геометрическая интерпретация
- 3 Оценка параметров
- 4 Регуляризация
- 5 Логистическая регрессия**
- 6 Многоклассовая классификация бинарными классификаторами
- 7 Связь с вероятностными подходами


Бинарная классификация²

- Предпочтение $y = +1$ относительно $y = -1$ бинарного классификатора:

$$g(x) = w^T x$$

- Предположение логистической регрессии:

$$p(y = +1|x) = \sigma(w^T x)$$



²Является частным случаем GLM модели (Generalized Linear Model).

Оценка параметров³

Свойство сигмоиды:

$$1 - \sigma(z) = 1 - \frac{1}{1 + e^{-z}} = \frac{e^{-z}}{1 + e^{-z}} = \frac{1}{1 + e^z} = \sigma(-z)$$

поэтому

$$p(y = +1|x) = \sigma(w^T x) \implies p(y = -1|x) = 1 - p(y = +1|x) = \sigma(-w^T x)$$

$$p(y|x) = \sigma(y\langle w, x \rangle) \text{ в общем случае.}$$

Оценим w методом условного максимального правдоподобия:

$$ML = P(Y|X) = \prod_{n=1}^N p(y_n|x_n) = \prod_{n=1}^N \sigma(\langle w, x_n \rangle y_n) \rightarrow \max_w$$

³Почему $\|w\| \rightarrow \infty$ при линейной разделимости классов? Как с этим бороться?

Минимизация эмпирического риска и максимизация правдоподобия


$$\prod_{n=1}^N \sigma(\langle w, x_n \rangle y_n) = \prod_{n=1}^N \frac{1}{1 + e^{-\langle w, x_n \rangle y_n}} \rightarrow \max_w$$

$$\prod_{n=1}^N (1 + e^{-\langle w, x_n \rangle y_n}) \rightarrow \min_w$$

$$\sum_{n=1}^N \log_2(1 + e^{-\langle w, x_n \rangle y_n}) \rightarrow \min_w \quad (\text{прологарифмировали критерий})$$

Иллюстрация

Обратим внимание, что логистическая ϕ -ция потерь -
сглаженная версия ϕ -ции потерь персептрона



SGD для логистической регрессии

$$w := w - \varepsilon \nabla_w \mathcal{L}(w^T xy) = w - \varepsilon \frac{\partial \mathcal{L}(M)}{\partial M} \frac{\partial M}{\partial w} = w - \varepsilon \frac{\partial \mathcal{L}(M)}{\partial M} xy$$

$$\mathcal{L}(M) = [-M]_+ :$$

$$\frac{\partial \mathcal{L}(M)}{\partial M} = -\mathbb{I}[M < 0]$$

$$w := w + \varepsilon \mathbb{I}[M < 0] xy$$

$$\mathcal{L}(M) = \log_2(1 + e^{-M}) :$$

$$\frac{\partial \mathcal{L}(M)}{\partial M} = \frac{1}{\log_2 e} \frac{-e^{-M}}{(1 + e^{-M})} = \frac{1}{\log_2 e} \frac{-1}{(1 + e^M)} = -\frac{\sigma(-M)}{\log_2 e}$$


$$w := w + \varepsilon' \sigma(-M) xy$$

Получили сглаженный классификатора персептрона⁴.

⁴ Может ли $M(x_i, y_i)$ после обновления весов уменьшиться?

Иллюстрация

Иллюстрация:



Использование логистической регрессии

```
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import brier_score_loss
from sklearn.metrics import accuracy_score

X_train, X_test, Y_train, Y_test =
    get_demo_classification_data()
model = LogisticRegression(C=1, penalty='l2') # иници-
        ция
model.fit(X_train, Y_train) # обучение модели
Y_hat = model.predict(X_test) # построение прогнозов
print(f'Точность прогнозов: \
{100*accuracy_score(Y_test, Y_hat):.1 f}%')
P_hat = model.predict_proba(X_test) # вер-ти классов
loss = brier_score_loss(Y_test, P_hat[:,1])
print(f'Мера Бриеера ошибки вероятностей: {loss:.2 f}')
```

- $1/C$ - вес при регуляризаторе.
- Больше информации. Полный код.

Многоклассовая логистическая регрессия

Многоклассовая классификация:

$$\begin{aligned}y = 1 : \quad g_1(x) &= w_1^T x \\y = 2 : \quad g_2(x) &= w_2^T x \\&\dots \qquad \dots \\y = C : \quad g_C(x) &= w_C^T x\end{aligned}$$

Логистическая регрессия предполагает связь $g_1(x), \dots, g_C(x)$ и вероятностей классов через softmax преобразование:

$$p(y = c|x) = \text{softmax}(w_c^T x | x_1^T x, \dots, x_C^T x) = \frac{\exp(w_c^T x)}{\sum_{i=1}^C \exp(w_i^T x)}$$

SoftMax

- SoftMax преобразует уверенности исходов в их вероятности:

$$\text{Softmax}_\tau(z_1, \dots, z_K) =$$
$$= \left[\frac{e^{z_1/\tau}}{e^{z_1/\tau} + \dots + e^{z_K/\tau}}, \frac{e^{z_2/\tau}}{e^{z_1/\tau} + \dots + e^{z_K/\tau}}, \dots, \frac{e^{z_K/\tau}}{e^{z_1/\tau} + \dots + e^{z_K/\tau}} \right]$$

- τ - параметр температуры, контролирующий контрастность вероятностей⁵.

⁵как?

Неоднозначность параметров и их оценка

- Веса $\{w_c\}$ определены с точностью до сдвига v :

$$\frac{\exp((w_c - v)^T x)}{\sum_i \exp((w_i - v)^T x)} = \frac{\exp(-v^T x) \exp(w_c^T x)}{\sum_i \exp(-v^T x) \exp(w_i^T x)} = \frac{\exp(w_c^T x)}{\sum_i \exp(w_i^T x)}$$

Чтобы убрать неоднозначность, ограничим $w_C = 0$
(соответствует $v = w_C$)

- Параметры оценим максимизацией условного правдоподобия:

$$\begin{cases} \prod_{n=1}^N \text{softmax}(w_{y_n}^T x_n | x_1^T x, \dots, x_C^T x) \rightarrow \max_{w_1, \dots, w_{C-1}} \\ w_C = 0 \end{cases}$$

Содержание

- 1 Виды классификаторов
- 2 Геометрическая интерпретация
- 3 Оценка параметров
- 4 Регуляризация
- 5 Логистическая регрессия
- 6 Многоклассовая классификация бинарными классификаторами**
- 7 Связь с вероятностными подходами

Многоклассовая классификация бинарными классификаторами


Хотим построить C -классовый классификатор по совокупности бинарных.

Подходы:

- один против всех (one-versus-all)
 - для каждого класса $c = 1, 2, \dots, C$ обучим бинарный классификатор на $y' = \mathbb{I}[y = c]$,
 - назначим класс, предсказанный с максимальной уверенностью (среди C классификаторов).
- один против одного (one-versus-one)
 - для каждой пары классов $i \neq j \in \{1, 2, \dots, C\}$ обучим бинарные классификаторы на $(x_n, y_n) : y_n \in \{i, j\}$.
 - назначим класс, максимально часто побеждающий среди $C(C-1)/2$ сравнений.
 - при неоднозначности - используем уверенность классификации
- коды, исправляющие ошибки (error correcting codes)


Один против всех - неоднозначность

Классификация среди 3х классов $\omega_1, \omega_2, \omega_3$:



Один против одного - неоднозначность

Классификация среди 3х классов $\omega_1, \omega_2, \omega_3$:



Коды исправляющие ошибки

- Каждый класс i кодируется бинарным представлением W_i из B бит:

$$\text{класс } i \rightarrow W_i \in \mathbb{R}^B, \quad W_{ik} \in \{0, 1\}, \quad k = 1, 2, \dots, B.$$

- Минимально достаточное количество бит для однозначного кодирования C классов = $\lceil \log_2 C \rceil$
- Для заданного x , B бинарных классификаторов $\hat{y}_1(x), \dots, \hat{y}_B(x)$ предсказывают каждый бит.
- Итоговый класс прогнозируется по правилу⁶:

$$\hat{y}(x) = \arg \min_c \rho(W_c, [\hat{y}_1(x), \dots, \hat{y}_B(x)])$$

- Обычно, $\rho(\cdot, \cdot)$ считается по L_1 норме.

⁶Какому методу будет соответствовать случай, когда у представляется one-hot кодированием?

Коды исправляющие ошибки

- Используется избыточное количество бит $B \geq \lceil \log_2 C \rceil$ через коды, исправляющие ошибки (error correcting codes)
 - ошибки отдельных классификаторов исправляются другими.
- В качестве $\hat{y}_1(x), \dots, \hat{y}_B(x)$ выдаются вероятности классов.
 - метки загроуляют информацию о неточной классификации.
- Кодовые представления классов W_i выбираются, чтобы быть максимально непохожими по расстоянию Хэмминга.

Содержание

- 1 Виды классификаторов
- 2 Геометрическая интерпретация
- 3 Оценка параметров
- 4 Регуляризация
- 5 Логистическая регрессия
- 6 Многоклассовая классификация бинарными классификаторами
- 7 Связь с вероятностными подходами

Связь с принципом максимального правдоподобия

- $X = \{x_1, x_2, \dots, x_N\}$, $Y = \{y_1, y_2, \dots, y_N\}$ - обучающая выборка; $(x_i, y_i) \sim p(y|x, w)$
- Принцип максимума правдоподобия (при условии наблюдаемых X)

$$\hat{w} = \arg \max_w p(Y|X, w)$$

$$\prod_{i=1}^N p(y_i|x_i, w) \rightarrow \max_w \iff \sum_{i=1}^N \ln p(y_i|x_i, w) \rightarrow \max_w$$

- Минимизация эмпирического риска:

$$\sum_{i=1}^N \mathcal{L}(g(x_i)y_i|w) \rightarrow \min_w$$

- Взаимосвязь между $\mathcal{L}(\cdot)$ и $p(\cdot)$:

$$\mathcal{L}(g(x_i)y_i|w) = -\ln p(y_i|x_i, w)$$

Связь с оценкой максимальной апостериорной вероятности

- Оценка максимальной апостериорной вероятности - англ. Maximum a posteriori (MAP) estimation.
- Байесовский подход: w - случайная величина с априорным распределением $p(w)$

- $p(w)$ не зависит от последующей обучающей выборки

$$\begin{aligned} p(w|Y, X) &= \frac{p(Y, w|X)}{p(Y|X)} = \frac{p(Y|X, w)p(w|X)}{p(Y|X)} \\ &\propto p(Y|X, w)p(w|X) = p(Y|X, w)p(w) \end{aligned}$$

$$w = \arg \max_w p(w|X, Y) = \arg \max_w p(Y|X, w)p(w)$$

$$\sum_{i=1}^N \ln p(y_i|x_i, \theta) + \ln p(w) \rightarrow \max_w$$

Связь с оценкой максимальной апостериорной вероятности

$$\sum_{i=1}^N \ln p(y_i|x_i, \theta) + \ln p(w) \rightarrow \max_w$$
$$\sum_{i=1}^N \mathcal{L}(g(x_i)y_i|w) + \lambda R(w) \rightarrow \min_w$$

Взаимосвязь:

$$\mathcal{L}(g(x_i)y_i|w) = -\ln p(y_i|x_i, w), \quad \lambda R(w) = -\ln p(w)$$

Априорные распределения для L_1 и L_2 регуляризации

- Распределение Гаусса:

$$\ln p(w, \sigma^2) = \ln \left(C_1 e^{-\frac{\|w\|_2^2}{2\sigma^2}} \right) = -\frac{1}{2\sigma^2} \|w\|_2^2 + \text{const}(w)$$

- Распределение Лапласа:

$$\ln p(w, C) = \ln \left(C_2 e^{-\frac{\|w\|_1}{C}} \right) = -\frac{1}{C} \|w\|_1 + \text{const}(w)$$

Заключение

- Линейный классификатор - классификатор с линейными дискриминантными функциями.
- Линейный бинарный классификатор:
 $\hat{y}(x) = \text{sign}(w^T x + w_0)$, граница классов - гиперплоскость.
 - популярные методы: метод опорных векторов и логистическая регрессия.
- Регуляризация контролирует сложность модели.
 - L_1 регуляризация может отбирать признаки.
- Логистическая регрессия может оценивать вероятности классов.
- Многоклассовые классификаторы можно строить из набора бинарных классификаторов.