


Метод опорных векторов

Виктор Китов



v.v.kitov@yandex.ru



Содержание

- 1 Линейно разделимый случай
- 2 Линейно неразделимый случай
- 3 Оптимизация - напоминание
- 4 Решение через двойственную задачу
- 5 Визуализация работы SVM с ядрами

Метод опорных векторов



Рассмотрим бинарную классификацию $y \in \{+1, -1\}$ линейно разделимой выборки.

Идея метода опорных векторов (support vector machines, SVM)

Выберем гиперплоскость, разделяющую классы с максимальным зазором.

Гиперплоскости $x_i^T w + w_0 = 0$, $x_i^T w + w_0 = b$, $x_i^T w + w_0 = -b$ поэтому величина зазора $\frac{2b}{\|w\|}$.

Метод опорных векторов

Объекты (x_i, y_i) отделены от разделяющей гиперплоскости
 $\geq \frac{b}{\|w\|}$, если

$$\begin{cases} x_i^T w + w_0 \geq b, & y_i = +1 \\ x_i^T w + w_0 \leq -b & y_i = -1 \end{cases} \quad i = 1, 2, \dots, N.$$

Это можно записать в виде

$$y_i(x_i^T w + w_0) \geq b, \quad i = 1, 2, \dots, N.$$

Максимизация зазора между классами:

$$2b / \|w\| \rightarrow \max_{w, w_0, b}$$

Оптимизационная задача

Оптимизационная задача:

$$\begin{cases} \frac{2b}{\|w\|} \rightarrow \max_{w, w_0, b} \\ y_i(x_i^T w + w_0) \geq b, \quad i = 1, 2, \dots, N. \end{cases}$$

Если (w, w_0, b) -решение, то $(\alpha w, \alpha w_0, \alpha b)$ - тоже решение $\forall \alpha > 0$. Положим $b = 1$ ($\alpha = \frac{1}{b}$).

$$\begin{cases} \frac{2}{\|w\|} \rightarrow \max_{w, w_0} \\ y_i(x_i^T w + w_0) \geq 1 \quad i = 1, 2, \dots, N. \end{cases}$$

Используя свойство $\arg \max \frac{2}{\|w\|} = \arg \min \frac{\|w\|}{2} = \arg \min \frac{\|w\|^2}{2}$:

$$\begin{cases} \frac{1}{2} w^T w \rightarrow \min_{w, w_0} \\ y_i(x_i^T w + w_0) = M(x_i, y_i) \geq 1, \quad i = 1, 2, \dots, N. \end{cases}$$


Типы объектов

Неинформативные объекты: $y_i(x_i^T w + w_0) > 1$

- не влияют на решение

Опорные вектора: $y_i(x_i^T w + w_0) = 1$


- лежат на расстоянии $1/\|w\|$ к разделяющей гиперплоскости
- влияют на решение



Содержание

- 1 Линейно разделимый случай
- 2 Линейно неразделимый случай
- 3 Оптимизация - напоминание
- 4 Решение через двойственную задачу
- 5 Визуализация работы SVM с ядрами

Линейно неразделимый случай



$$\begin{cases} \frac{1}{2} w^T w \rightarrow \min_{w, w_0} \\ y_i(x_i^T w + w_0) = M(x_i, y_i) \geq 1, \quad i = 1, 2, \dots, N. \end{cases}$$


Ограничения становятся несовместными \Rightarrow пустое множество решений.

Линейно неразделимый случай

Разрешим частичные нарушения ограничений на величины нарушений ξ_i (slack variables):

$$\begin{cases} \frac{1}{2} w^T w + C \sum_{i=1}^N \xi_i \rightarrow \min_{w, w_0, \xi} \\ y_i(w^T x_i + w_0) = M(x_i, y_i) \geq 1 - \xi_i, \quad i = 1, 2, \dots, N \\ \xi_i \geq 0, \quad i = 1, 2, \dots, N \end{cases}$$

- Штраф за нарушение C контролирует точность модели (в противовес простоте).
- Подбирается по сетке на валидации.
- Другие штрафы возможны, например $C \sum_i \xi_i^2$.



Типы объектов

- **Неинформативные объекты:**
 - $y_i(w^T x_i + w_0) > 1$
- **Опорные вектора SV :**
 - $y_i(w^T x_i + w_0) \leq 1$
 - **пограничные \widetilde{SV} :**
 - $y_i(w^T x_i + w_0) = 1$
 - **объекты-нарушители:**
 - $y_i(w^T x_i + w_0) > 0$: нарушитель корректно классифицирован
 - $y_i(w^T x_i + w_0) < 0$: нарушитель некорректно классифицирован


Безусловная оптимизация

Оптимизационная задача:

$$\begin{cases} \frac{1}{2} w^T w + C \sum_{i=1}^N \xi_i \rightarrow \min_{w, w_0, \xi} \\ y_i(w^T x_i + w_0) = M_i(w, w_0) \geq 1 - \xi_i, \\ \xi_i \geq 0, i = 1, 2, \dots, N \end{cases}$$

может быть переписана как

$$\frac{1}{2C} \|w\|_2^2 + \sum_{i=1}^N [1 - M_i(w, w_0)]_+ \rightarrow \min_{w, w_0}$$



Таким образом, метод - линейный классификатор с функцией потерь $\mathcal{L}(M) = [1 - M]_+$ и L_2 регуляризацией (обобщается на другие).

Разреженность решения

- Решение зависит только от опорных векторов.
- Это видно из условия $\mathcal{L}(M) = 0$ для $M \geq 1$.
 - хорошо классифицированные объекты с $M \geq 1$ не влияют на решение
- Разреженность решения - метод менее устойчив к выбросам
 - выбросы - всегда опорные объекты

Многоклассовый метод опорных векторов

С дискриминантных ф-ций строятся одновременно:

$$g_c(x) = (\mathbf{w}^c)^T x + w_0^c, \quad c = \overline{1, C}.$$

Линейно разделимый случай:

$$\begin{cases} \sum_{c=1}^C (\mathbf{w}^c)^T \mathbf{w}^c \rightarrow \min_{\mathbf{w}} \\ (\mathbf{w}^{y_n})^T x_n + w_0^{y_n} - (\mathbf{w}^c)^T x - w_0^c \geq 1 \quad \forall c \neq y_n, \\ n = \overline{1, N}. \end{cases}$$

Линейно неразделимый случай:

$$\begin{cases} \sum_{c=1}^C (\mathbf{w}^c)^T \mathbf{w}^c + C \sum_{n=1}^N \xi_n \rightarrow \min_w \\ (\mathbf{w}^{y_n})^T x + w_0^{y_n} - (\mathbf{w}^c)^T x - w_0^c \geq 1 - \xi_n \quad \forall c \neq y_n, \\ \xi_n \geq 0, \quad n = \overline{1, N}. \end{cases}$$

Настраивается медленнее, по точности сравним с бинарным обобщением через один-против-всех и один-против-одного.


Содержание

- 1 Линейно separable случай
- 2 Линейно non-separable случай
- 3 Оптимизация - напоминание**
- 4 Решение через двойственную задачу
- 5 Визуализация работы SVM с ядрами

Условия Каруша-Куна-Таккера

Рассмотрим оптимизационную задачу:

$$\begin{cases} f(x) \rightarrow \min_x \\ g_m(x) \leq 0 \quad m = \overline{1, M} \end{cases} \quad (1)$$



Необходимые условия оптимальности

Определим Лагранжиан

$$L(x, \lambda) = f(x) + \sum_{m=1}^M \lambda_m g_m(x)$$

Теорема (необходимые условия оптимальности):

- Пусть x^* - решение (1),
- $f(x^*)$ и $g_m(x^*)$, $m = 1, 2, \dots, M$ - непрерывно-дифференцируемы в x^* .
- Выполнены условия регулярности Слейтера:
 $\exists x : g_m(x) < 0 \forall m$.

Тогда $\exists \lambda_1^*, \lambda_2^*, \dots, \lambda_M^*$, что x^* удовлетворяет условию:


$$\left\{ \begin{array}{ll} \nabla_x f(x^*) + \sum_{i=1}^M \lambda_i^* \nabla_x g_i(x^*) = 0 & \text{стационарность} \\ g_m(x^*) \leq 0, \quad m = \overline{1, M} & \text{достижимость} \\ \lambda_m^* \geq 0, \quad m = \overline{1, M} & \text{неотрицательность} \\ \lambda_m^* g_m(x^*) = 0, \quad m = \overline{1, M} & \text{дополняющая нежесткость} \end{array} \right.$$

Условия Каруша-Куна-Таккера (ККТ)

Предположим $f(x)$ и $g_m(x)$, $m = \overline{1, M}$ выпуклы. Тогда

- 1 Условия Каруша-Куна-Таккера (2) становятся **достаточными**, чтобы x^* было решением (1).
- 2 (x^*, λ^*) являются седловой точкой Лагранжиана:

$$L(x^*, \lambda) \leq L(x^*, \lambda^*) \leq L(x, \lambda^*) \quad \forall x \forall \lambda \in \mathbb{R}_+^M$$



Седловая точка

Двойственная задача

Из условия $\nabla_x L(x^*, \lambda^*) = 0$ можем найти $x^* = x(\lambda^*)$.

Поскольку (x^*, λ^*) - седловая точка $L(x, \lambda)$ можем найти λ^* из двойственной задачи:

$$\begin{cases} L(x(\lambda), \lambda) \rightarrow \max_{\lambda} \\ g_m(x(\lambda)) \leq 0 & m = \overline{1, M} \\ \lambda_m \geq 0 & m = \overline{1, M} \\ \lambda_m g_m(x(\lambda)) = 0 & m = \overline{1, M} \end{cases}$$

В целом, выпуклость $f(x)$ и $g_m(x)$, $m = \overline{1, M}$ обеспечивает:

- все локальные минимумы являются глобальными
- множество минимумов выпукло
- если $f(x)$ - строго выпукла и минимум существует, то он единственный.

Содержание

- 1 Линейно разделимый случай
- 2 Линейно неразделимый случай
- 3 Оптимизация - напоминание
- 4 Решение через двойственную задачу
- 5 Визуализация работы SVM с ядрами

Линейно неразделимый случай

$$\begin{cases} \frac{1}{2} w^T w + C \sum_{i=1}^N \xi_i \rightarrow \min_{w, w_0, \xi} \\ y_i(w^T x_i + w_0) = M(x_i, y_i) \geq 1 - \xi_i, \quad i = 1, 2, \dots, N \\ \xi_i \geq 0, \quad i = 1, 2, \dots, N \end{cases}$$

Лагранжиан:

$$L = \frac{1}{2} w^T w + C \sum_{i=1}^N \xi_i - \sum_{i=1}^N \alpha_i (y_i(w^T x_i + w_0) - 1 + \xi_i) - \sum_{i=1}^N \beta_i \xi_i$$

Условия ККТ:

$$\begin{cases} \frac{\partial L_P}{\partial w} = \vec{0}, \quad \frac{\partial L_P}{\partial w_0} = 0, \quad \frac{\partial L_P}{\partial \xi_i} = 0 & \text{стационарность} \\ y_i(x_i^T w + w_0) \geq 1 - \xi_i, \quad \xi_i \geq 0 & \text{достижимость} \\ \alpha_i \geq 0, \quad \beta_i \geq 0 & \text{двойственные переменные} \geq 0 \\ \alpha_i (y_i(w^T x_i + w_0) - 1 + \xi_i) = 0 & \text{дополняющая нежесткость} \\ \beta_i \xi_i = 0, \quad i = 1, 2, \dots, N & \text{дополняющая нежесткость} \end{cases}$$

Решение условий ККТ

$$\frac{\partial L}{\partial w} = \vec{0} : w = \sum_{i=1}^N \alpha_i y_i x_i \quad (3)$$

$$\frac{\partial L}{\partial w_0} = 0 : \sum_{i=1}^N \alpha_i y_i = 0$$

$$\frac{\partial L}{\partial \xi_i} = 0 : C - \alpha_i - \beta_i = 0 \quad (4)$$

Подставляя эти ограничения в L , получим *двойственную задачу*¹:

$$\begin{cases} L_D = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j x_i^T x_j \rightarrow \max_{\alpha} \\ \sum_{i=1}^N \alpha_i y_i = 0 \\ 0 \leq \alpha_i \leq C \quad (\text{используя (4) и } \alpha_i \geq 0, r_i \geq 0) \end{cases} \quad (5)$$

¹Седловая точка лагранжиана, \min для w, w_0, ξ_i и \max для α_i, β_i .

Определение типа объектов

- **неинформативные объекты:** $y_i(w^T x_i + w_0) > 1 \Leftrightarrow \xi_i = 0, y_i(w^T x_i + w_0) - 1 + \xi_i > 0 \Rightarrow \alpha_i = 0$
 - опорные вектора SV будут иметь $\alpha_i > 0$.
- **опорные объекты нарушители $SV \setminus \tilde{SV}$:**
 $y_i(w^T x_i + w_0) < 1 \Leftrightarrow \xi_i > 0 \Rightarrow \beta_i = 0 \Leftrightarrow \alpha_i = C$.
- **опорные пограничные объекты \tilde{SV} :** $y_i(w^T x_i + w_0) = 1 \Rightarrow$
 - $\xi_i = 0 \Rightarrow \beta_i > 0 \Rightarrow \alpha_i < C$ в общем случае
 - $y_i(w^T x_i + w_0) - 1 + \xi_i = 0 \Rightarrow \alpha_i > 0$ в общем случае

В общем случае $\alpha_i \in (0, C)$, ($\alpha_i = 0, C$ - частный случай).

Решение

- 1 Решим (5), чтобы найти α_i^*
- 2 Используя (3) и условие $\alpha_i^* = 0$ для неинформативных объектов, получим оптимальную w

$$w = \sum_{i \in \mathcal{SV}} \alpha_i^* y_i x_i$$

- 3 w_0 может быть найдено из условия пограничности объекта:

$$y_i(x_i^T w + w_0) = 1, \forall i \in \widetilde{\mathcal{SV}} \quad (6)$$

Решение для w_0

Домножая (6) на y_i , получим

$$x_i^T w + w_0 = y_i \quad \forall i \in \widetilde{SV} \quad (7)$$

Вычислительно более устойчивое решение: просуммируем 7 по всем $i \in \widetilde{SV}$:

$$n_{\widetilde{SV}} w_0 = \sum_{j \in \widetilde{SV}} (y_j - x_j^T w) = \sum_{j \in \widetilde{SV}} y_j - \sum_{j \in \widetilde{SV}} x_j^T w,$$

$$w_0 = \frac{1}{|\widetilde{SV}|} \left(\sum_{j \in \widetilde{SV}} y_j - \sum_{j \in \widetilde{SV}} \overbrace{\sum_{i \in SV} \alpha_i^* y_i x_i^T}^{w^T} x_j \right)$$

Если нет пограничных объектов, можно найти w_0 одномерной оптимизацией.

Построение прогнозов

- ❶ Решаем двойственную задачу, что найти α_i^* , $i = 1, 2, \dots, N$

$$\begin{cases} \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j \langle x_i, x_j \rangle \rightarrow \max_{\alpha} \\ \sum_{i=1}^N \alpha_i y_i = 0 \\ 0 \leq \alpha_i \leq C \quad (\text{используя (4) и } \alpha_i \geq 0, r_i \geq 0) \end{cases}$$

- ❷ Находим w_0 :

$$w_0 = \frac{1}{n_{\tilde{S}V}} \left(\sum_{j \in \tilde{S}V} y_j - \sum_{j \in \tilde{S}V} \sum_{i \in SV} \alpha_i^* y_i \langle x_i, x_j \rangle \right)$$

- ❸ Строим прогноз для нового x :

$$\hat{y} = \text{sign}[w^T x + w_0] = \text{sign}\left[\sum_{i \in SV} \alpha_i^* y_i \langle x_i, x \rangle + w_0\right]$$

Построение прогнозов

- ❶ Решаем двойственную задачу, что найти α_i^* , $i = 1, 2, \dots, N$

$$\begin{cases} L_D = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j \langle \mathbf{x}_i, \mathbf{x}_j \rangle \rightarrow \max_{\alpha} \\ \sum_{i=1}^N \alpha_i y_i = 0 \\ 0 \leq \alpha_i \leq C \quad (\text{используя (4) и } \alpha_i \geq 0, r_i \geq 0) \end{cases}$$

- ❷ Находим w_0 :

$$w_0 = \frac{1}{n_{\tilde{S}V}} \left(\sum_{j \in \tilde{S}V} y_j - \sum_{j \in \tilde{S}V} \sum_{i \in SV} \alpha_i^* y_i \langle \mathbf{x}_i, \mathbf{x}_j \rangle \right)$$

- ❸ Строим прогноз для нового \mathbf{x} :

$$\hat{y} = \text{sign}[w^T \mathbf{x} + w_0] = \text{sign} \left[\sum_{i \in SV} \alpha_i^* y_i \langle \mathbf{x}_i, \mathbf{x} \rangle + w_0 \right]$$

- На всех этапах нам нужно знать не \mathbf{x} , а скалярные произведения $\langle \mathbf{x}, \mathbf{x}' \rangle$!

Обобщение через ядра

- 1 Решаем двойственную задачу, что найти α_i^* , $i = 1, 2, \dots, N$

$$\begin{cases} L_D = \sum_{i=1}^N \alpha_i - \frac{1}{2} \sum_{i=1}^N \sum_{j=1}^N \alpha_i \alpha_j y_i y_j K(x_i, x_j) \rightarrow \max_{\alpha} \\ \sum_{i=1}^N \alpha_i y_i = 0 \\ 0 \leq \alpha_i \leq C \quad (\text{используя (4) и } \alpha_i \geq 0, r_i \geq 0) \end{cases}$$

- 2 Находим w_0 :

$$w_0 = \frac{1}{n_{\tilde{S}V}} \left(\sum_{j \in \tilde{S}V} y_j - \sum_{j \in \tilde{S}V} \sum_{i \in SV} \alpha_i^* y_i K(x_i, x_j) \right)$$

- 3 Строим прогноз для нового x :

$$\hat{y} = \text{sign}[w^T x + w_0] = \text{sign} \left[\sum_{i \in SV} \alpha_i^* y_i K(x_i, x) + w_0 \right]$$

- Заменяли $\langle x, x' \rangle \rightarrow K(x, x')$ для $K(x, x') = \langle \phi(x), \phi(x') \rangle$ с некоторым преобразованием признаков $\phi(\cdot)$.

Обобщение

Ядерно-обобщенный метод x :

$$\hat{y}(x) = \text{sign}[w^T x + w_0] = \text{sign}\left[\sum_{i \in \mathcal{SV}} \alpha_i^* y_i K(x_i, x) + w_0\right]$$

$K(x, z) = \langle \phi(x), \phi(z) \rangle$ - ядро Мерсера.

Ядро	$K(x, z)$
линейное	$\langle x, z \rangle$
полиномиальное	$(a\langle x, z \rangle + b)^d, \quad a > 0, \quad b \geq 0, \quad d = 1, 2, \dots$
RBF (Гауссово)	$e^{-\gamma \ x - z\ ^2}, \quad \gamma > 0$

Содержание

- 1 Линейно разделимый случай
- 2 Линейно неразделимый случай
- 3 Оптимизация - напоминание
- 4 Решение через двойственную задачу
- 5 Визуализация работы SVM с ядрами
 - SVM - линейное ядро
 - SVM - полиномиальное ядро
 - SVM - Гауссово ядро

5 Визуализация работы SVM с ядрами

- SVM - линейное ядро
- SVM - полиномиальное ядро
- SVM - Гауссово ядро

Параметр C

Условная оптимизация:


$$\begin{cases} \frac{1}{2} w^T w + C \sum_{i=1}^N \xi_i \rightarrow \min_{w, w_0, \xi} \\ y_i(w^T x_i + w_0) = M(x_i, y_i) \geq 1 - \xi_i, \quad i = 1, 2, \dots, N \\ \xi_i \geq 0, \quad i = 1, 2, \dots, N \end{cases}$$

Безусловная оптимизация:


$$\frac{1}{2C} \|w\|_2^2 + \sum_{i=1}^N [1 - M_i(w, w_0)]_+ \rightarrow \min_{w, w_0}$$

Параметр C контролирует противоречие: простота \leftrightarrow точность.


Линейное ядро, влияние C




Линейное ядро, влияние C



Линейное ядро, влияние C



Линейное ядро, влияние C



5 Визуализация работы SVM с ядрами

- SVM - линейное ядро
- SVM - полиномиальное ядро
- SVM - Гауссово ядро

Полиномиальное ядро

Полиномиальное ядро:


$$K(x, z) = (a\langle x, z \rangle + b)^d, \quad a > 0, \quad b \geq 0, \quad d = 1, 2, \dots$$

Прогноз


$$\begin{aligned}\hat{y}(x) &= \text{sign} \left(\sum_{i \in \mathcal{SV}} \alpha_i^* y_i K(x_i, x) + w_0 \right) = \\ &= \text{sign} \left(\sum_{i \in \mathcal{SV}} \alpha_i^* y_i (a\langle x, x_i \rangle + b)^d + w_0 \right)\end{aligned}$$

Граница между классами - полиномиальная поверхность порядка d .


Полиномиальное ядро, влияние d




Полиномиальное ядро, влияние d



Полиномиальное ядро, влияние d



Полиномиальное ядро, влияние d



5 Визуализация работы SVM с ядрами

- SVM - линейное ядро
- SVM - полиномиальное ядро
- SVM - Гауссово ядро

Гауссово ядро


Гауссово ядро:


$$K(x, z) = e^{-\gamma \|x - z\|^2}, \quad \gamma > 0$$


Прогноз

$$\begin{aligned}\hat{y}(x) &= \text{sign} \left(\sum_{i \in \mathcal{SV}} \alpha_i^* y_i K(x_i, x) + w_0 \right) \\ &= \text{sign} \left(\sum_{i \in \mathcal{SV}} \alpha_i^* y_i e^{-\gamma \|x - x_i\|^2} + w_0 \right)\end{aligned}$$


Классификация на основе близости x к опорным объектам в весах α_i^* (их важность).

Гауссово ядро, влияние γ 

Гауссово ядро, влияние γ 

Гауссово ядро, влияние γ 

Гауссово ядро, влияние γ



Заключение

- Метод опорных векторов - линейный классификатор с L_2 регуляризацией и функцией потерь hinge.
- Геометрически метод максимизирует зазор между классами.
- Решение зависит только от опорных векторов с $M \leq 1$.
- Решение через двойственную задачу зависит не от x , а от $\langle x_i, x_j \rangle$
 - допускает обобщение $\langle x_i, x_j \rangle \longrightarrow K(x_i, x_j) = \langle \phi(x_i), \phi(x_j) \rangle$
 - линейное ядро - без обобщения
 - полиномиальное ядро - полиномиальная граница
 - Гауссово ядро - метрический метод