


Метод опорных векторов

Виктор Китов

victorkitov.github.io

Курс поддержан
фондом
'Интеллект'





Победитель
конкурса VK среди
курсов по IT



Содержание

- 1 Линейно разделимый случай
- 2 Линейно неразделимый случай

Метод опорных векторов



Рассмотрим бинарную классификацию $y \in \{+1, -1\}$ линейно разделимой выборки.

Идея метода опорных векторов (support vector machines, SVM)

Выберем гиперплоскость, разделяющую классы с максимальным зазором.

Гиперплоскости $x_i^T w + w_0 = 0$, $x_i^T w + w_0 = b$, $x_i^T w + w_0 = -b$ поэтому величина зазора $\frac{2b}{\|w\|}$.

Метод опорных векторов

Объекты (x_i, y_i) отделены от разделяющей гиперплоскости
 $\geq \frac{b}{\|w\|}$, если

$$\begin{cases} x_i^T w + w_0 \geq b, & y_i = +1 \\ x_i^T w + w_0 \leq -b & y_i = -1 \end{cases} \quad i = 1, 2, \dots, N.$$

Это можно записать в виде

$$y_i(x_i^T w + w_0) \geq b, \quad i = 1, 2, \dots, N.$$

Максимизация зазора между классами:

$$2b / \|w\| \rightarrow \max_{w, w_0, b}$$

Оптимизационная задача

Оптимизационная задача:

$$\begin{cases} \frac{2b}{\|w\|} \rightarrow \max_{w, w_0, b} \\ y_i(x_i^T w + w_0) \geq b, \quad i = 1, 2, \dots, N. \end{cases}$$

Если (w, w_0, b) -решение, то $(\alpha w, \alpha w_0, \alpha b)$ - тоже решение $\forall \alpha > 0$. Положим $b = 1$ ($\alpha = \frac{1}{b}$).

$$\begin{cases} \frac{2}{\|w\|} \rightarrow \max_{w, w_0} \\ y_i(x_i^T w + w_0) \geq 1 \quad i = 1, 2, \dots, N. \end{cases}$$

Используя свойство $\arg \max \frac{2}{\|w\|} = \arg \min \frac{\|w\|}{2} = \arg \min \frac{\|w\|^2}{2}$:

$$\begin{cases} \frac{1}{2} w^T w \rightarrow \min_{w, w_0} \\ y_i(x_i^T w + w_0) = M(x_i, y_i) \geq 1, \quad i = 1, 2, \dots, N. \end{cases}$$


Типы объектов

Неинформативные объекты: $y_i(x_i^T w + w_0) > 1$

- не влияют на решение

Опорные вектора: $y_i(x_i^T w + w_0) = 1$


- лежат на расстоянии $1/\|w\|$ к разделяющей гиперплоскости
- влияют на решение



Содержание

- 1 Линейно разделимый случай
- 2 Линейно неразделимый случай

Линейно неразделимый случай



$$\begin{cases} \frac{1}{2} w^T w \rightarrow \min_{w, w_0} \\ y_i(x_i^T w + w_0) = M(x_i, y_i) \geq 1, \quad i = 1, 2, \dots, N. \end{cases}$$


Ограничения становятся несовместными \Rightarrow пустое множество решений.

Линейно неразделимый случай

Разрешим частичные нарушения ограничений на величины нарушений ξ_i (slack variables):

$$\begin{cases} \frac{1}{2} w^T w + C \sum_{i=1}^N \xi_i \rightarrow \min_{w, w_0, \xi} \\ y_i(w^T x_i + w_0) = M(x_i, y_i) \geq 1 - \xi_i, i = 1, 2, \dots, N \\ \xi_i \geq 0, i = 1, 2, \dots, N \end{cases}$$

- Штраф за нарушение C контролирует точность модели (в противовес простоте).
- Подбирается по сетке на валидации.
- Другие штрафы возможны, например $C \sum_i \xi_i^2$.



Типы объектов

- **Неинформативные объекты:**
 - $y_i(w^T x_i + w_0) > 1$
- **Опорные вектора SV :**
 - $y_i(w^T x_i + w_0) \leq 1$
 - **пограничные \widetilde{SV} :**
 - $y_i(w^T x_i + w_0) = 1$
 - **объекты-нарушители:**
 - $y_i(w^T x_i + w_0) > 0$: нарушитель корректно классифицирован
 - $y_i(w^T x_i + w_0) < 0$: нарушитель некорректно классифицирован


Безусловная оптимизация

Оптимизационная задача:

$$\begin{cases} \frac{1}{2} w^T w + C \sum_{i=1}^N \xi_i \rightarrow \min_{w, w_0, \xi} \\ y_i(w^T x_i + w_0) = M_i(w, w_0) \geq 1 - \xi_i, \\ \xi_i \geq 0, i = 1, 2, \dots, N \end{cases}$$

может быть переписана как

$$\frac{1}{2C} \|w\|_2^2 + \sum_{i=1}^N [1 - M_i(w, w_0)]_+ \rightarrow \min_{w, w_0}$$



Таким образом, метод - линейный классификатор с функцией потерь $\mathcal{L}(M) = [1 - M]_+$ и L_2 регуляризацией (обобщается на другие).

Разреженность решения

- Решение зависит только от опорных векторов.
- Это видно из условия $\mathcal{L}(M) = 0$ для $M \geq 1$.
 - хорошо классифицированные объекты с $M \geq 1$ не влияют на решение
- Разреженность решения - метод менее устойчив к выбросам
 - выбросы - всегда опорные объекты

Использование SVM

```
...  
from sklearn.svm import SVC  
from sklearn.metrics import accuracy_score  
  
X_train, X_test, Y_train, Y_test =  
    get_demo_classification_data()  
model = SVC(C=1) # инициализация модели  
model.fit(X_train, Y_train) # обучение модели  
Y_hat = model.predict(X_test) # построение прогнозов  
print(f'Точность прогнозов: \n  
{100*accuracy_score(Y_test, Y_hat):.1 f}%')  
  
print(f'Число опорных векторов к каждому классу: \n  
{model.n_support_}')  
# первые 5 опорных векторов:  
print(model.support_vectors_[:5])
```

- $1/C$ - вес при регуляризаторе.
- Больше информации. Полный код.

Ядерное обобщение

- Решение исходной задачи с ограничениями


$$\begin{cases} \frac{1}{2} w^T w + C \sum_{i=1}^N \xi_i \rightarrow \min_{w, w_0, \xi} \\ y_i(w^T x_i + w_0) = M_i(w, w_0) \geq 1 - \xi_i, \\ \xi_i \geq 0, i = 1, 2, \dots, N \end{cases}$$

вычислительно сложнее (нужно использовать условия Каруша-Куна-Таккера), зато позволяет получить решение, зависящее только от $\langle x', x'' \rangle$.


- Замена $\langle x', x'' \rangle \rightarrow K(x', x'')$ позволяет обобщить метод и сделать его нелинейным!
 - это ядерное обобщение (kernel trick).

Пример ядерно-обобщённых прогнозов


SVC with linear kernel



SVC with RBF kernel



SVC with polynomial (degree 3) kernel



Многоклассовый метод опорных векторов

С дискриминантных ф-ций строятся одновременно:

$$g_c(x) = (w^c)^T x + w_0^c, \quad c = \overline{1, C}.$$

Линейно разделимый случай:

$$\begin{cases} \sum_{c=1}^C (w^c)^T w^c \rightarrow \min_w \\ (w^{y_n})^T x_n + w_0^{y_n} - (w^c)^T x - w_0^c \geq 1 \quad \forall c \neq y_n, \\ n = \overline{1, N}. \end{cases}$$

Линейно неразделимый случай:

$$\begin{cases} \sum_{c=1}^C (w^c)^T w^c + C \sum_{n=1}^N \xi_n \rightarrow \min_w \\ (w^{y_n})^T x + w_0^{y_n} - (w^c)^T x - w_0^c \geq 1 - \xi_n \quad \forall c \neq y_n, \\ \xi_n \geq 0, \quad n = \overline{1, N}. \end{cases}$$


Настраивается медленнее, по точности сравним с бинарным обобщением через один-против-всех и один-против-одного.

Регрессия опорных векторов

Эквивалентная формулировка (без ограничений неравенства):

$$\frac{1}{2} \|\beta\|_2^2 + C \sum_{n=1}^N \mathcal{L}(x_n^T \beta + \beta_0 - y_n) \rightarrow \min_{\beta \in \mathbb{R}^D}$$

$$\mathcal{L}(u) = \begin{cases} 0, & \text{если } |u| \leq \varepsilon \\ |u| - \varepsilon & \text{иначе} \end{cases} \quad \varepsilon - \text{нечувствительная ф-ция потерь}$$



Решение будет зависеть только от объектов, где $|\text{ошибка}| \geq \varepsilon$, называемых опорными векторами.

Регрессия опорных векторов

Идея: допускаем небольшие $\pm\varepsilon$ отклонения, L_2 регуляризация.

$$\begin{cases} \frac{1}{2} \|\beta\|_2^2 \rightarrow \min_{\beta \in \mathbb{R}^D} & (\text{смещение } \beta_0 \text{ пишем явно}) \\ x_n^T \beta + \beta_0 - y_n \leq \varepsilon & n = \overline{1, N} \\ y_n - x_n^T \beta - \beta_0 \leq \varepsilon & n = \overline{1, N} \end{cases}$$


Если невозможно вписать все ошибки в интервал $[-\varepsilon, \varepsilon]$, воспользуемся методом общего вида:

$$\begin{cases} \frac{1}{2} \|\beta\|_2^2 + C \sum_{n=1}^N (\xi_n + \xi_n^*) \rightarrow \min_{\beta \in \mathbb{R}^D; \xi_n, \xi_n^* \in \mathbb{R}^N} \\ x_n^T \beta + \beta_0 - y_n \leq \varepsilon + \xi_n, & \xi_n \geq 0 & n = \overline{1, N} \\ y_n - x_n^T \beta - \beta_0 \leq \varepsilon + \xi_n^*, & \xi_n^* \geq 0 & n = \overline{1, N} \end{cases}$$

$C \geq 0$ - гиперпараметр, контролирующий противоречие между точностью и простотой модели.

Ядерное обобщение

- Решение через задачу с ограничениями приводит к решению, зависящему только от $\langle x', x'' \rangle$.
- Ядерное обобщение (kernel trick)¹: $\langle x', x'' \rangle \rightarrow K(x', x'')$



¹Источник.

Заключение

- Метод опорных векторов - линейный классификатор с L_2 регуляризацией и функцией потерь hinge.
- Геометрически метод максимизирует зазор между классами.
- Решение зависит только от опорных векторов с $M \leq 1$.
- Регрессия опорных векторов - линейная регрессия с L_2 регуляризацией и ε -нечувствительной функцией потерь.
- Методы допускают ядерное обобщение
 - и становятся нелинейными