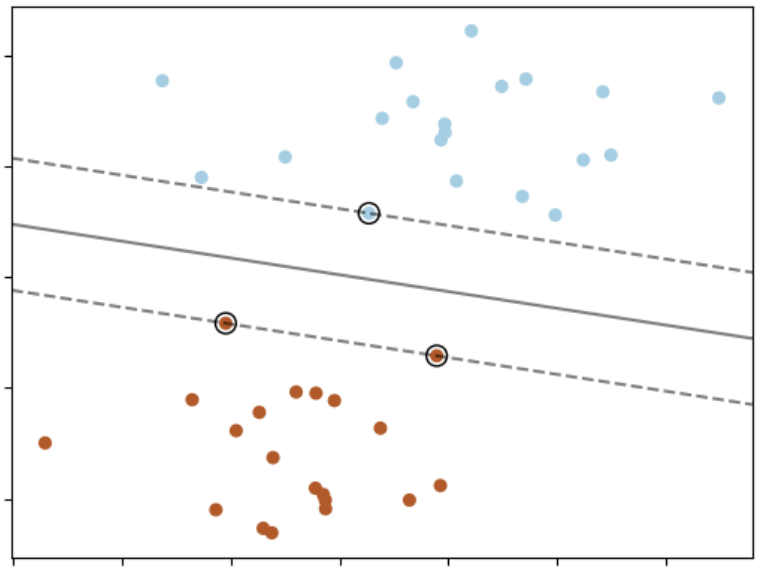
Метод опорных векторов

Виктор Китов

victorkitov.github.io



Курс поддержан фондом 'Интеллект'

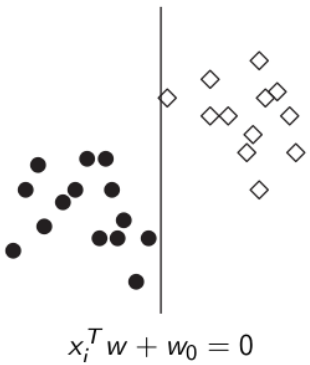
Победитель конкурса VK среди курсов по IT

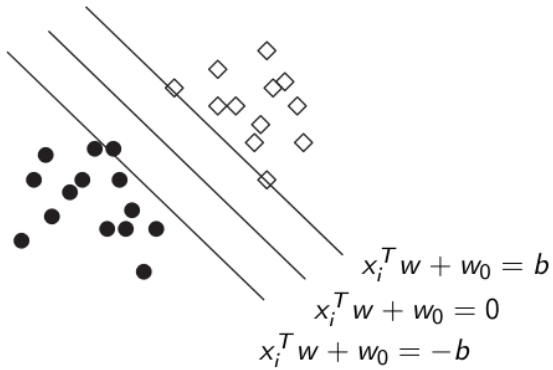
Содержание

1 Линейно разделимый случай

2 Линейно неразделимый случай

Метод опорных векторов





Рассмотрим бинарную классификацию $y \in \{+1, -1\}$ линейно разделимой выборки.

Идея метода опорных векторов (support vector machines, SVM)

Выберем гиперплоскость, разделяющую классы с максимальным зазором.

Гиперплоскости $\mathbf{x}_i^T \mathbf{w} + w_0 = 0$, $\mathbf{x}_i^T \mathbf{w} + w_0 = b$, $\mathbf{x}_i^T \mathbf{w} + w_0 = -b$ поэтому величина зазора $\frac{2b}{\|\mathbf{w}\|}$.

Метод опорных векторов

Объекты (x_i, y_i) отделены от разделяющей гиперплоскости $\geq \frac{b}{\|\mathbf{w}\|}$, если

$$\begin{cases} \mathbf{x}_i^T\mathbf{w} + w_0 \geq b, & y_i = +1 \\ \mathbf{x}_i^T\mathbf{w} + w_0 \leq -b & y_i = -1 \end{cases} \quad i = 1, 2, ...N.$$

Это можно записать в виде

$$y_i(\mathbf{x}_i^T\mathbf{w} + w_0) \geq b, \quad i = 1, 2, ...N.$$

Максимизация зазора между классами:

$$2b/\|\mathbf{w}\| \to \max_{\mathbf{w}, w_0, b}$$

Оптимизационная задача

Оптимизационная задача:

$$\begin{cases} \frac{2b}{\|\mathbf{w}\|} \to \max\limits_{\mathbf{w},w_0,b} \\ y_i(\mathbf{x}_i^T\mathbf{w}+w_0) \geq b, \quad i=1,2,...N. \end{cases}$$

Если $(\mathbf{w},w_0,b)$-решение, то $(\alpha\mathbf{w},\alpha w_0,\alpha b)$ - тоже решение $\forall\alpha>0$. Положим $b=1$ $(\alpha=\frac{1}{b})$.

$$\begin{cases} \frac{2}{\|\mathbf{w}\|} \to \max\limits_{\mathbf{w},w_0} \\ y_i(\mathbf{x}_i^T\mathbf{w}+w_0) \geq 1 \quad i=1,2,...N. \end{cases}$$

Используя свойство
$\arg\max \frac{2}{\|\mathbf{w}\|} = \arg\min \frac{\|\mathbf{w}\|}{2} = \arg\min \frac{\|\mathbf{w}\|^2}{2}$:

$$\begin{cases} \frac{1}{2}\mathbf{w}^T\mathbf{w} \to \min\limits_{\mathbf{w},w_0} \\ y_i(\mathbf{x}_i^T\mathbf{w}+w_0) = M(\mathbf{x}_i,y_i) \geq 1, \quad i=1,2,...N. \end{cases}$$

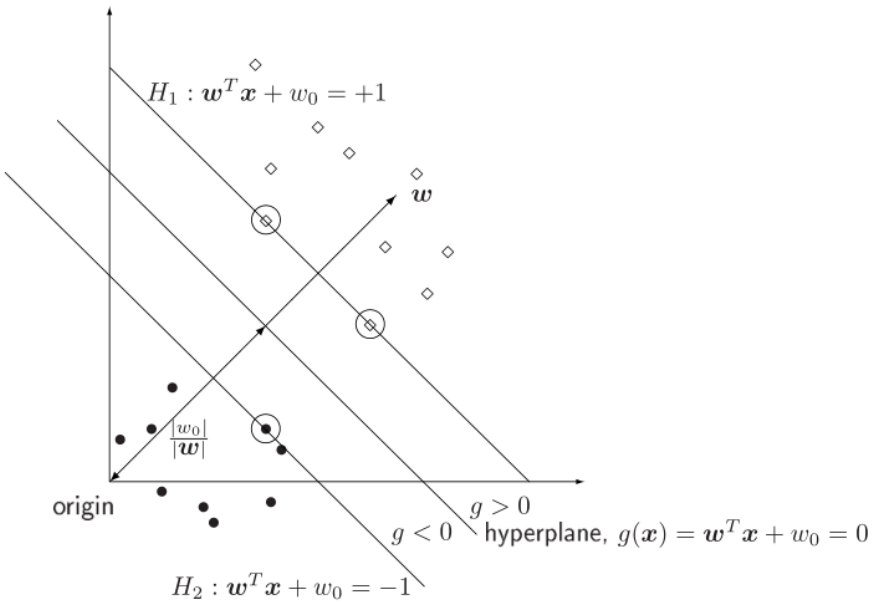
Типы объектов

Неинформативные объекты: $y_i(\mathbf{x}_i^T\mathbf{w} + w_0) > 1$

- не влияют на решение

Опорные вектора: $y_i(\mathbf{x}_i^T\mathbf{w} + w_0) = 1$

- лежат на расстоянии $1/\|\mathbf{w}\|$ к разделяющей гиперплоскости
- влияют на решение

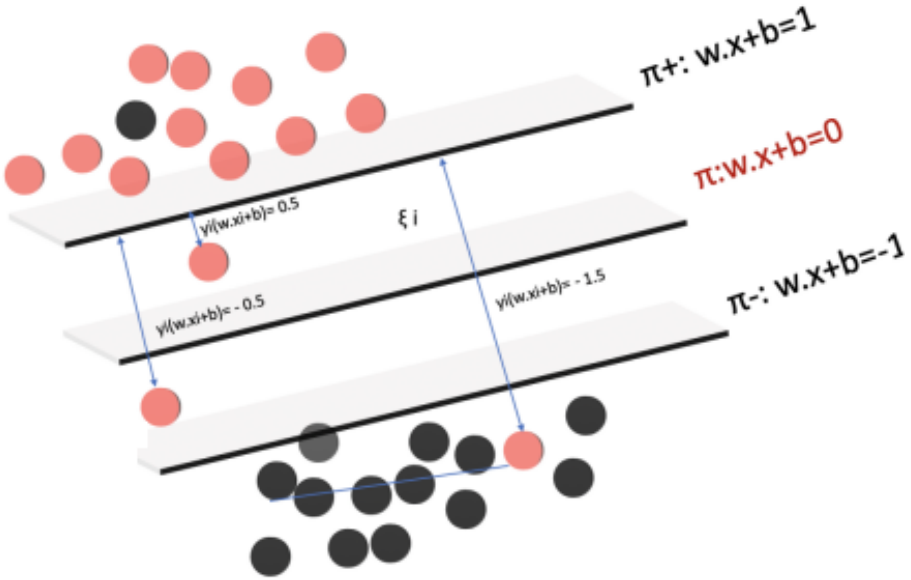


Содержание

1 Линейно разделимый случай

2 Линейно неразделимый случай

Линейно неразделимый случай



$$\begin{cases} \frac{1}{2}\mathbf{w}^T\mathbf{w} \to \min\limits_{\mathbf{w},w_0} \\ y_i(\mathbf{x}_i^T\mathbf{w} + w_0) = M(\mathbf{x}_i, y_i) \geq 1, \quad i = 1, 2, ...N. \end{cases}$$

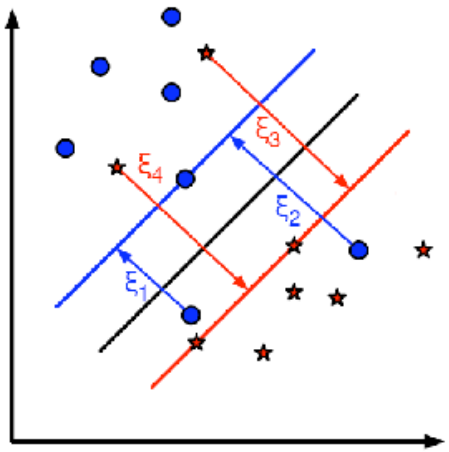
Ограничения становятся несовместными=>пустое множество решений.

Линейно неразделимый случай

Разрешим частичные нарушения ограничений на величины нарушений ξ_i (slack variables):

$$\begin{cases} \frac{1}{2}\mathbf{w}^T\mathbf{w} + C\sum_{i=1}^N \xi_i \to \min_{\mathbf{w},w_0,\boldsymbol{\xi}} \\ y_i(\mathbf{w}^T\mathbf{x}_i + w_0) = M(\mathbf{x}_i, y_i) \geq 1 - \xi_i,\ i = 1,2,...N \\ \xi_i \geq 0,\ i = 1,2,...N \end{cases}$$

- Штраф за нарушение C контролирует точность модели (в противовес простоте).
- Подбирается по сетке на валидации.
- Другие штрафы возможны, например $C\sum_i \xi_i^2$.



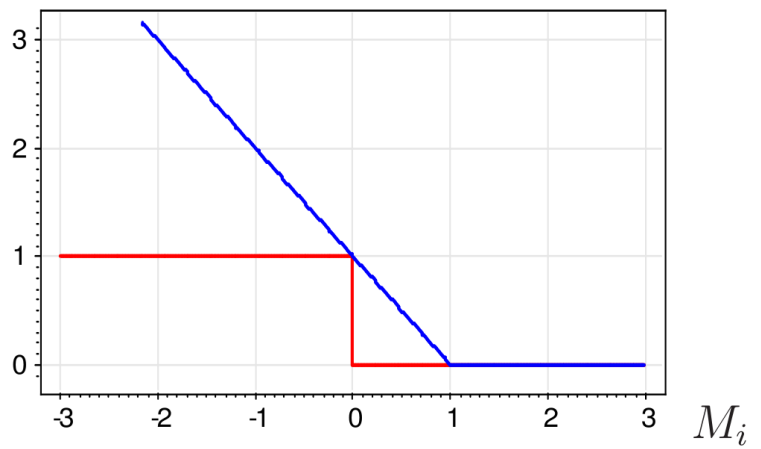
Типы объектов

- **Неинформативные объекты**:
  - $y_i(\mathbf{w}^T\mathbf{x}_i + w_0) > 1$
- **Опорные вектора** SV**:**
  - $y_i(\mathbf{w}^T\mathbf{x}_i + w_0) \leq 1$
  - **пограничные** $\widetilde{SV}$:
    - $y_i(\mathbf{w}^T\mathbf{x}_i + w_0) = 1$
  - **объекты-нарушители**:
    - $y_i(\mathbf{w}^T\mathbf{x}_i + w_0) > 0$: нарушитель корректно классифицирован
    - $y_i(\mathbf{w}^T\mathbf{x}_i + w_0) < 0$: нарушитель некорректно классифицирован

Безусловная оптимизация

Оптимизационная задача:

$$\begin{cases} \frac{1}{2}\mathbf{w}^T\mathbf{w} + C\sum_{i=1}^N \xi_i \to \min_{\mathbf{w},w_0,\xi} \\ y_i(\mathbf{w}^T\mathbf{x}_i + w_0) = M_i(\mathbf{w},w_0) \geq 1-\xi_i, \\ \xi_i \geq 0,\ i=1,2,...N \end{cases}$$



может быть переписана как

$$\frac{1}{2C}\|\mathbf{w}\|_2^2 + \sum_{i=1}^N [1-M_i(\mathbf{w},w_0)]_+ \to \min_{\mathbf{w},w_0}$$

Таким образом, метод - линейный классификатор с функцией потерь $\mathcal{L}(M) = [1-M]_+$ и L_2 регуляризацией (обобщается на другие).

Разреженность решения

- Решение зависит только от опорных векторов.
- Это видно из условия $\mathcal{L}(M) = 0$ для $M \geq 1$.
  - хорошо классифицированные объекты с $M \geq 1$ не влияют на решение
- Разреженность решения - метод менее устойчив к выбросам
  - выбросы - всегда опорные объекты

Использование SVM

```
...
from sklearn.svm import SVC
from sklearn.metrics import accuracy_score

X_train, X_test, Y_train, Y_test =
    get_demo_classification_data()
model = SVC(C=1)                    # инициализация модели
model.fit(X_train, Y_train)         # обучение модели
Y_hat = model.predict(X_test) # построение прогнозов
print(f'Точность прогнозов: \
{100*accuracy_score(Y_test, Y_hat):.1f}%')

print(f'Число опорных векторов к каждом классе: \
{model.n_support_}')
# первые 5 опорных векторов:
print(model.support_vectors_[:5])
```

- 1/C - вес при регуляризаторе.

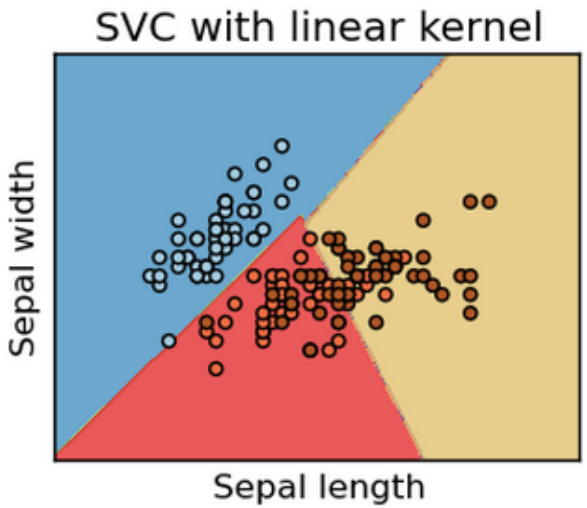
Ядерное обобщение

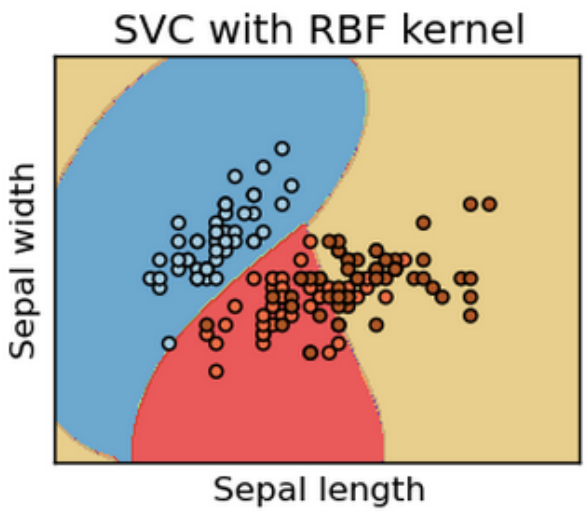
- Решение исходной задачи с ограничениями

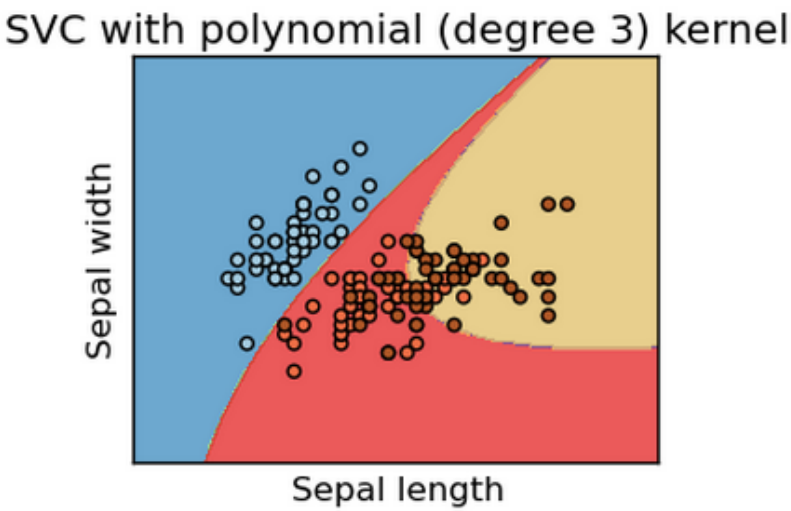
$$\begin{cases} \frac{1}{2}\mathbf{w}^T\mathbf{w} + C\sum_{i=1}^N \xi_i \to \min_{\mathbf{w},w_0,\xi} \\ y_i(\mathbf{w}^T\mathbf{x}_i + w_0) = M_i(\mathbf{w},w_0) \geq 1-\xi_i, \\ \xi_i \geq 0,\ i=1,2,...N \end{cases}$$

  вычислительно сложнее (нужно использовать условия Каруша-Куна-Таккера), зато позволяет получить решение, зависящее только от $\langle x', x''\rangle$.
- Замена $\langle x', x''\rangle \to K(x', x'')$ позволяет обобщить метод и сделать его нелинейным!
  - это ядерное обобщение (kernel trick).

Пример ядерно-обобщённых прогнозов







Многоклассовый метод опорных векторов

C дискриминантных ф-ций строятся одновременно:

$$g_c(\mathbf{x}) = (\mathbf{w}^c)^T\mathbf{x} + w_0^c, \qquad c = 1, 2, ...C$$

Линейно разделимый случай:

$$\begin{cases} \sum_{c=1}^{C}(\mathbf{w}^c)^T\mathbf{w}^c \to \min_{\{\mathbf{w}^c, w^c\}_c} \\ (\mathbf{w}^{y_n})^T\mathbf{x}_n + w_0^{y_n} - (\mathbf{w}^c)^T\mathbf{x} - w_0^c \geq 1 \quad \forall c \neq y_n, \\ n = 1, 2, ...N \end{cases}$$

Линейно неразделимый случай:

$$\begin{cases} \sum_{c=1}^{C}(\mathbf{w}^c)^T\mathbf{w}^c + C\sum_{n=1}^{N}\xi_n \to \min_{\{\mathbf{w}^c, w_0^c\}_c, \boldsymbol{\xi}} \\ (\mathbf{w}^{y_n})^T\mathbf{x}_n + w_0^{y_n} - (\mathbf{w}^c)^T\mathbf{x}_n - w_0^c \geq 1 - \xi_n \quad \forall c \neq y_n, \\ \xi_n \geq 0, \quad n = 1, 2, ...N \end{cases}$$

Настраивается медленнее, по точности сравним с бинарным обобщением через один-против-всех и один-против-одного.

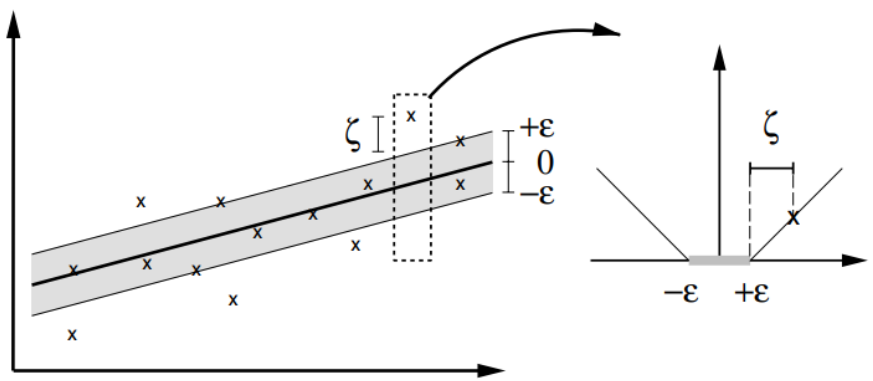
Регрессия опорных векторов

Эквивалентная формулировка (без ограничений неравенства):

$$\frac{1}{2}\|w\|_2^2 + C\sum_{n=1}^{N}\mathcal{L}(\mathbf{x}_n^T\mathbf{w} + w_0 - y_n) \to \min_{w,w_0}$$

$$\mathcal{L}(u) = \begin{cases} 0, & \text{если } |u| \le \varepsilon \\ |u| - \varepsilon & \text{иначе} \end{cases}$$

ε – нечувствительная ф-ция потерь



Решение будет зависеть только от объектов, где |ошибка|$\ge \varepsilon$, называемых опорными векторами.

Регрессия опорных векторов

Идея: допускаем небольшие $\pm\varepsilon$ отклонения, L_2 регуляризация.

$$\begin{cases} \frac{1}{2}\|\mathbf{w}\|_2^2 \to \min_{\mathbf{w},w_0} & \text{(смещение } \beta_0 \text{ пишем явно)} \\ \mathbf{x}_n^T\mathbf{w} + w_0 - y_n \le \varepsilon & n = \overline{1,N} \\ y_n - \mathbf{x}_n^T\mathbf{w} - w_0 \le \varepsilon & n = \overline{1,N} \end{cases}$$

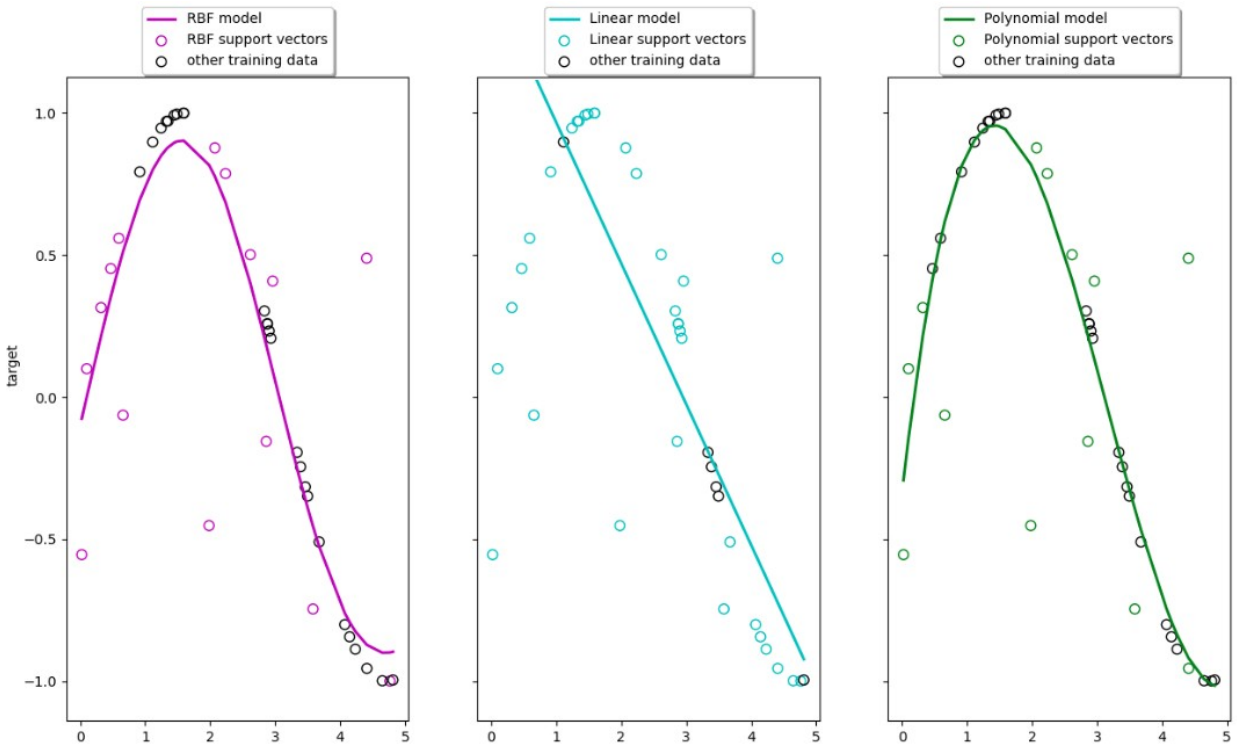
Если невозможно вписать все ошибки в интервал $[-\varepsilon, \varepsilon]$, воспользуемся методом общего вида:

$$\begin{cases} \frac{1}{2}\|\mathbf{w}\|_2^2 + C\sum_{n=1}^N(\xi_n + \xi_n^*) \to \min_{\mathbf{w},w_0;\xi_n,\xi_n^* \in \mathbb{R}^N} & \\ \mathbf{x}_n^T\mathbf{w} + w_0 - y_n \le \varepsilon + \xi_n, \quad \xi_n \ge 0 & n = \overline{1,N} \\ y_n - \mathbf{x}_n^T\mathbf{w} - w_0 \le \varepsilon + \xi_n^*, \quad \xi_n^* \ge 0 & n = \overline{1,N} \end{cases}$$

$C \ge 0$ - гиперпараметр, контролирующий противоречие между точностью и простотой модели.

Ядерное обобщение

- Решение через задачу с ограничениями приводит к решению, зависящему только от $\langle x', x'' \rangle$.
- Ядерное обобщение (kernel trick)[1]: $\langle x', x'' \rangle \to K(x', x'')$



[1] Источник.

Заключение

- Метод опорных векторов - линейный классификатор с L_2 регуляризацией и функцией потерь hinge.
- Геометрически метод максимизирует зазор между классами.
- Решение зависит только от опорных векторов с $M \leq 1$.
- Регрессия опорных векторов - линейная регрессия с L_2 регуляризацией и ε-нечувствительной функцией потерь.
- Методы допускают ядерное обобщение
  - и становятся нелинейными