Ядерное обобщение гребневой регрессии

Виктор Китов

1 Обозначения

Рассмотрим задачу регрессии $y \in \mathbb{R}$.

- N - число объектов: $(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), ...(\mathbf{x}_N, y_N)$.
- $X \in \mathbb{R}^{N \times D}$ - матрица объекты-признаки, вектор откликов: $\mathbf{y} = Y \in \mathbb{R}^N$.
- D - число признаков (включая константу), $\mathbf{x}_i \in \mathbb{R}^D$,$i = 1, 2, ...N$.

2 Обычное решение

Оптимизационный критерий гребневой регрессии:

$$\sum_{n=1}^{N} \left(\mathbf{x}_n^T \mathbf{w} - y_n\right)^2 + \lambda \mathbf{w}^T \mathbf{w} \to \min_{\mathbf{w}}$$

Он выпуклый, поэтому равенство нулю производной=глобальный минимум. Продифференцируем его:

$$2\sum_{n=1}^{N} \mathbf{x}_n \left(\mathbf{x}_n^T \mathbf{w} - y_n\right) + 2\lambda \mathbf{w} = 0$$

$$2X^T(X\mathbf{w} - Y) + \lambda \mathbf{w} = 0$$

$$\left(X^T X + \lambda I\right) \mathbf{w} = X^T Y$$

откуда

$$\widehat{\mathbf{w}} = (X^T X + \lambda I)^{-1} X^T Y$$

- Сложность обучения:

операция	**сложность**
$X^T X$	$O(D^2 N)$
$+\lambda I$	$O(D)$
$(X^T X + \lambda I)^{-1}$	$O(D^3)$
$X^T Y$	$O(DN)$
$(X^T X + \lambda I)^{-1} X^T Y$	$O(D^2)$
общая сложность:	$O(D^2 N + D^3)$

- Сложность предсказания: $\widehat{y}(x) = x^T w$, поэтому сложность $O(D)$.

В библиотеке sklearn метод реализован как sklearn.linear_model.Ridge.

3 Решение с ядерным обобщением

Выведем формулу для нахождения весов в $\widehat{y}(\mathbf{x}) = \mathbf{x}^T \mathbf{w}$ по-другому, чтобы прогноз зависел только от скалярных произведений. Для этого перепишем оптимизационную задачу

$$\sum_{n=1}^{N} \left(\mathbf{x}_n^T \mathbf{w} - y_n\right)^2 + \lambda \mathbf{w}^T \mathbf{w} \to \min_{\mathbf{w}} \tag{1}$$

в эквивалентном виде:

$$\begin{cases} \frac{1}{2} \|\boldsymbol{\varepsilon}\|^2 + \frac{1}{2}\lambda \|\mathbf{w}\|^2 \to \min_{w,\varepsilon} \\ \varepsilon_i = \mathbf{x}_i^T \mathbf{w} - y_i \qquad\qquad n = \overline{1, N} \end{cases}$$

Для решения оптимизационной задачи с ограничениями на равенство воспользуемся методом множителей Лагранжа. Выпишем Лагранжиан и продифференцируем его:

$$L = \frac{1}{2} \boldsymbol{\varepsilon}^T \boldsymbol{\varepsilon} + \frac{1}{2} \lambda \mathbf{w}^T \mathbf{w} + \sum_i \alpha_i \left(\mathbf{x}_i^T \mathbf{w} - y_i - \varepsilon_i\right)$$

$$\frac{\partial L}{\partial \mathbf{w}} = \lambda \mathbf{w} + \sum_i \alpha_i \mathbf{x}_i = 0$$
$$\frac{\partial L}{\partial \varepsilon_i} = \varepsilon_i - \alpha_i = 0$$

Отсюда следует, что $\varepsilon_i = \alpha_i$ и $w = -\frac{1}{\lambda} \sum_i \alpha_i x_i$. Подставим это в Лагранжиан и получим двойственную задачу

(относительно двойственных переменных - вектора весов α):

$$\begin{aligned} L &= \frac{1}{2}\boldsymbol{\alpha}^T\boldsymbol{\alpha} + \frac{1}{2}\lambda\frac{1}{\lambda^2}\sum_{i,j}\alpha_i\alpha_j\mathbf{x}_i^T\mathbf{x}_j + \sum_i \alpha_i \sum_j \alpha_j\mathbf{x}_j^T\mathbf{x}_i\left(-\frac{1}{\lambda}\right) - \sum_i \alpha_i\left(y_i + \alpha_i\right) \\ &= \frac{1}{2\lambda}\sum_{i,j}\alpha_i\alpha_j\mathbf{x}_i^T\mathbf{x}_j - \frac{1}{\lambda}\sum_{i,j}\alpha_i\alpha_j\mathbf{x}_i^T\mathbf{x}_j - \frac{1}{2}\boldsymbol{\alpha}^T\boldsymbol{\alpha} - \sum_i \alpha_i y_i \\ &= -\frac{1}{2\lambda}\sum_{i,j}\alpha_i\alpha_j\mathbf{x}_i^T\mathbf{x}_j - \boldsymbol{\alpha}^T\mathbf{y} - \frac{1}{2}\boldsymbol{\alpha}^T\boldsymbol{\alpha} \to extr_\alpha \end{aligned}$$

Изменим знак (не влияющий на точку экстремума):

$$\frac{1}{2\lambda}\sum_{i,j}\alpha_i\alpha_j\mathbf{x}_i^T\mathbf{x}_j + \frac{1}{2}\boldsymbol{\alpha}^T\boldsymbol{\alpha} + \boldsymbol{\alpha}^T\mathbf{y} \to \mathrm{extr}_{\boldsymbol{\alpha}}$$

Определим матрицу Грамма $M \in \mathbb{R}^{NxN}$ с элементами $\{M\}_{i,j} = x_i^T x_j$. Тогда можем переписать задачу на экстремум в матричном виде:

$$Q = \frac{1}{2\lambda}\boldsymbol{\alpha}^T M\boldsymbol{\alpha} + \frac{1}{2}\boldsymbol{\alpha}^T\boldsymbol{\alpha} + \boldsymbol{\alpha}^T\mathbf{y} \to \mathrm{extr}_{\boldsymbol{\alpha}}$$

$$\frac{dQ}{d\alpha} = \frac{1}{\lambda}M\boldsymbol{\alpha} + \boldsymbol{\alpha} + \mathbf{y} = 0,$$

что эквивалентно

$$\left(\frac{1}{\lambda}M + I\right)\boldsymbol{\alpha} = -\mathbf{y} \quad \Longrightarrow \quad \boldsymbol{\alpha} = -\left(\frac{1}{\lambda}M + I\right)^{-1}\mathbf{y}$$

- Сложность обучения:

операция	**сложность**
M	$O(N^2D)$
$\frac{1}{\lambda}M$	$O(N^2)$
$\frac{1}{\lambda}M + I$	$O(N)$
$\left(\frac{1}{\lambda}M + I\right)^{-1}$	$O(N^3)$
$-\left(\frac{1}{\lambda}M + I\right)^{-1}\mathbf{y}$	$O(N^2)$
общая сложность:	$O(N^2D + N^3)$

- Сложность предсказания $\widehat{y}(x) = x^T w = -\frac{1}{\lambda}\sum_i \alpha_i x_i^T x$ будет уже $O(DN)$, если используем только скалярные произведения объектов.

Преимущества:

- Имеем аналитическое решение для α, являющееся глобальным оптимумом.

- Решение всегда существует, поскольку $M \succcurlyeq 0$ (неотрицательно определена)

$$\mathbf{z}^T M \mathbf{z} = \sum_{i,j} z_i z_j \mathbf{x}_i^T \mathbf{x}_j = \left(\sum_i z_i \mathbf{x}_i \right)^T \left(\sum_j z_j \mathbf{x}_j \right) = \left\| \sum_i z_i \mathbf{x}_i \right\|^2 \geq 0 \, \forall z \in \mathbb{R}^N$$

  Поскольку $\lambda > 0$, а единичная матрица положительно определена, то $\frac{1}{\lambda} M + I$ - положительно определена, следовательно всегда невырождена и $\left(\frac{1}{\lambda} M + I \right)^{-1}$ всегда существует.

Недостаток:

Прогноз через скалярные произведения выражается как $\widehat{y}(\mathbf{x}) = \mathbf{w}^T \mathbf{x} = -\frac{1}{\lambda} \sum_i \alpha_i \mathbf{x}_i^T \mathbf{x}$. Вектор α - не разреженный (элементы - не нули в общем случае), поэтому существенно увеличивается сложность построения прогноза до $O(ND)$.

4 Ядерное обобщение решения (kernel trick)

Решение для $\boldsymbol{\alpha}$ и прогноз зависят от объектов не напрямую, а опосредованно через скалярные произведения. Поэтому можем обобщить решение, заменив везде $\mathbf{x}^T \mathbf{x}' \to K(\mathbf{x}, \mathbf{x}')$, где функция ядра $K(\mathbf{x}, \mathbf{x}') = \langle \phi(\mathbf{x}), \phi(\mathbf{x}') \rangle$ соответствует обычному скалярному произведению, но после некоторого преобразования признаков $\mathbf{x} \to \phi(\mathbf{x})$, где каждый объект $\mathbf{x}$ переводится в так называемое спрямляющее пространство $\phi(\mathbf{x})$.

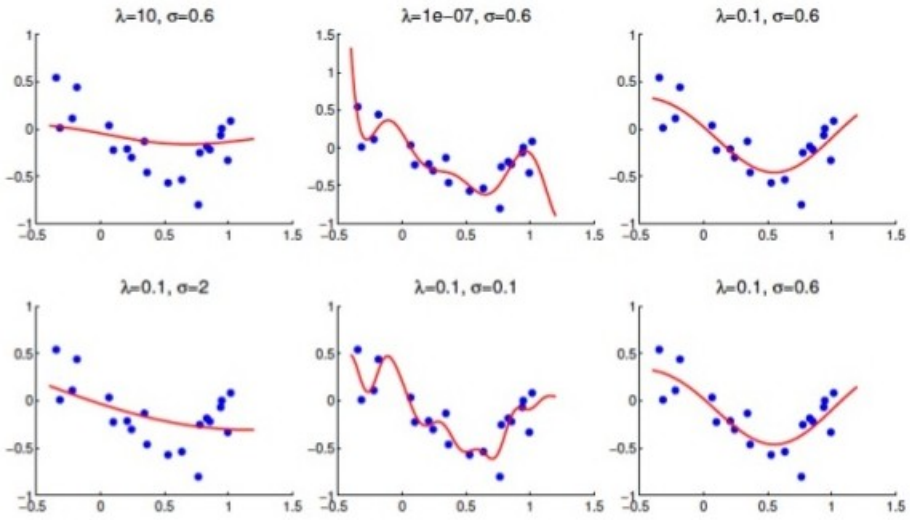
Матрица Грама тогда будет состоять из элементов $\{M\}_{i,j} = K(\mathbf{x}_i, \mathbf{x}_j)$, $\boldsymbol{\alpha} = \left(\frac{1}{\lambda} M + I \right)^{-1} \mathbf{y}$, а прогноз строится по формуле

$$\widehat{y}(\mathbf{x}) = \langle \mathbf{w}, \mathbf{x} \rangle = -\frac{1}{\lambda} \sum_i \alpha_i \langle \mathbf{x}_i, \mathbf{x} \rangle = -\frac{1}{\lambda} \sum_i \alpha_i K(\mathbf{x}_i, \mathbf{x})$$

Применим к Гауссову ядру:

$$K(\mathbf{x}, \mathbf{x}') = e^{-\gamma \left\| \mathbf{x} - \mathbf{x}' \right\|_2^2} = e^{\left\| \mathbf{x} - \mathbf{x}' \right\|^2 / (2\sigma^2)}$$

Пример прогнозов для Гауссова ядра:



Параметр λ по-прежнему определяет сложность (гибкость) модели, а γ (или σ для альтернативной параметризации) определяет скорость изменения Гауссиан, из линейной комбинации которых составляется прогноз. При использовании (λ, γ) нужно настраивать по сетке. В библиотеке sklearn метод реализован как sklearn.kernel_ridge.KernelRidge.