Метод главных компонент

Виктор Китов

victorkitov.github.io

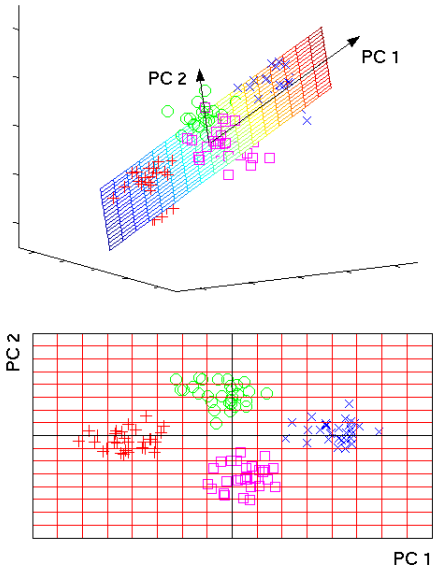

Курс поддержан фондом 'Интеллект'

Победитель конкурса VK среди курсов по IT

Содержание

1. Задача снижения размерности
2. Применение метода главных компонент
3. Определение главных компонент
4. Свойства проекций на главные компоненты
5. Глобальная оптимальность главных компонент

Задача снижения размерности

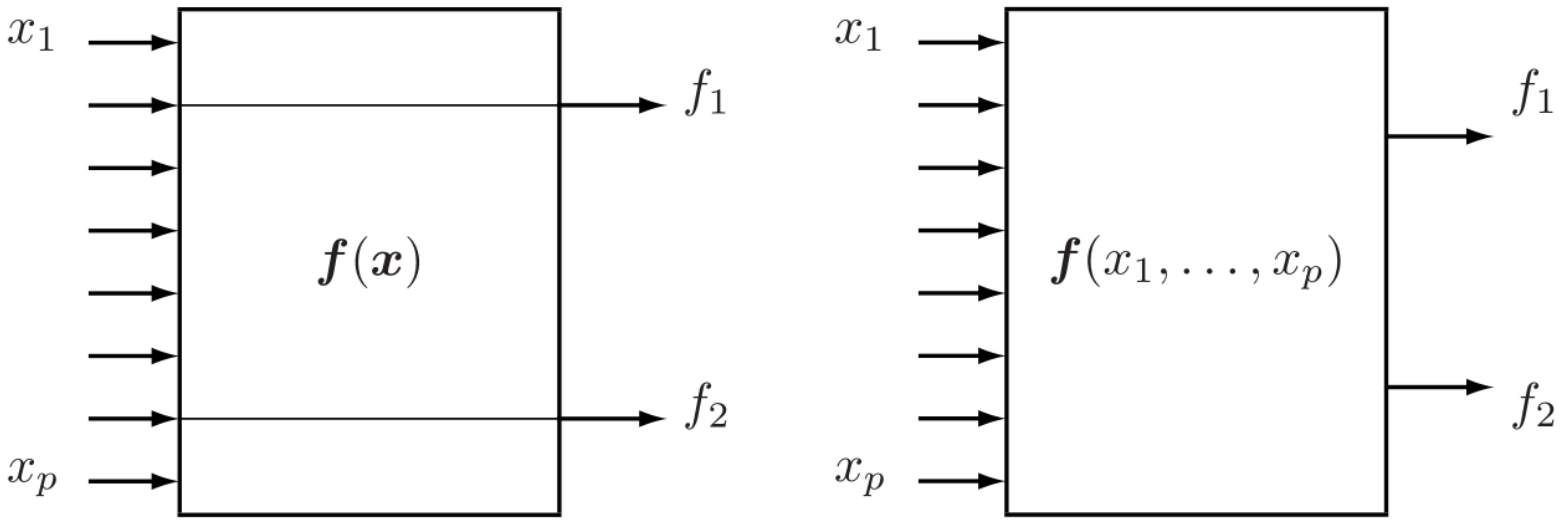

(a) feature selector (b) feature extractor

- **Снижение размерности:** преобразование всех входных признаков в уменьшенное число новых признаков.
- Виды снижения размерности:
  - с учителем/без учителя
  - линейное/нелинейное.

Применения снижения размерности

Применения снижения размерности:

- Визуализация многомерных данных в 2D или 3D
- Снижение вычислительных ресурсов при обучении и применении
  - процессор, память, хранение на диске, пересылка
- Повышение интерпретируемости модели
  - если извлеченные признаки интерпретируемы
- Повышение устойчивости некоторых методов
  - при линейно-зависимых признаках коэффициенты лин. регрессии не определены

Категоризация методов снижения размерности

- Метод главных компонент (principal component analysis)
  - линейный метод снижения размерности без учителя.
- Находится подпространство наилучшей аппроксимации
  - в среднеквадратичном смысле

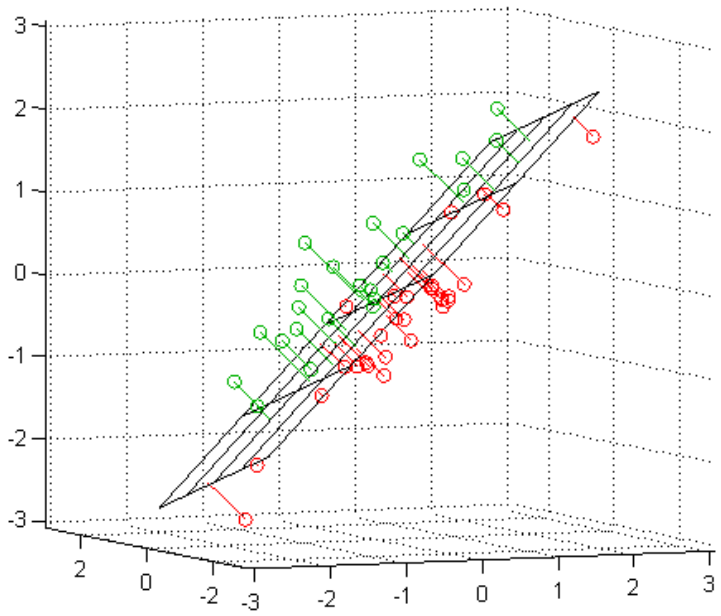

- Гл. компоненты-ортонормированный базис этого подпр-ва.

Содержание

1. Задача снижения размерности
2. Применение метода главных компонент
3. Определение главных компонент
4. Свойства проекций на главные компоненты
5. Глобальная оптимальность главных компонент

Визуализация в 2D, 3D

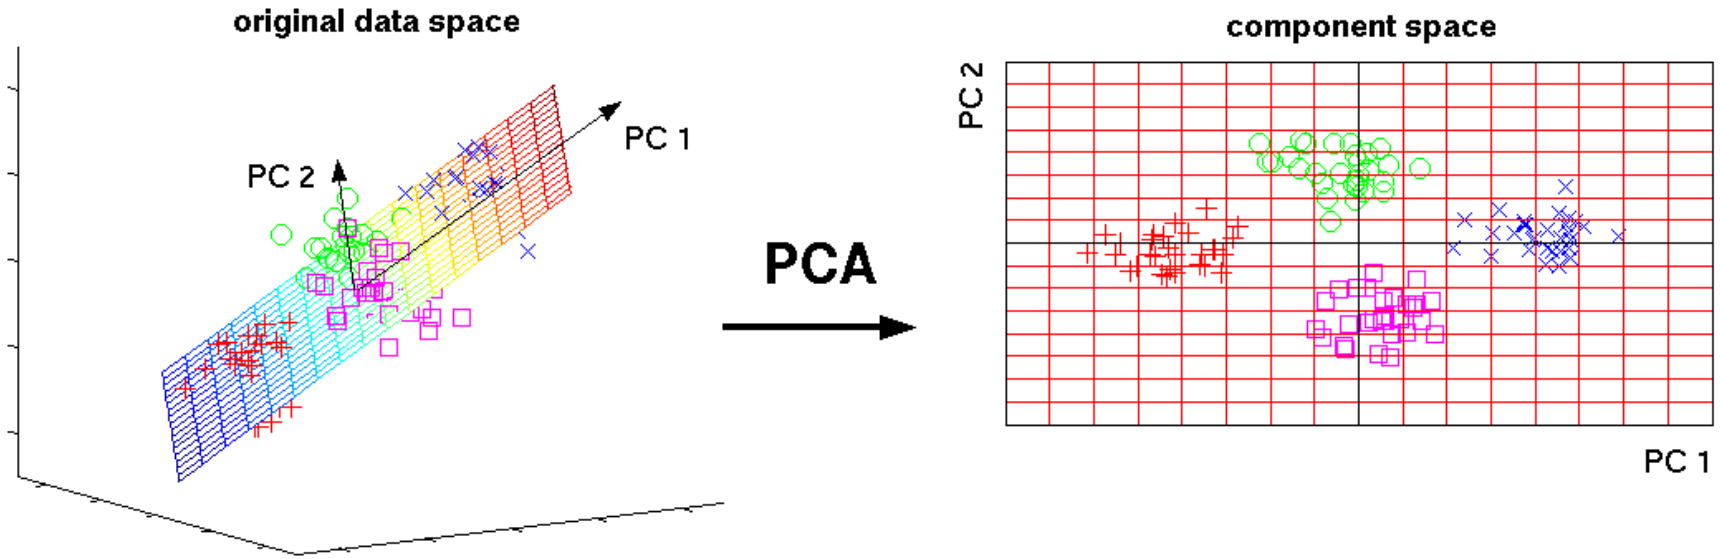

Стандартная обработка изображений

Идентификация человека по лицу:

Для фото $H \times W$: HW признаков

- переобучение.

Использование главных компонент (eigenfaces)

Главные компоненты (eigenfaces) - семантические признаки:

Достаточно малого числа гл. компонент для точной аппр-ции.

- аналогично построению фоторобота

Базовое представление текстов

- Объекты - текстовые файлы.
- Индикаторные, TF, TF-IDF кодировки приводят в высокому D.
  - вычислительно долгая работа с X и настройкой моделей
- Разреженность данных приводит к проблемам:
  - например, задача поиска:
    "ремонт машины" != "обслуживание автомобилей"

Представление через главные компоненты

- Снижение размерности PCA позволяет решить эти проблемы.
  - технически-через сокр. сингулярное разложение
  - достаточно 200-300 гл. компонент
  - признаки не центрируются, чтобы не потерять разреженность
  - англ. latent semantic analysis (LSA)

Обозначения

Далее в лекции будем рассматривать дискретное пространство исходов <u>только по конечной обучающей выборке</u>

$$X = \{\boldsymbol{x}_n\}_{n=1}^N$$

В этом пространстве

- мат. ожидание=выборочное среднее
- дисперсия=выборочная дисперсия

Содержание

1. Задача снижения размерности
2. Применение метода главных компонент
3. Определение главных компонент
4. Свойства проекций на главные компоненты
5. Глобальная оптимальность главных компонент

Выборочные оценки

- **Выборочное среднее:**

$$\boldsymbol{\mu} = \frac{1}{N}\sum_{n=1}^{N}\boldsymbol{x}_n$$

- **Выборочная ковариационная матрица:**

$$\Sigma = \frac{1}{N}\sum_{n=1}^{N}(\boldsymbol{x}_n - \boldsymbol{\mu})(\boldsymbol{x}_n - \boldsymbol{\mu})^T$$

- Из определения $\Sigma = \Sigma^T$, по спектральной теореме существует ортонормированный базис из СВ $\boldsymbol{q}_1, ...\boldsymbol{q}_D$, отвечающих СЗ $\lambda_1 \geq \lambda_2 \geq ... \geq \lambda_D$.

$$\Sigma = Q\Lambda Q^T = \sum_{i=1}^{D}\lambda_i \boldsymbol{q}_i \boldsymbol{q}_i^T \qquad Q = [\boldsymbol{q}_1; \boldsymbol{q}_2; ...\boldsymbol{q}_D] \in \mathbb{R}^{D\times D}$$

Дисперсия проекций

Утверждение

Дисперсия $\mathbb{D}$ проекций данных на вектор $\boldsymbol{v}$ с $\|\boldsymbol{v}\| = 1$ равна:

$$\mathbb{D}(z) = \boldsymbol{v}^T \Sigma \boldsymbol{v}$$

Доказательство: Рассмотрим дисперсию скаляра $z = \boldsymbol{v}^T \boldsymbol{x}$:

$$\mathbb{D}(z) = \mathbb{E}\left\{(z - \mathbb{E}[z])^2\right\}$$

В силу линейности $\mathbb{E}[z] = \boldsymbol{v}^T \boldsymbol{\mu}$:

$$\mathbb{D}(z) = \mathbb{E}\left\{(\boldsymbol{v}^T \boldsymbol{x} - \boldsymbol{v}^T \boldsymbol{\mu})^2\right\} = \mathbb{E}\left\{(\boldsymbol{v}^T (\boldsymbol{x} - \boldsymbol{\mu}))^2\right\}$$

$$\begin{aligned}
\mathbb{D}(z) &= \mathbb{E}\left\{\left(\boldsymbol{v}^T (\boldsymbol{x} - \boldsymbol{\mu})\right)\left(\boldsymbol{v}^T (\boldsymbol{x} - \boldsymbol{\mu})\right)^T\right\} \\
&= \mathbb{E}\left\{\boldsymbol{v}^T (\boldsymbol{x} - \boldsymbol{\mu})(\boldsymbol{x} - \boldsymbol{\mu})^T \boldsymbol{v}\right\} \\
&= \boldsymbol{v}^T \mathbb{E}\left\{(\boldsymbol{x} - \boldsymbol{\mu})(\boldsymbol{x} - \boldsymbol{\mu})^T\right\} \boldsymbol{v} = \boldsymbol{v}^T \Sigma \boldsymbol{v}
\end{aligned}$$

Определение первой ГК

Первая главная компонента - задача оптимизации:

$$\begin{cases} \boldsymbol{v}^T \Sigma \boldsymbol{v} \to \max_{\boldsymbol{v}} \\ \boldsymbol{v}^T \boldsymbol{v} = 1 \end{cases}$$

Лагранжиан:

$$L(\boldsymbol{v}, \lambda) = \boldsymbol{v}^T \Sigma \boldsymbol{v} - \lambda(\boldsymbol{v}^T \boldsymbol{v} - 1)$$

Условие стационарности:

$$\frac{\partial L}{\partial v} = 2\Sigma \boldsymbol{v} - 2\lambda \boldsymbol{v} = 0$$

$$\Sigma \boldsymbol{v} = \lambda \boldsymbol{v}$$

Дисперсия проекций:

$$\mathbb{D}(z) = \boldsymbol{v}^T \Sigma \boldsymbol{v} = \boldsymbol{v}^T (\lambda \boldsymbol{v}) = \lambda \boldsymbol{v}^T \boldsymbol{v} = \lambda$$

Следовательно, $\boldsymbol{v}_1 = \boldsymbol{q}_1$ - собственный вектор, отвечающий λ_1.

Определение $(K+1)$-й главной компоненты

Задача для $(K+1)$-й компоненты:

$$\begin{cases} \boldsymbol{v}^T \Sigma \boldsymbol{v} \to \max_{\boldsymbol{v}} \\ \boldsymbol{v}^T \boldsymbol{v} = 1 \\ \boldsymbol{v}^T \boldsymbol{v}_j = 0, \quad j = 1, \ldots, K \end{cases}$$

$$L(\boldsymbol{v}, \lambda, \eta_j) = \boldsymbol{v}^T \Sigma \boldsymbol{v} - \lambda(\boldsymbol{v}^T \boldsymbol{v} - 1) - \sum_{j=1}^{K} \eta_j \boldsymbol{v}^T \boldsymbol{v}_j \quad \text{лагранжиан}$$

$$2\Sigma \boldsymbol{v} - 2\lambda \boldsymbol{v} - \sum_{j=1}^{K} \eta_j \boldsymbol{v}_j = 0 \qquad \text{условие стационарности}$$

$$2\boldsymbol{v}_i^T \Sigma \boldsymbol{v} - 2\lambda \boldsymbol{v}_i^T \boldsymbol{v} - \sum_{j=1}^{K} \eta_i \boldsymbol{v}_i^T \boldsymbol{v}_j = 0 \quad \text{умножили слева на } \boldsymbol{v}_i^T \ (i \le K)$$

Определение $(K+1)$-й главной компоненты

$$\boldsymbol{v}_i^T \boldsymbol{v} = 0 \quad \text{по условию } \boldsymbol{v}$$

$$\boldsymbol{v}_i^T \Sigma \boldsymbol{v} = (\Sigma \boldsymbol{v}_i)^T \boldsymbol{v} = \lambda_i \boldsymbol{v}_i^T \boldsymbol{v} = 0$$

$$\sum_{j=1}^{K} \eta_i \boldsymbol{v}_i^T \boldsymbol{v}_j = \eta_i \boldsymbol{v}_i^T \boldsymbol{v}_i = \eta_i$$

Получаем условие для $i = 1, 2, ...K$:

$$2\boldsymbol{v}_i^T \Sigma \boldsymbol{v} - 2\lambda \boldsymbol{v}_i^T \boldsymbol{v} - \sum_{j=1}^{K} \eta_i \boldsymbol{v}_i^T \boldsymbol{v}_j = 0 \quad \rightarrow \quad \eta_i = 0$$

Определение $(K+1)$-й главной компоненты

$$2\Sigma\boldsymbol{v} - 2\lambda\boldsymbol{v} - \sum_{j=1}^{K}\eta_j\boldsymbol{v}_j = 0 \quad \rightarrow \quad \Sigma\boldsymbol{v} = \lambda\boldsymbol{v}$$

Для максимизации $\mathbb{D}(z) = \lambda$ выбираем СВ $\boldsymbol{v} = \boldsymbol{q}_{K+1}$, отвечающий λ_{K+1}.

Утверждение

Дисперсия проекции данных на k-ю главную компоненту в точности равна соответствующему собственному числу λ_k.

Доказательство: Так как $\Sigma\boldsymbol{v}_k = \lambda_k\boldsymbol{v}_k$ и $\|\boldsymbol{v}_k\| = 1$:

$$\begin{aligned}\mathbb{D}\{z_k\} &= \boldsymbol{v}_k^T\Sigma\boldsymbol{v}_k \\ &= \boldsymbol{v}_k^T(\lambda_k\boldsymbol{v}_k) \\ &= \lambda_k\|\boldsymbol{v}_k\|^2 = \lambda_k\end{aligned}$$

Значимость главных компонент

- Объяснённая дисперсия (explained variance) k-й компоненты:
$$EV(\boldsymbol{v}_K) = \lambda_K$$
- Доля объяснённой дисперсии (explained variance ratio) k-й компоненты:
$$EVR(\boldsymbol{v}_K) = \frac{\lambda_K}{\sum_{i=1}^{D} \lambda_i}$$
- Совокупная доля объяснённой дисперсии (cumulative explained variance ratio) $\boldsymbol{v}_1, \boldsymbol{v}_2, ...\boldsymbol{v}_K$:
$$CEVR(\boldsymbol{v}_1, \boldsymbol{v}_2, ...\boldsymbol{v}_K) = \frac{\sum_{k=1}^{K} \lambda_k}{\sum_{i=1}^{D} \lambda_i}$$

Отбор числа компонент

Визуализация и отбор числа компонент:

- $EVR \geq$ threshold
- либо $CEVR \geq$ threshold

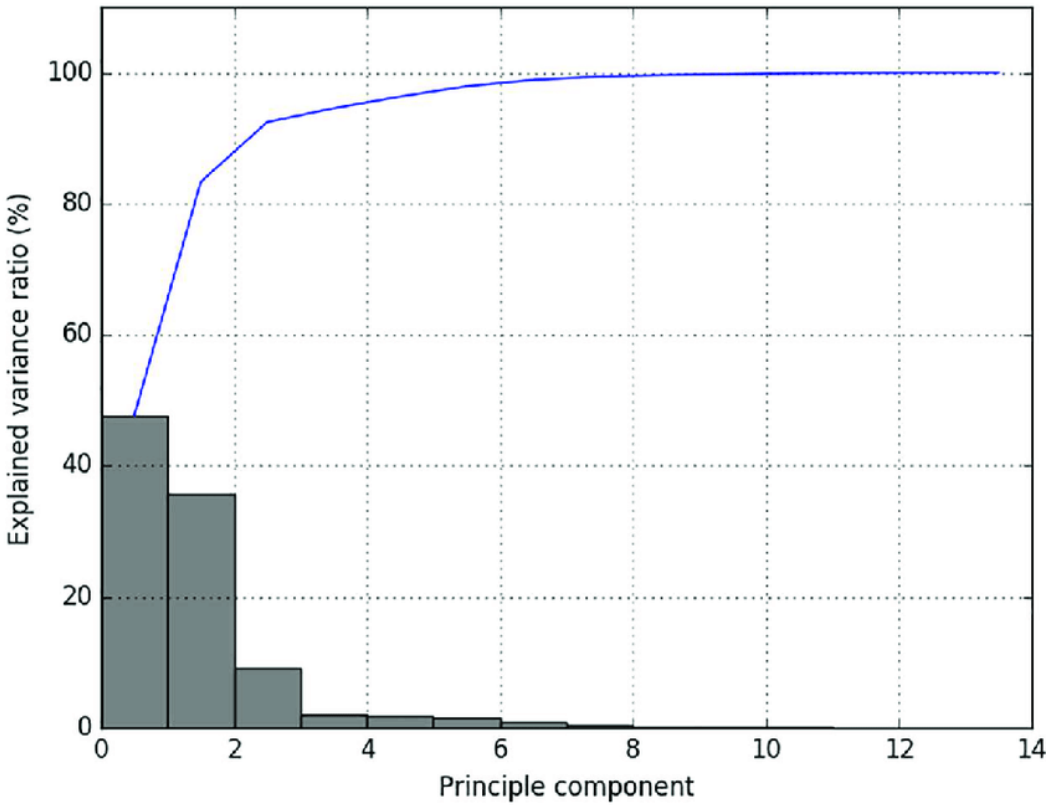

Оценка разброса распределения

Разброс сл. вел. $x \sim F(\mu, \Sigma)$

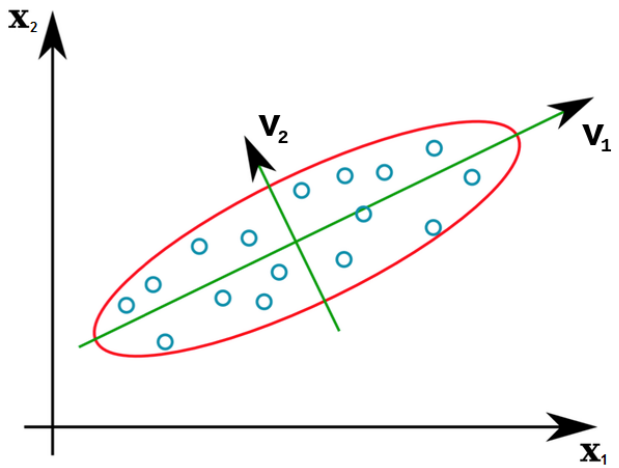

Используя инвариантность tr и $\det$ к смене базиса:

$$\frac{1}{D}(\lambda_1 + ... + \lambda_D) = \frac{1}{D}\,\mathrm{trace}\,\Lambda = \frac{1}{D}\,\mathrm{trace}\,P\Lambda P^T = \frac{1}{D}\,\mathrm{trace}\,\Sigma$$

$$\sqrt[D]{\lambda_1 \cdot ... \cdot \lambda_D} = \sqrt[D]{\det \Lambda} = \sqrt[D]{\det P\Lambda P^T} = \sqrt[D]{\det \Sigma}$$

Содержание

1. Задача снижения размерности
2. Применение метода главных компонент
3. Определение главных компонент
4. Свойства проекций на главные компоненты
5. Глобальная оптимальность главных компонент

Центрированность проекций

Утверждение

Если данные центрированы ($\mathbb{E}[\boldsymbol{x}] = \mathbf{0}$), то среднее проекции на любую ГК также равно нулю.

Доказательство: Рассмотрим i-й новый признак $z^i = \boldsymbol{v}_i^T \boldsymbol{x}$.
В силу линейности математического ожидания:

$$\mathbb{E}\left\{z^i\right\} = \mathbb{E}\left\{\boldsymbol{v}_i^T \boldsymbol{x}\right\} = \boldsymbol{v}_i^T \mathbb{E}\left\{\boldsymbol{x}\right\}$$

Так как $\mathbb{E}[\boldsymbol{x}] = \mathbf{0}$:

$$\mathbb{E}\left\{z^i\right\} = \boldsymbol{v}_i^T \cdot \mathbf{0} = 0$$

Нескоррелированность проекций

Утверждение

Проекции данных на различные главные компоненты нескоррелированы.

Доказательство: Для центрированных данных ковариация z_i и z_j равна:

$$\begin{aligned}\text{cov}(z_i, z_j) &= \mathbb{E}\left\{(\boldsymbol{v}_i^T(\boldsymbol{x}-\boldsymbol{\mu}))(\boldsymbol{v}_j^T(\boldsymbol{x}-\boldsymbol{\mu}))^T\right\} \\ &= \mathbb{E}\left\{(\boldsymbol{v}_i^T(\boldsymbol{x}-\boldsymbol{\mu}))(\boldsymbol{x}-\boldsymbol{\mu})^T\boldsymbol{v}_j\right\} \\ &= \boldsymbol{v}_i^T\mathbb{E}\left\{(\boldsymbol{x}-\boldsymbol{\mu})(\boldsymbol{x}-\boldsymbol{\mu})^T\right\}\boldsymbol{v}_j \\ &= \boldsymbol{v}_i^T\Sigma\boldsymbol{v}_j = \boldsymbol{v}_i^T(\lambda_j\boldsymbol{v}_j) = \lambda_j(\boldsymbol{v}_i^T\boldsymbol{v}_j) = 0\end{aligned}$$

поскольку по определению $\boldsymbol{v}_i^T\boldsymbol{v}_j = 0$

$$\text{cov}(z_i, z_j) = 0$$

Линейная независимость признаков

Утверждение

Векторы новых признаков $\{\boldsymbol{z}_k\}_{k=1}^D$ линейно независимы, если все собственные числа $\lambda_i > 0$.

Доказательство: Пусть Z — матрица проекций $N \times D$. Рассмотрим матрицу $G = \frac{1}{N} Z^T Z$. Её элементы:

$$
\begin{aligned}
G_{ij} &= \frac{1}{N} \sum_{n=1}^{N} (\boldsymbol{v}_i^T (\boldsymbol{x}_n - \boldsymbol{\mu}))((\boldsymbol{x}_n - \boldsymbol{\mu})^T \boldsymbol{v}_j) \\
&= \boldsymbol{v}_i^T \left(\frac{1}{N} \sum_{n=1}^{N} (\boldsymbol{x}_n - \boldsymbol{\mu})(\boldsymbol{x}_n - \boldsymbol{\mu})^T \right) \boldsymbol{v}_j \\
&= \boldsymbol{v}_i^T \Sigma \boldsymbol{v}_j = \lambda_j \boldsymbol{v}_i^T \boldsymbol{v}_j = \lambda_j \mathbb{I}\{i = j\}
\end{aligned}
$$

Анализ ранга матрицы проекций

Матрица $G = \frac{1}{N} Z^T Z$ является диагональной:

$$\frac{1}{N} Z^T Z = \text{diag}(\lambda_1, \lambda_2, \ldots, \lambda_D)$$

- Если $\lambda_k > 0$ для всех k, то $\det(\frac{1}{N} Z^T Z) = \prod_{k=1}^{D} \lambda_k \neq 0$.
- Значит, матрица $Z^T Z$ имеет полный ранг D.
- Из свойств ранга произведения: $\text{rank}(Z^T Z) = \text{rank}(Z)$.
- $\text{rank}(Z) = D$, что означает линейную независимость векторов новых признаков (столбцов Z).

Содержание

1. Задача снижения размерности
2. Применение метода главных компонент
3. Определение главных компонент
4. Свойства проекций на главные компоненты
5. Глобальная оптимальность главных компонент

Оптимальность подпространства

Утверждение

Первые K ГК максимизируют суммарную дисперсию проекций среди всех подпространств размерности K:

$$\mathbb{D}_{total} = \sum_{i=1}^{K} \mathbb{D}\left\{z^i\right\} = \sum_{i=1}^{K} \lambda_i$$

Доказательство: Пусть $\{\boldsymbol{u}_i\}_{i=1}^K$ — ортонормированный базис подпространства U. Суммарная дисперсия проекций на U:

$$\mathbb{D}_{total}(U) = \sum_{i=1}^{K} \boldsymbol{u}_i^T \Sigma \boldsymbol{u}_i = \sum_{i=1}^{K} \boldsymbol{u}_i^T \left(\sum_{j=1}^{D} \lambda_j \boldsymbol{v}_j \boldsymbol{v}_j^T \right) \boldsymbol{u}_i = \sum_{i=1}^{K} \sum_{j=1}^{D} \lambda_j (\boldsymbol{u}_i^T \boldsymbol{v}_j)^2$$

(использовали спектральное разложение $\Sigma = \sum_{j=1}^{D} \lambda_j \boldsymbol{v}_j \boldsymbol{v}_j^T$)

Максимизация взвешенной суммы

$$\mathbb{D}_{total}(U) = \sum_{i=1}^{K}\sum_{j=1}^{D}\lambda_j(\boldsymbol{u}_i^T\boldsymbol{v}_j)^2 = \sum_{j=1}^{D}\lambda_j\overbrace{\sum_{i=1}^{K}(\boldsymbol{u}_i^T\boldsymbol{v}_j)^2}^{c_j} = \sum_{j=1}^{D}\lambda_j c_j$$

Максимизация взвешенной суммы

$$\mathbb{D}_{total}(U) = \sum_{i=1}^{K}\sum_{j=1}^{D}\lambda_j(\boldsymbol{u}_i^T\boldsymbol{v}_j)^2 = \sum_{j=1}^{D}\lambda_j\overbrace{\sum_{i=1}^{K}(\boldsymbol{u}_i^T\boldsymbol{v}_j)^2}^{c_j} = \sum_{j=1}^{D}\lambda_j c_j$$

Для c_j выполняется:

1. $0 \le c_j \le 1$ (квадрат длины проекции $\boldsymbol{v}_j$ на U).
2. $\sum_{j=1}^{D} c_j = \sum_{i=1}^{K}\|\boldsymbol{u}_i\|^2 = K$
   т.к. это длины проекций $\boldsymbol{u}_1, ...\boldsymbol{u}_K$ на <u>полный</u> базис гл. компонент

Максимизация взвешенной суммы

$$\mathbb{D}_{total}(U) = \sum_{i=1}^{K}\sum_{j=1}^{D}\lambda_j(\boldsymbol{u}_i^T\boldsymbol{v}_j)^2 = \sum_{j=1}^{D}\lambda_j\overbrace{\sum_{i=1}^{K}(\boldsymbol{u}_i^T\boldsymbol{v}_j)^2}^{c_j} = \sum_{j=1}^{D}\lambda_j c_j$$

Для c_j выполняется:

1. $0 \le c_j \le 1$ (квадрат длины проекции $\boldsymbol{v}_j$ на U).
2. $\sum_{j=1}^{D} c_j = \sum_{i=1}^{K}\|\boldsymbol{u}_i\|^2 = K$
   т.к. это длины проекций $\boldsymbol{u}_1, ...\boldsymbol{u}_K$ на <u>полный</u> базис гл. компонент

Задача: $\sum_{j=1}^{D}\lambda_j c_j \to \max_{c_1,...c_D}$ при $0 \le c_j \le 1$ и $\sum c_j = K$

Максимизация взвешенной суммы

$$\mathbb{D}_{total}(U) = \sum_{i=1}^{K}\sum_{j=1}^{D}\lambda_j(\boldsymbol{u}_i^T\boldsymbol{v}_j)^2 = \sum_{j=1}^{D}\lambda_j\overbrace{\sum_{i=1}^{K}(\boldsymbol{u}_i^T\boldsymbol{v}_j)^2}^{c_j} = \sum_{j=1}^{D}\lambda_j c_j$$

Для c_j выполняется:

1. $0 \le c_j \le 1$ (квадрат длины проекции $\boldsymbol{v}_j$ на U).
2. $\sum_{j=1}^{D} c_j = \sum_{i=1}^{K}\|\boldsymbol{u}_i\|^2 = K$
   т.к. это длины проекций $\boldsymbol{u}_1, ...\boldsymbol{u}_K$ на <u>полный</u> базис гл. компонент

Задача: $\sum_{j=1}^{D}\lambda_j c_j \to \max_{c_1,...c_D}$ при $0 \le c_j \le 1$ и $\sum c_j = K$
Так как $\lambda_1 \ge \lambda_2 \ge \cdots \ge \lambda_D$, максимум достигается при:

$$c_1 = \cdots = c_K = 1, \quad c_{K+1} = \cdots = c_D = 0$$

Максимизация взвешенной суммы

$$\mathbb{D}_{total}(U) = \sum_{i=1}^{K}\sum_{j=1}^{D}\lambda_j(\boldsymbol{u}_i^T\boldsymbol{v}_j)^2 = \sum_{j=1}^{D}\lambda_j\overbrace{\sum_{i=1}^{K}(\boldsymbol{u}_i^T\boldsymbol{v}_j)^2}^{c_j} = \sum_{j=1}^{D}\lambda_j c_j$$

Для c_j выполняется:

1. $0 \le c_j \le 1$ (квадрат длины проекции $\boldsymbol{v}_j$ на U).
2. $\sum_{j=1}^{D} c_j = \sum_{i=1}^{K}\|\boldsymbol{u}_i\|^2 = K$
   т.к. это длины проекций $\boldsymbol{u}_1, ...\boldsymbol{u}_K$ на <u>полный</u> базис гл. компонент

Задача: $\sum_{j=1}^{D}\lambda_j c_j \to \max_{c_1,...c_D}$ при $0 \le c_j \le 1$ и $\sum c_j = K$
Так как $\lambda_1 \ge \lambda_2 \ge \dots \ge \lambda_D$, максимум достигается при:

$$c_1 = \dots = c_K = 1, \quad c_{K+1} = \dots = c_D = 0$$

Выполняется при $\boldsymbol{u}_1 = \boldsymbol{v}_1, \dots \boldsymbol{u}_K = \boldsymbol{v}_K$

- для них $\mathbb{D}_{total} = \sum_{i=1}^{K}\lambda_i$

Подпространство наилучшей аппроксимации

Метод главный компонент находит подпространство наилучшей аппроксимации:

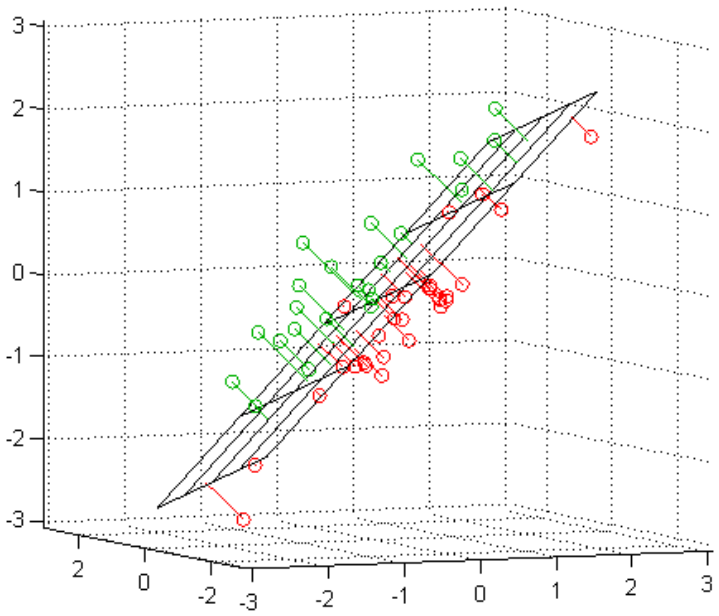

Первые K главных компонент $a_1, a_2, ...a_K$ - ортонормированный базис этого подпространства.

Связь дисперсии и квадрата нормы

Утверждение

Для центрированных данных суммарная дисперсия равна среднему квадрата евклидовой нормы вектора новых признаков:

$$\mathbb{D}_{total} = \mathbb{E}\left\{\|\boldsymbol{z}\|^2\right\}$$

Доказательство: Так как $\mathbb{E}[z^i] = 0$:

$$\mathbb{D}_{total} = \sum_{i=1}^{K} \mathbb{D}\left\{z^i\right\} = \sum_{i=1}^{K} \left(\mathbb{E}\left\{(z^i)^2\right\} - \left(\mathbb{E}\left\{z^i\right\}\right)^2\right) = \sum_{i=1}^{K} \mathbb{E}\left\{\left(z^i\right)^2\right\}$$

В силу линейности $\mathbb{E}$:

$$\mathbb{D}_{total} = \mathbb{E}\left\{\sum_{i=1}^{K} \left(z^i\right)^2\right\} = \mathbb{E}\left\{\|\boldsymbol{z}\|^2\right\}$$

Сохранение нормы при проектировании

Утверждение

Для проекции $\boldsymbol{p}$ точки $\boldsymbol{x}$ на подпространство гл. компонент:

$$\|\boldsymbol{p}\|^2 = \|\boldsymbol{z}\|^2$$

Доказательство:

$$\|\boldsymbol{p}\|^2 = \left(\sum_{i=1}^{K} z^i \boldsymbol{v}_i\right)^T \left(\sum_{j=1}^{K} z^j \boldsymbol{v}_j\right) = \sum_{i=1}^{K}\sum_{j=1}^{K} z^i z^j (\boldsymbol{v}_i^T \boldsymbol{v}_j)$$

$$= \sum_{i=1}^{K}\sum_{j=1}^{K} z^i z^j \mathbb{I}\{i=j\} = \sum_{i=1}^{K} \left(z^i\right)^2 = \|\boldsymbol{z}\|^2$$

т.к. главные компоненты образуют ортонормированный базис.

Минимизация ошибки реконструкции

Утверждение

Подпространство гл. компонент минимизирует средний квадрат ошибки аппроксимации $\mathbb{E}\left\{\|\boldsymbol{h}\|^2\right\}$

Минимизация ошибки реконструкции

Утверждение

Подпространство гл. компонент минимизирует средний квадрат ошибки аппроксимации $\mathbb{E}\left\{\|\boldsymbol{h}\|^2\right\}$

Пусть $\boldsymbol{x} = \boldsymbol{p} + \boldsymbol{h}$, $\boldsymbol{p}$-проекция, а $\boldsymbol{h}$-орт. дополнение, $\boldsymbol{h} \perp \boldsymbol{p}$.

Минимизация ошибки реконструкции

Утверждение

Подпространство гл. компонент минимизирует средний квадрат ошибки аппроксимации $\mathbb{E}\left\{\|\boldsymbol{h}\|^2\right\}$

Пусть $\boldsymbol{x} = \boldsymbol{p} + \boldsymbol{h}$, $\boldsymbol{p}$-проекция, а $\boldsymbol{h}$-орт. дополнение, $\boldsymbol{h} \perp \boldsymbol{p}$.

$$\begin{aligned}\|\boldsymbol{x}\|^2 &= \langle \boldsymbol{p}+\boldsymbol{h}, \boldsymbol{p}+\boldsymbol{h}\rangle = \langle \boldsymbol{p},\boldsymbol{p}\rangle + \langle \boldsymbol{h},\boldsymbol{h}\rangle + 2\langle \boldsymbol{p},\boldsymbol{h}\rangle \\ &= \langle \boldsymbol{p},\boldsymbol{p}\rangle + \langle \boldsymbol{h},\boldsymbol{h}\rangle = \|\boldsymbol{p}\|^2 + \|\boldsymbol{h}\|^2\end{aligned}$$

Минимизация ошибки реконструкции

Утверждение

Подпространство гл. компонент минимизирует средний квадрат ошибки аппроксимации $\mathbb{E}\left\{\|\boldsymbol{h}\|^2\right\}$

Пусть $\boldsymbol{x} = \boldsymbol{p} + \boldsymbol{h}$, $\boldsymbol{p}$-проекция, а $\boldsymbol{h}$-орт. дополнение, $\boldsymbol{h} \perp \boldsymbol{p}$.

$$\begin{aligned}\|\boldsymbol{x}\|^2 &= \langle \boldsymbol{p}+\boldsymbol{h}, \boldsymbol{p}+\boldsymbol{h}\rangle = \langle \boldsymbol{p},\boldsymbol{p}\rangle + \langle \boldsymbol{h},\boldsymbol{h}\rangle + 2\langle \boldsymbol{p},\boldsymbol{h}\rangle \\ &= \langle \boldsymbol{p},\boldsymbol{p}\rangle + \langle \boldsymbol{h},\boldsymbol{h}\rangle = \|\boldsymbol{p}\|^2 + \|\boldsymbol{h}\|^2\end{aligned}$$

$$\frac{1}{N}\sum_{n=1}^{N}\|\boldsymbol{x}_n\|^2 = \frac{1}{N}\sum_{n=1}^{N}\|\boldsymbol{p}_n\|^2 + \frac{1}{N}\sum_{n=1}^{N}\|\boldsymbol{h}_n\|^2$$

$$\mathbb{E}\left\{\|\boldsymbol{x}\|^2\right\} = \mathbb{E}\left\{\|\boldsymbol{p}\|^2\right\} + \mathbb{E}\left\{\|\boldsymbol{h}\|^2\right\}$$

Минимизация ошибки реконструкции

Утверждение

Подпространство гл. компонент минимизирует средний квадрат ошибки аппроксимации $\mathbb{E}\left\{\|\boldsymbol{h}\|^2\right\}$

Пусть $\boldsymbol{x} = \boldsymbol{p} + \boldsymbol{h}$, $\boldsymbol{p}$-проекция, а $\boldsymbol{h}$-орт. дополнение, $\boldsymbol{h} \perp \boldsymbol{p}$.

$$\|\boldsymbol{x}\|^2 = \langle \boldsymbol{p}+\boldsymbol{h}, \boldsymbol{p}+\boldsymbol{h}\rangle = \langle \boldsymbol{p},\boldsymbol{p}\rangle + \langle \boldsymbol{h},\boldsymbol{h}\rangle + 2\langle \boldsymbol{p},\boldsymbol{h}\rangle$$
$$= \langle \boldsymbol{p},\boldsymbol{p}\rangle + \langle \boldsymbol{h},\boldsymbol{h}\rangle = \|\boldsymbol{p}\|^2 + \|\boldsymbol{h}\|^2$$

$$\frac{1}{N}\sum_{n=1}^{N}\|\boldsymbol{x}_n\|^2 = \frac{1}{N}\sum_{n=1}^{N}\|\boldsymbol{p}_n\|^2 + \frac{1}{N}\sum_{n=1}^{N}\|\boldsymbol{h}_n\|^2$$
$$\mathbb{E}\left\{\|\boldsymbol{x}\|^2\right\} = \mathbb{E}\left\{\|\boldsymbol{p}\|^2\right\} + \mathbb{E}\left\{\|\boldsymbol{h}\|^2\right\}$$

Поскольку $\mathbb{E}\left\{\|\boldsymbol{x}\|^2\right\} = \frac{1}{N}\sum_{n=1}^{N}\|\boldsymbol{x}\|^2 = \text{const}$, то

$$\mathbb{E}\left\{\|\boldsymbol{p}\|^2\right\} \to \max_{\boldsymbol{v}_1,\ldots\boldsymbol{v}_K} \iff \mathbb{E}\left\{\|\boldsymbol{h}\|^2\right\} \to \min_{\boldsymbol{v}_1,\ldots\boldsymbol{v}_K}$$

Геометрическая интерпретация PCA

- PCA находит K-мерное подпространство
  - максимизирующее сумму квадратов длин проекций
  - минимизирующее сумму квадратов длин отклонений
- Различие линейной регрессии и PCA:

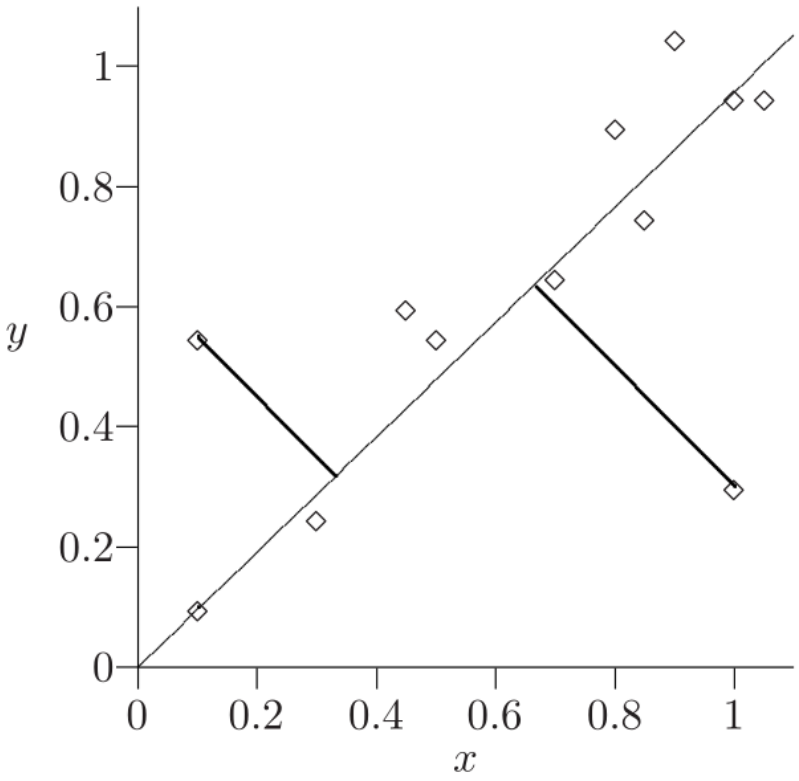

Расчет $\boldsymbol{p}$ по $\boldsymbol{x}$

Рассмотрим первые K главных компонент
$V = [\boldsymbol{v}_1; \boldsymbol{v}_2; ...\boldsymbol{v}_D] \in \mathbb{R}^{D\times K}$

$$\boldsymbol{z} = V^T(\boldsymbol{x} - \boldsymbol{\mu})$$
$$\boldsymbol{p} = V\boldsymbol{z} + \boldsymbol{\mu} = VV^T(\boldsymbol{x} - \boldsymbol{\mu}) + \boldsymbol{\mu}$$

Вычисляя компоненты по локальной окрестности точек, можно расшумлять данные[1]:

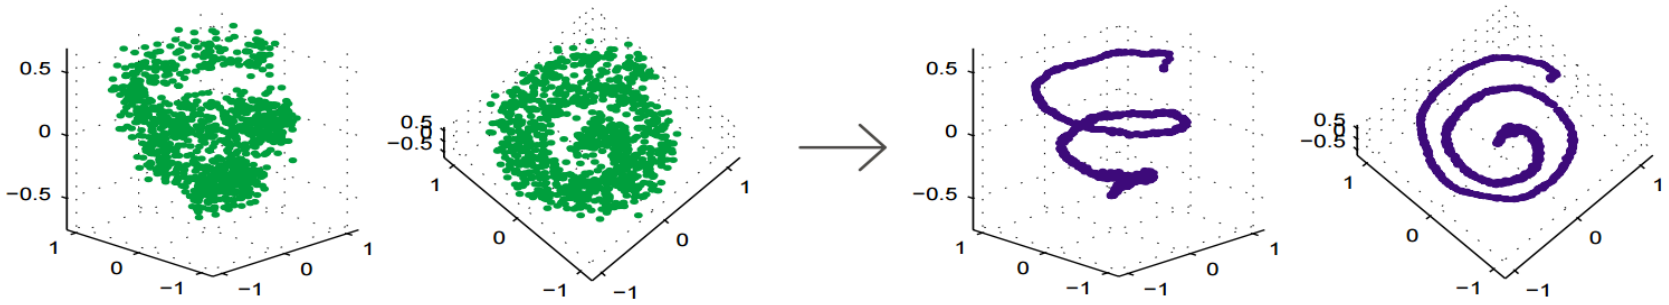

[1] X. Huo and Jihong Chen (2002). Local linear projection (LLP). First IEEE Workshop on Genomic Signal Processing and Statistics (GENSIPS).

Заключение

- Снижение размерности - преобразование признаков с переходом в пространство меньшей размерности.
- Метод главных компонент - метод линейного снижения размерности без учителя.
- Перед применением:
  - центрируем признаки ($\Rightarrow$нулевые средние)
  - приводим к одной шкале ($\Rightarrow$единичные дисперсии)
- Вдоль каждой компоненты дисперсия проекций максимально возможная.
  - с учётом ортогональности компонент друг другу
- Первые K главных компонент образуют ОНБ подпространства наилучшей аппроксимации.
  - в среднеквадратичном смысле