EM-алгоритм

Виктор Китов

victorkitov.github.io

Курс поддержан фондом 'Интеллект'

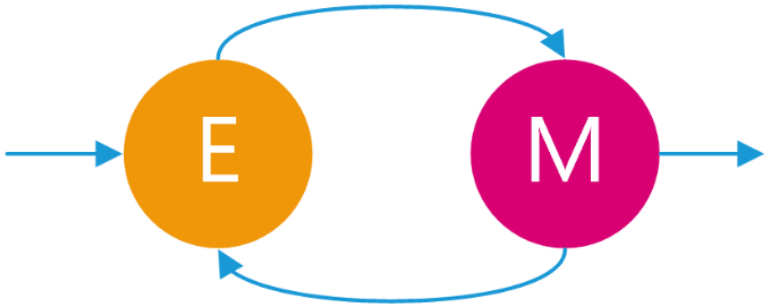

Победитель конкурса VK среди курсов по IT

Содержание

1. Неравенство Йенсена
2. Расстояние Кульбака-Лейблера
3. EM-алгоритм
4. Случай независимых наблюдений

Строго выпуклые функции

- Множество X выпукло, если $\forall x, y \in X$, $\forall \alpha \in (0,1)$:

$$\alpha x + (1-\alpha) y \in X$$

[1] Верно ли утверждение в обратную сторону?

Строго выпуклые функции

- Множество X выпукло, если $\forall x, y \in X$, $\forall \alpha \in (0,1)$:

$$\alpha x + (1-\alpha) y \in X$$

- Функция $f(x)$ строго выпукла на выпуклом X, если $\forall \alpha \in (0,1)$, $\forall y \neq x \in X$:

$$f\left(\alpha y + (1-\alpha)\, x\right) < \alpha f(y) + (1-\alpha) f(x)$$

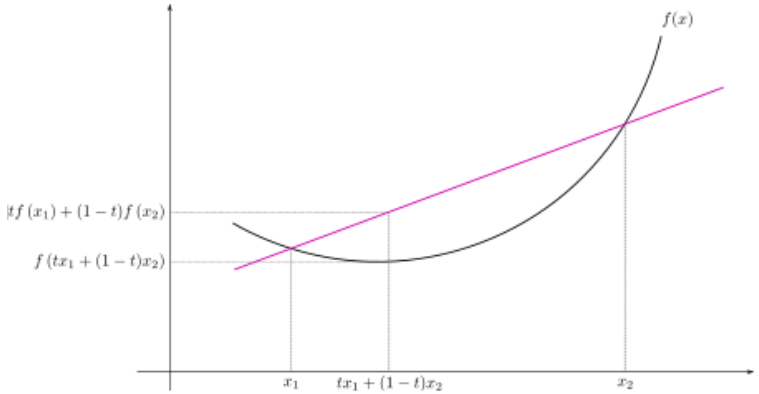

- Если $\nabla^2 f(x) \succ 0 \; \forall x \in X$, то $f(x)$ строго выпукла на X.[1]
  - пример: $f(x) = e^x$, поскольку $\nabla^2 f(x) \succ 0$

[1] Верно ли утверждение в обратную сторону?

Свойства выпуклых функций[2]

- Что можно сказать о минимумах выпуклых/строго выпуклых ф-ций и достаточном условии минимума?
- $f(x)$ строго выпукла => она всегда выше касательной

$$f(y) > f(x) + \nabla f(x)^T (y - x) \quad \forall y \neq x \in X$$

[2] Докажите утверждения. Верны ли они в обратную сторону?

Свойства выпуклых функций[2]

- Что можно сказать о минимумах выпуклых/строго выпуклых ф-ций и достаточном условии минимума?
- $f(x)$ строго выпукла => она всегда выше касательной

$$f(y) > f(x) + \nabla f(x)^T (y - x) \quad \forall y \neq x \in X$$

- Если $f(x)$ - строго выпукла, то выполнено нер-во Йенсена

$$\mathbb{E}[f(X)] > f(\mathbb{E}X) \quad \forall X \overset{\text{п.в.}}{\neq} \text{const}$$

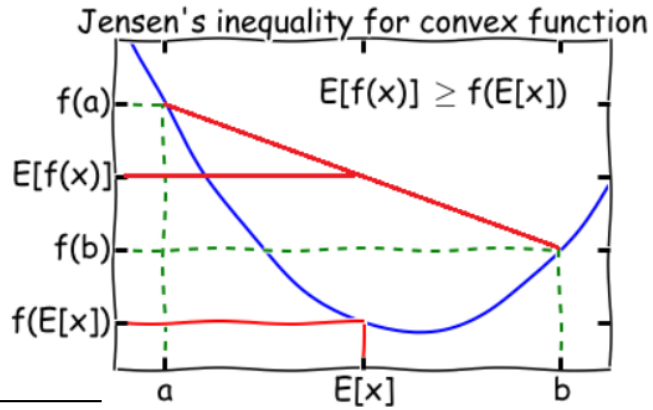

[2] Докажите утверждения. Верны ли они в обратную сторону?

Доказательство неравенства Йенсена

Строго вып. ф-ция $f(x)$ лежит выше касетельной:

$$f(y) > f(x) + \nabla f(x)^T (y - x)$$

Для $\forall$с.в. X подставим $y = X$ и $x = \mathbb{E}X$

$$f(X) > f(\mathbb{E}X) + \nabla f(\mathbb{E}X)^T (X - \mathbb{E}X)$$

Возьмём $\mathbb{E}$:

$$\mathbb{E}f(X) > f(\mathbb{E}X) + \nabla f(\mathbb{E}X)^T (\mathbb{E}X - \mathbb{E}X) = f(\mathbb{E}X)$$

Когда достигается равенство?

Доказательство неравенства Йенсена

Строго вып. ф-ция $f(x)$ лежит выше касетельной:

$$f(y) > f(x) + \nabla f(x)^T (y - x)$$

Для $\forall$с.в. X подставим $y = X$ и $x = \mathbb{E}X$

$$f(X) > f(\mathbb{E}X) + \nabla f(\mathbb{E}X)^T (X - \mathbb{E}X)$$

Возьмём $\mathbb{E}$:

$$\mathbb{E}f(X) > f(\mathbb{E}X) + \nabla f(\mathbb{E}X)^T (\mathbb{E}X - \mathbb{E}X) = f(\mathbb{E}X)$$

Когда достигается равенство?
Для $X \overset{\text{п.в.}}{=} \mathbb{E}X$:

$$f(X) = f(\mathbb{E}X)$$
$$\mathbb{E}: \quad \mathbb{E}f(X) = \mathbb{E}f(\mathbb{E}X) = f(\mathbb{E}X)$$

Строгая вогнутость

Функция $f(x)$ строго вогнута на выпуклом X, если

$$f\left(\alpha y+(1-\alpha)x\right)<\alpha f(y)+(1-\alpha)f(x) \quad \forall\alpha\in(0,1),\ \forall y\neq x\in X$$

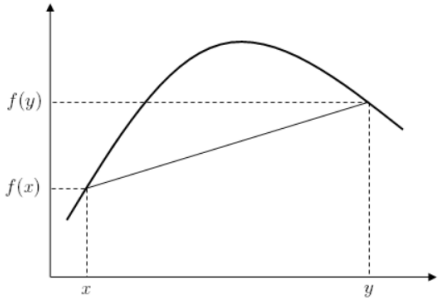

- Лежит всегда ниже касательной.
- Неравенство Йенсена в обратную сторону:

$$f(\mathbb{E}X)>\mathbb{E}[f(X)] \quad \forall X \overset{\text{п.в.}}{\neq} \text{const}$$

Строгая вогнутость

Функция $f(x)$ строго вогнута на выпуклом X, если

$$f\left(\alpha y+(1-\alpha)x\right)<\alpha f(y)+(1-\alpha)f(x) \quad \forall\alpha\in(0,1),\ \forall y\neq x\in X$$

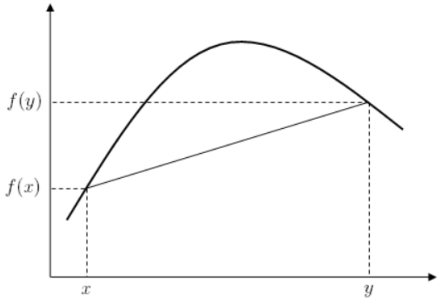

- Лежит всегда ниже касательной.
- Неравенство Йенсена в обратную сторону:

$$f(\mathbb{E}X)>\mathbb{E}[f(X)] \quad \forall X \overset{\text{п.в.}}{\neq} \text{const}$$

- Пример: $f(x)=\log x$, поскольку $\nabla^2 f(x)=-\frac{1}{x^2}>0$.

$$\log(\mathbb{E}X)>\mathbb{E}[\log(X)] \quad \forall X \overset{\text{п.в.}}{\neq} \text{const}$$

Содержание

1. Неравенство Йенсена
2. Расстояние Кульбака-Лейблера
3. EM-алгоритм
4. Случай независимых наблюдений

Определение и формулировка

Пусть $p(x)$ и $q(x)$ — дискретные распределения вероятностей.

- для непрерывных $\sum$ заменяются $\int$.

Дивергенция Кульбака — Лейблера:

$$D_{KL}(p \parallel q) = \sum_x p(x) \log \frac{p(x)}{q(x)}$$

Теорема:
$D_{KL}(p \parallel q) \geq 0$
$D_{KL}(p \parallel q) = 0 \iff p(x) = q(x)$ для всех x

Доказательство

Перепишем $-D_{KL}(p \parallel q)$ в эквивалентном виде:

$$
\begin{aligned}
-D_{KL}(p \parallel q) &= -\sum_x p(x) \log \frac{p(x)}{q(x)} \\
&= \sum_x p(x) \log \frac{q(x)}{p(x)} \\
&= \mathbb{E}_p \left[\log \frac{q(x)}{p(x)} \right]
\end{aligned}
$$

Здесь случайная величина X, принимающая значения $\frac{q(x)}{p(x)}$ с вероятностями $p(x)$.

Доказательство

Используя вогнутость $\log(t)$, применим неравенство Йенсена:

$$\mathbb{E}_p\left[\log\frac{q(x)}{p(x)}\right] \leq \log\left(\mathbb{E}_p\left[\frac{q(x)}{p(x)}\right]\right)$$

Доказательство

Используя вогнутость $\log(t)$, применим неравенство Йенсена:

$$\mathbb{E}_p\left[\log\frac{q(x)}{p(x)}\right] \le \log\left(\mathbb{E}_p\left[\frac{q(x)}{p(x)}\right]\right)$$

$$\mathbb{E}_p\left[\frac{q(x)}{p(x)}\right] = \sum_x p(x)\frac{q(x)}{p(x)} = \sum_x q(x) = 1$$

Следовательно:

$$-D_{KL}(p \parallel q) \le \log(1) = 0 \implies D_{KL}(p \parallel q) \ge 0$$

Условие равенства

Поскольку $\log(t)$ **строго** вогнута, $=$ в неравенстве Йенсена выполняется $\Leftrightarrow$ сл. вел. $\frac{q(x)}{p(x)}$=const:

$$\frac{q(x)}{p(x)} = c \quad (\text{для всех } x, \text{ где } p(x) > 0)$$

Условие равенства

Поскольку $\log(t)$ **строго** вогнута, $=$ в неравенстве Йенсена выполняется $\Leftrightarrow$ сл. вел. $\frac{q(x)}{p(x)}$=const:

$$\frac{q(x)}{p(x)} = c \quad (\text{для всех } x, \text{ где } p(x) > 0)$$

Найдём c, просуммировав по всем x:

$$\sum_x q(x) = \sum_x c \cdot p(x) \implies 1 = c \cdot 1 \implies c = 1$$

Условие равенства

Поскольку $\log(t)$ **строго** вогнута, $=$ в неравенстве Йенсена выполняется $\Leftrightarrow$ сл. вел. $\frac{q(x)}{p(x)}$=const:

$$\frac{q(x)}{p(x)} = c \quad (\text{для всех } x, \text{ где } p(x) > 0)$$

Найдём c, просуммировав по всем x:

$$\sum_x q(x) = \sum_x c \cdot p(x) \implies 1 = c \cdot 1 \implies c = 1$$

Следовательно, $D_{KL}(p \parallel q) = 0 \Leftrightarrow p(x) = q(x)$ для всех x.

KL-дивергенция для независимых сл. величин

Пусть x и y — независимые случайные величины, тогда

$$p(x,y) = p(x)p(y)$$
$$q(x,y) = q(x)q(y)$$

$D_{KL}(p(x,y) \parallel q(x,y))$ можно записать в виде

$$\sum_x \sum_y p(x,y) \log \frac{p(x,y)}{q(x,y)} = \sum_x \sum_y p(x)p(y) \log \frac{p(x)p(y)}{q(x)q(y)}$$

KL-дивергенция для независимых сл. величин

Пусть x и y — независимые случайные величины, тогда

$$p(x,y) = p(x)p(y)$$
$$q(x,y) = q(x)q(y)$$

$D_{KL}(p(x,y) \parallel q(x,y))$ можно записать в виде

$$\sum_x \sum_y p(x,y) \log \frac{p(x,y)}{q(x,y)} = \sum_x \sum_y p(x)p(y) \log \frac{p(x)p(y)}{q(x)q(y)}$$

$$= \sum_x \sum_y p(x)p(y) \log \frac{p(x)}{q(x)} + \sum_x \sum_y p(x)p(y) \log \frac{p(y)}{q(y)}$$

KL-дивергенция для независимых сл. величин

Пусть x и y — независимые случайные величины, тогда

$$p(x,y) = p(x)p(y)$$
$$q(x,y) = q(x)q(y)$$

$D_{KL}(p(x,y) \parallel q(x,y))$ можно записать в виде

$$\sum_x \sum_y p(x,y) \log \frac{p(x,y)}{q(x,y)} = \sum_x \sum_y p(x)p(y) \log \frac{p(x)p(y)}{q(x)q(y)}$$

$$= \sum_x \sum_y p(x)p(y) \log \frac{p(x)}{q(x)} + \sum_x \sum_y p(x)p(y) \log \frac{p(y)}{q(y)}$$

$$= \sum_x p(x) \log \frac{p(x)}{q(x)} \underbrace{\left(\sum_y p(y) \right)}_{=1} + \sum_y p(y) \log \frac{p(y)}{q(y)} \underbrace{\left(\sum_x p(x) \right)}_{=1}$$

KL-дивергенция для независимых сл. величин

Пусть x и y — независимые случайные величины, тогда

$$p(x,y) = p(x)p(y)$$
$$q(x,y) = q(x)q(y)$$

$D_{KL}(p(x,y) \parallel q(x,y))$ можно записать в виде

$$\sum_x \sum_y p(x,y) \log \frac{p(x,y)}{q(x,y)} = \sum_x \sum_y p(x)p(y) \log \frac{p(x)p(y)}{q(x)q(y)}$$

$$= \sum_x \sum_y p(x)p(y) \log \frac{p(x)}{q(x)} + \sum_x \sum_y p(x)p(y) \log \frac{p(y)}{q(y)}$$

$$= \sum_x p(x) \log \frac{p(x)}{q(x)} \underbrace{\left(\sum_y p(y) \right)}_{=1} + \sum_y p(y) \log \frac{p(y)}{q(y)} \underbrace{\left(\sum_x p(x) \right)}_{=1}$$

$$= D_{KL}(p(x) \parallel q(x)) + D_{KL}(p(y) \parallel q(y))$$

Связь с методом максимального правдоподобия

- Рассм. iid-выборку $x_1, ...x_N$, моделируемую $q_\theta(x)$, θ-?

Связь с методом максимального правдоподобия

- Рассм. iid-выборку $x_1, ...x_N$, моделируемую $q_\theta(x)$, θ-?

эмпирическое распределение: $$p(x) = \frac{1}{N}\sum_{n=1}^{N} \mathbb{I}\{x = x_n\}$$

Связь с методом максимального правдоподобия

- Рассм. iid-выборку $x_1, ...x_N$, моделируемую $q_\theta(x)$, θ-?

  эмпирическое распределение: $$p(x) = \frac{1}{N}\sum_{n=1}^{N} \mathbb{I}\{x = x_n\}$$

- θ будем находить минимизацией $D_{KL}(p \parallel q_\theta) \to \min_\theta$

$$\sum_x p(x)\log\frac{p(x)}{q_\theta(x)} = \underbrace{\sum_x p(x)\log p(x)}_{\text{const}(\theta)} - \sum_x p(x)\log q_\theta(x) \to \min_\theta$$

Связь с методом максимального правдоподобия

- Рассм. iid-выборку $x_1, ...x_N$, моделируемую $q_\theta(x)$, θ-?

  эмпирическое распределение: $$p(x) = \frac{1}{N}\sum_{n=1}^{N} \mathbb{I}\{x = x_n\}$$

- θ будем находить минимизацией $D_{KL}(p \parallel q_\theta) \to \min_\theta$

$$\sum_x p(x)\log\frac{p(x)}{q_\theta(x)} = \underbrace{\sum_x p(x)\log p(x)}_{\text{const}(\theta)} - \sum_x p(x)\log q_\theta(x) \to \min_\theta$$

$$\sum_x p(x)\log q_\theta(x) \to \max_\theta$$

Связь с методом максимального правдоподобия

- Рассм. iid-выборку $x_1, ...x_N$, моделируемую $q_\theta(x)$, θ-?

  эмпирическое распределение: $$p(x) = \frac{1}{N}\sum_{n=1}^{N} \mathbb{I}\{x = x_n\}$$

- θ будем находить минимизацией $D_{KL}(p \parallel q_\theta) \to \min_\theta$

$$\sum_x p(x)\log\frac{p(x)}{q_\theta(x)} = \underbrace{\sum_x p(x)\log p(x)}_{\text{const}(\theta)} - \sum_x p(x)\log q_\theta(x) \to \min_\theta$$

$$\sum_x p(x)\log q_\theta(x) \to \max_\theta$$

- Это <u>эквивалентно методу максимального правдоподобия</u>:

$$\frac{1}{N}\sum_{n=1}^{N}\log q_\theta(x_n) \to \max_\theta$$

Содержание

1. Неравенство Йенсена
2. Расстояние Кульбака-Лейблера
3. EM-алгоритм
4. Случай независимых наблюдений

Примеры задач со скрытыми переменными

- **Смеси распределений (смесь Гауссиан):**
  - Наблюдаемые (X): координаты точек в пространстве.
  - Латентные (Z): из какого компоненты смеси пришла точка.
- **Задачи с пропусками в данных (missing values):**
  - Наблюдаемые (X): известные значения признаков.
  - Латентные (Z): отсутствующие (пропущенные) значения.
- **Тематическое моделирование (topic modeling, TM):**
  - Наблюдаемые (X): слова в документах.
  - Латентные (Z): темы, к которым относятся эти слова.
- **Скрытые марковские модели (HMM):**
  - Наблюдаемые (X): последовательность сигналов или слов.
  - Латентные (Z): последовательность скрытых состояний системы.

Иллюстрации

Тематическое моделирование:

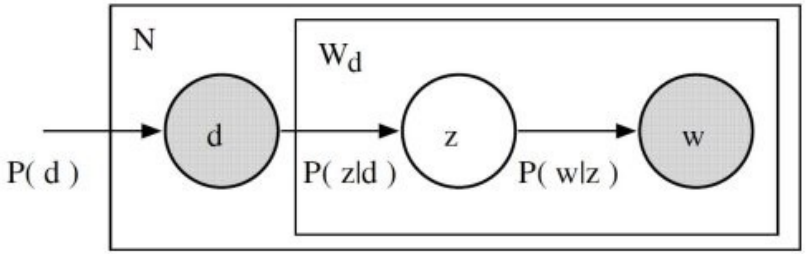

Скрытая марковская модель:

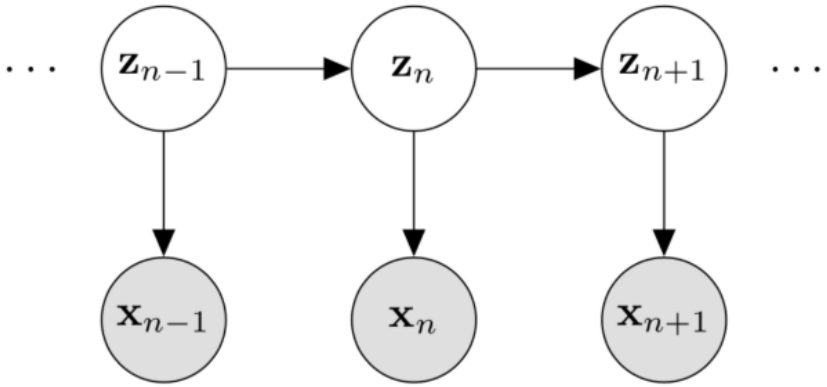

Применение тематического моделирования

Анализ больших текстовых корпусов

- автоматическое выявление основных тем в документах
- группировка документов по темам
- индексация по темам, а не по словам

Типичные источники данных

- новостные архивы
- научные публикации
- юридические документы
- посты пользователей в соц. сетях и на формумах

Применение ТМ

- **Социальные сети / форумы**
  - выявление обсуждаемых тем
  - обнаружение трендов
  - анализ общественного мнения
- **Анализ научной литературы**
  - выявление исследовательских направлений
  - анализ эволюции научных тем
  - поиск междисциплинарных связей
- **Рекомендательные системы**
  - представление документов через распределение тем
  - сопоставление интересов пользователя и тем документов
  - рекомендации статей и новостей
- **Информационный поиск**
  - поиск не только по словам, но и по общей теме
  - устраняет проблему синонимов (обслуживание автомобиля/ремонт машины)

Применение HMM: распознавание речи

Задача: восстановление последовательности фонем по аудиосигналу.

- Скрытые состояния:

$$z_t = \text{фонема речи в момент времени } t$$

- Наблюдения:

$$x_t = \text{акустические признаки сигнала (например, MFCC)}$$

- Интерпретация:
  - $p(z_t \mid z_{t-1})$ - фонетическая структура речи
  - $p(x_t \mid z_t)$ связывает фонему и акустический сигнал

Применение HMM: POS-теггинг

Задача: определение части речи для каждого слова в предложении.

- Скрытые состояния:

$$z_t = \text{часть речи слова } t$$

$$z_t \in \{\text{NOUN}, \text{VERB}, \text{ADJ}, \dots\}$$

- Наблюдения:

$$x_t = \text{слово в позиции } t$$

- Интерпретация:
  - $p(z_t \mid z_{t-1})$ - грамматические переходы
  - $p(x_t \mid z_t)$ - вероятность слова при данной части речи

Применение HMM: финансовые рынки

Задача: моделирование скрытых рыночных режимов.

- Скрытые состояния:

$$z_t = \text{режим рынка}$$

$$z_t \in \{\text{рост}, \text{падение}, \text{боковой тренд}\}$$

- Наблюдения:

$$x_t = \text{наблюдения цен, обм. курсов, доходностей обл-ций}$$

- Интерпретация:
  - $p(z_t \mid z_{t-1})$ - смена рыночных режимов
  - $p(x_t \mid z_t)$ - распределение показателей в каждом режиме

Применение HMM: анализ видео и жестов

Задача: распознавание действий или жестов по видео.

- Скрытые состояния:

$$z_t = \text{фаза действия или жеста}$$

- Наблюдения:

$$x_t = \text{визуальные признаки кадра}$$

$$x_t = \text{координаты суставов, дескрипторы изображения}$$

- Интерпретация:
  - $p(z_t \mid z_{t-1})$ описывает последовательность фаз действия
  - $p(x_t \mid z_t)$ связывает фазу жеста и наблюдаемые признаки

Постановка задачи

Проблема: Прямая максимизация

$$\log p(X|\theta) = \log \sum_Z p(X, Z|\theta) \to \max_\theta$$

затруднена, так как мы не знаем Z.

- Совместное правдоподобие $p(X, Z|\theta)$ оптимизировать гораздо проще (часто можно аналитически).
- Пусть $\theta^{(t)}$ — текущее приближение параметров.

EM-алгоритм итеративно выполняет E- и M-шаги до сходимости:

- E-шаг: вычисление $\mathbb{E}_{Z|X,\theta^{(t)}}[\log p(X, Z|\theta)]$
- M-шаг: его максимизация по θ.

Шаги EM-алгоритма

E-шаг (Expectation): вычисляется условное математическое ожидание логарифма полного правдоподобия:

$$Q(\theta, \theta^{(t)}) \stackrel{\text{def}}{=} \mathbb{E}_{Z|X,\theta^{(t)}}[\log p(X, Z|\theta)] = \sum_{Z} p(Z|X, \theta^{(t)}) \log p(X, Z|\theta)$$

M-шаг (Maximization): находятся новые параметры $\theta^{(t+1)}$, максимизирующие функцию Q:

$$\theta^{(t+1)} \stackrel{\text{def}}{=} \arg\max_{\theta} Q(\theta, \theta^{(t)})$$

Разложение правдоподобия

Введем $\forall$ распределение $q(Z)$, $\sum_Z q(Z) = 1$.

Разложение правдоподобия

Введем $\forall$ распределение $q(Z)$, $\sum_Z q(Z) = 1$.

1. По правилу определению условной вероятности

$$\frac{p(X,Z|\theta)}{p(Z|X,\theta)} = \frac{p(X,Z|\theta)}{p(Z,X,\theta)/p(X|\theta)} = p(X|\theta)$$

Разложение правдоподобия

Введем $\forall$ распределение $q(Z)$, $\sum_Z q(Z) = 1$.

1. По правилу определению условной вероятности

$$\frac{p(X,Z|\theta)}{p(Z|X,\theta)} = \frac{p(X,Z|\theta)}{p(Z,X,\theta)/p(X|\theta)} = p(X|\theta)$$

2. Подставим:

$$\log p(X|\theta) = \sum_Z q(Z) \log p(X|\theta) = \sum_Z q(Z) \log \frac{p(X,Z|\theta)}{p(Z|X,\theta)}$$

Разложение правдоподобия

Введем $\forall$ распределение $q(Z)$, $\sum_Z q(Z) = 1$.

1. По правилу определению условной вероятности

$$\frac{p(X,Z|\theta)}{p(Z|X,\theta)} = \frac{p(X,Z|\theta)}{p(Z,X,\theta)/p(X|\theta)} = p(X|\theta)$$

2. Подставим:

$$\log p(X|\theta) = \sum_Z q(Z) \log p(X|\theta) = \sum_Z q(Z) \log \frac{p(X,Z|\theta)}{p(Z|X,\theta)}$$

3. Умножим и разделим на $q(Z)$:

$$\log p(X|\theta) = \sum_Z q(Z) \log \left(\frac{p(X,Z|\theta)}{q(Z)} \cdot \frac{q(Z)}{p(Z|X,\theta)} \right)$$

Выделение $L(q,\theta)$ и $KL(q||p)$

Используя свойство логарифма произведения:

$$\log p(X|\theta) = \sum_Z q(Z)\left(\log\frac{p(X,Z|\theta)}{q(Z)} + \log\frac{q(Z)}{p(Z|X,\theta)}\right)$$

Разобьем на две суммы:

$$\log p(X|\theta) = \sum_Z q(Z)\log\frac{p(X,Z|\theta)}{q(Z)} + \sum_Z q(Z)\log\frac{q(Z)}{p(Z|X,\theta)}$$

Выделение $L(q,\theta)$ и $KL(q||p)$

Используя свойство логарифма произведения:

$$\log p(X|\theta) = \sum_Z q(Z)\left(\log\frac{p(X,Z|\theta)}{q(Z)} + \log\frac{q(Z)}{p(Z|X,\theta)}\right)$$

Разобьем на две суммы:

$$\log p(X|\theta) = \sum_Z q(Z)\log\frac{p(X,Z|\theta)}{q(Z)} + \sum_Z q(Z)\log\frac{q(Z)}{p(Z|X,\theta)}$$

$$\log p(X|\theta) = L(q,\theta) + KL(q(Z)\,||\,p(Z|X,\theta))$$

$L(q,\theta) \stackrel{\text{def}}{=}$ нижняя оценка (Evidence Lower Bound, ELBO)
KL — дивергенция Кульбака-Лейблера. $KL(q||p) > 0$ для $\forall p \neq q$; =0 при $p = q$.

Оптимизация на E- и M-шагах

$$\log p(X|\theta) = L(q,\theta) + KL(q(Z)\,||\,p(Z|X,\theta))$$

- **E-шаг:** Фиксируем $\theta^{(t)}$ и ищем q, при котором $\log p(X|\theta^{(t)}) = L(q,\theta^{(t)})$.
  - Достигается при $KL=0$, т.е. когда $q(Z)=p(Z|X,\theta^{(t)})$.
  - "Лучшая прикидка" для Z при X и $\theta=\theta^{(t)}$.

Оптимизация на E- и M-шагах

$$\log p(X|\theta) = L(q,\theta) + KL(q(Z)\,||\,p(Z|X,\theta))$$

- **E-шаг:** Фиксируем $\theta^{(t)}$ и ищем q, при котором $\log p(X|\theta^{(t)}) = L(q,\theta^{(t)})$.
  - Достигается при $KL=0$, т.е. когда $q(Z)=p(Z|X,\theta^{(t)})$.
  - "Лучшая прикидка" для Z при X и $\theta=\theta^{(t)}$.
- **M-шаг:** Фиксируем q и максимизируем:

$$L(q,\theta) = \sum_Z q(Z)\log p(X,Z|\theta) - \sum_Z q(Z)\log q(Z) \to \max_\theta$$

Оптимизация на E- и M-шагах

$$\log p(X|\theta) = L(q,\theta) + KL(q(Z)\,||\,p(Z|X,\theta))$$

- **E-шаг:** Фиксируем $\theta^{(t)}$ и ищем q, при котором $\log p(X|\theta^{(t)}) = L(q,\theta^{(t)})$.
  - Достигается при $KL=0$, т.е. когда $q(Z)=p(Z|X,\theta^{(t)})$.
  - "Лучшая прикидка" для Z при X и $\theta=\theta^{(t)}$.
- **M-шаг:** Фиксируем q и максимизируем:

$$L(q,\theta) = \sum_Z q(Z)\log p(X,Z|\theta) - \sum_Z q(Z)\log q(Z) \to \max_\theta$$

Энтропия $-\sum_Z q(Z)\log q(Z)$ не зависит от θ, поэтому максимизация L эквивалентна максимизации:

$$Q(\theta) \stackrel{\text{def}}{=} \sum_Z p(Z|X,\theta^{(t)})\log p(X,Z|\theta) \to \max_\theta$$

- Повторяем E- и M-шаги до сходимости.

Иллюстрация

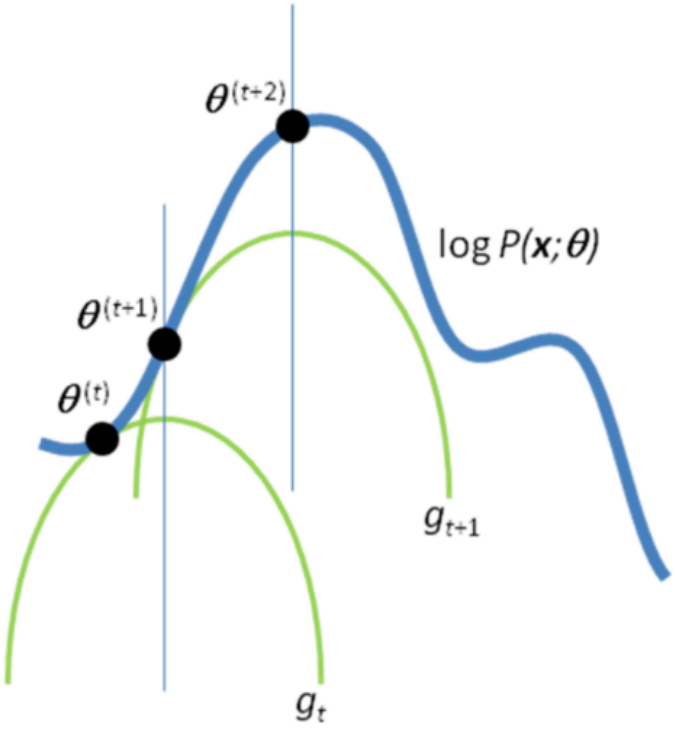

$$\log P(x|\theta^{(t)}) \geq L(q, \theta^{(t)}) = g_t$$

- В цикле до сходимости:
  - делаем нижнюю оценку точной
  - максимизируем её

Доказательство монотонности

Покажем, что $\log p(X|\theta^{(t+1)}) \geq \log p(X|\theta^{(t)})$:

1. После E-шага q выбрано так, что $KL = 0$:

$$\log p(X|\theta^{(t)}) = L(q^{(t+1)}, \theta^{(t)})$$

Доказательство монотонности

Покажем, что $\log p(X|\theta^{(t+1)}) \geq \log p(X|\theta^{(t)})$:

1. После E-шага q выбрано так, что $KL = 0$:

$$\log p(X|\theta^{(t)}) = L(q^{(t+1)}, \theta^{(t)})$$

2. После M-шага нашли $\theta^{(t+1)}$, максимизирущий L по θ:

$$L(q^{(t+1)}, \theta^{(t+1)}) \geq L(q^{(t+1)}, \theta^{(t)})$$

Доказательство монотонности

Покажем, что $\log p(X|\theta^{(t+1)}) \geq \log p(X|\theta^{(t)})$:

1. После E-шага q выбрано так, что $KL = 0$:

$$\log p(X|\theta^{(t)}) = L(q^{(t+1)}, \theta^{(t)})$$

2. После M-шага нашли $\theta^{(t+1)}$, максимизирущий L по θ:

$$L(q^{(t+1)}, \theta^{(t+1)}) \geq L(q^{(t+1)}, \theta^{(t)})$$

3. Из неотрицательности KL для любого θ:

$$\log p(X|\theta^{(t+1)}) \geq L(q^{(t+1)}, \theta^{(t+1)})$$

$$\log p(X|\theta^{(t+1)}) \geq L(q^{(t+1)}, \theta^{(t+1)}) \geq L(q^{(t+1)}, \theta^{(t)}) = \log p(X|\theta^{(t)})$$

Комментарии

- Возможные **критерии сходимости**:
  - $\left\|\theta^{(t+1)} - \theta^{(t)}\right\| < \varepsilon$, $L\left(\theta^{(t+1)}\right) - L\left(\theta^{(t)}\right) < \varepsilon$, #итераций>порога

Комментарии

- Возможные **критерии сходимости**:
  - $\left\|\theta^{(t+1)} - \theta^{(t)}\right\| < \varepsilon$, $L\left(\theta^{(t+1)}\right) - L\left(\theta^{(t)}\right) < \varepsilon$, #итераций>порога
- **Обобщеный EM-алгоритм** (generalized EM, GEM)
  - для сходимости достаточно выбрать $\theta^{(t+1)}$ так, что

$$L\left(q(Z), \theta^{(t+1)}\right) > L\left(q(Z), \theta^{(t)}\right)$$

  - например, сделать один шаг в оптимизации, а не находить точный максимум

EM-алгоритм как метод покоординатного подъёма

EM алгоритм - м-д покоординатного подъема нижн. границы:

- **E-шаг**:

$$L\left(q(Z),\theta^{(t)}\right) = \log p(X|\theta) - KL(q(Z)\,||\,p(Z|X,\theta)) \to \max_{q(Z)}$$

- **M-шаг**:

$$L(q(Z),\theta) \to \max_{\theta}$$

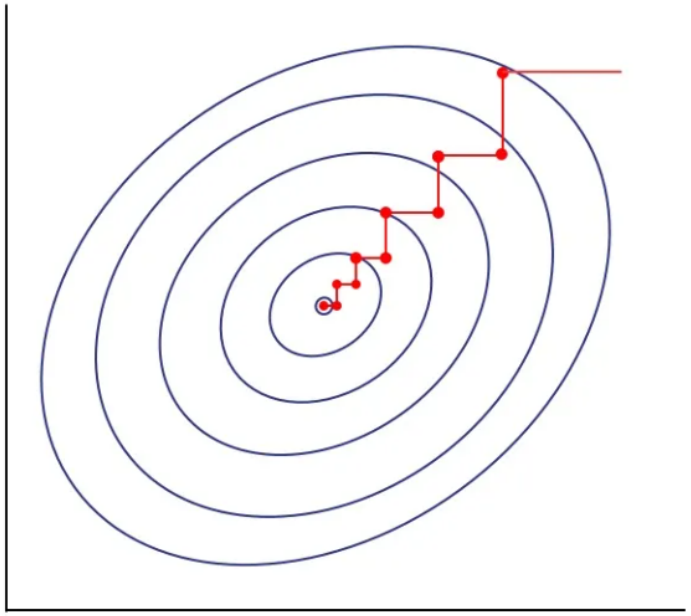

EM-алгоритм с регуляризацией

- Добавим регуляризацию $R(\theta)$ в задачу

$$L(\theta) = \ln p(X|\theta) - \lambda R(\theta) \to \max_{\theta}$$

  - $R(\theta)$ штрафует сложность
  - вычитаем, т.к. $\ln p(X|\theta)$ <u>максимизируется</u>.
- Пример штрафа:
  - Байесовская MAP оценка:

$$\ln p(X,\theta) = \ln p(X|\theta)p(\theta) = \ln p(X|\theta) + \underbrace{\ln p(\theta)}_{-\lambda R(\theta)} \to \max_{\theta}$$

EM алгоритм с регуляризацией

- При регуляризации целевой критерий меняется

$$\log p(X|\theta) \to \log p(X|\theta) - \lambda R(\theta)$$

EM алгоритм с регуляризацией

- При регуляризации целевой критерий меняется

$$\log p(X|\theta) \to \log p(X|\theta) - \lambda R(\theta)$$

- Поэтому нижняя грань

$$L(q(Z),\theta) \to L(q(Z),\theta) - \lambda R(\theta)$$

EM алгоритм с регуляризацией

- При регуляризации целевой критерий меняется

$$\log p(X|\theta) \to \log p(X|\theta) - \lambda R(\theta)$$

- Поэтому нижняя грань

$$L(q(Z),\theta) \to L(q(Z),\theta) - \lambda R(\theta)$$

- **E-шаг**: не меняется

$$\arg\min_{q(Z)} KL(q(Z)\,||\,p(Z|X,\theta^{(t)})) = p(Z|X,\theta^{(t)})$$

EM алгоритм с регуляризацией

- При регуляризации целевой критерий меняется

$$\log p(X|\theta) \to \log p(X|\theta) - \lambda R(\theta)$$

- Поэтому нижняя грань

$$L(q(Z),\theta) \to L(q(Z),\theta) - \lambda R(\theta)$$

- **E-шаг**: не меняется

$$\arg\min_{q(Z)} KL(q(Z)\,||\,p(Z|X,\theta^{(t)})) = p(Z|X,\theta^{(t)})$$

- **M-шаг**:

$$\theta^{(t+1)} = \arg\max_{\theta} \left\{ Q(\theta,\theta^{(t)}) - \lambda R(\theta) \right\}$$
$$= \arg\max_{\theta} \left\{ \mathbb{E}_{Z\sim q(Z)} \ln p_\theta(X,Z) - \lambda R(\theta) \right\}$$

Содержание

1. Неравенство Йенсена
2. Расстояние Кульбака-Лейблера
3. EM-алгоритм
4. Случай независимых наблюдений

Независимые и одинаково распределённые (x_n, z_n)

- Рассмотрим случай независимых наблюдений $\{(x_n, z_n)\}_{n=1}^N$
  - пример: смесь Гауссиан, z_n- номер компоненты, x_n-реализация.
- Тогда

$$q(Z) = q\left(z_1 ... z_N\right) = \prod_{n=1}^N q_n(z_n)$$

$$p(Z|X, \theta) = \prod_{n=1}^N p\left(z_n | x_n, \theta\right)$$

Упрощение E-шага

- Используя аддитивность KL:

$$KL(q(Z)\,||\,p(Z|X,\theta)) = \sum_n KL(q_n(z_n)\,||\,p(z_n|x_n,\theta)) \to \min_q$$

- Задача декомпозируется по наблюдениям:

$$\begin{cases} KL(q_1(z_1)\,||\,p(z_1|x_1,\theta)) \to \min_{q_1} & q_1(z_1) = p(z_1|x_1,\theta) \\ KL(q_2(z_2)\,||\,p(z_2|x_2,\theta)) \to \min_{q_2} & q_2(z_2) = p(z_2|x_2,\theta) \\ \dots & \dots \\ KL(q_N(z_N)\,||\,p(z_N|x_N,\theta)) \to \min_{q_N} & q_N(z_N) = p(z_N|x_N,\theta) \end{cases}$$

Упрощение для независимых наблюдений

$$\sum_{Z} q(Z) \ln \left(\prod_{k=1}^{N} p(x_k, z_k|\theta) \right) = \sum_{z_1,\ldots,z_N} \prod_{i=1}^{N} q_i(z_i) \left(\sum_{n=1}^{N} \ln p(x_n, z_n|\theta) \right)$$

Упрощение для независимых наблюдений

$$\sum_{Z} q(Z) \ln \left(\prod_{k=1}^{N} p(x_k, z_k|\theta) \right) = \sum_{z_1,\ldots,z_N} \prod_{i=1}^{N} q_i(z_i) \left(\sum_{n=1}^{N} \ln p(x_n, z_n|\theta) \right)$$

$$= \sum_{n=1}^{N} \left[\sum_{z_1,\ldots,z_N} \left(\prod_{i=1}^{N} q_i(z_i) \right) \ln p(x_n, z_n|\theta) \right]$$

Упрощение для независимых наблюдений

$$\sum_{Z} q(Z) \ln \left(\prod_{k=1}^{N} p(x_k, z_k|\theta) \right) = \sum_{z_1,\ldots,z_N} \prod_{i=1}^{N} q_i(z_i) \left(\sum_{n=1}^{N} \ln p(x_n, z_n|\theta) \right)$$

$$= \sum_{n=1}^{N} \left[\sum_{z_1,\ldots,z_N} \left(\prod_{i=1}^{N} q_i(z_i) \right) \ln p(x_n, z_n|\theta) \right]$$

$$= \sum_{n=1}^{N} \left[\sum_{\{z_i\}_{i\neq n}} \sum_{z_n} \left(\prod_{i\neq n} q_i(z_i) \right) q_n(z_n) \ln p(x_n, z_n|\theta) \right]$$

Упрощение для независимых наблюдений

$$\sum_Z q(Z)\ln\left(\prod_{k=1}^N p(x_k,z_k|\theta)\right)=\sum_{z_1,\dots,z_N}\prod_{i=1}^N q_i(z_i)\left(\sum_{n=1}^N \ln p(x_n,z_n|\theta)\right)$$

$$=\sum_{n=1}^N\left[\sum_{z_1,\dots,z_N}\left(\prod_{i=1}^N q_i(z_i)\right)\ln p(x_n,z_n|\theta)\right]$$

$$=\sum_{n=1}^N\left[\sum_{\{z_i\}_{i\neq n}}\sum_{z_n}\left(\prod_{i\neq n} q_i(z_i)\right)q_n(z_n)\ln p(x_n,z_n|\theta)\right]$$

$$=\sum_{n=1}^N\left[\left(\sum_{z_n} q_n(z_n)\ln p(x_n,z_n|\theta)\right)\underbrace{\left(\sum_{\{z_i\}_{i\neq n}}\left(\prod_{i\neq n} q_i(z_i)\right)\right)}_{\text{сумма по всем исходам распр. }\{z_i\}_{i\neq n}}\right]$$

Упрощение для независимых наблюдений

$$= \sum_{n=1}^{N} \left[\left(\sum_{z_n} q_n(z_n) \ln p(x_n, z_n|\theta) \right) \prod_{i \neq n} \underbrace{\left(\sum_{z_i} q_i(z_i) \right)}_{=1} \right]$$

Итоговый вид E-шага для независимых наблюдений:

$$Q(\theta) = \sum_{n=1}^{N} \sum_{z_n} q_n(z_n) \ln p(x_n, z_n|\theta) \to \max_{\theta}$$

Заключение

- **KL-дивергенция** - расстояние между распределениями
  - ≥ 0, $= 0 \Leftrightarrow$ распределения совпадают
- **EM-алгоритм** оценивает параметры вероятностных моделей с наблюдаемыми и латентными переменными.
- В цикле до сходимости повторяются E и M шаги
  - **E-шаг**: оцениваем распределение латентов при текущей оценке параметров $\theta^{(t)}$

$$q(Z) = p(Z|X, \theta^{(t)})$$

  - **M-шаг**: максимизируем совместное правдоподобие, усреднённое по возможным значениям латентов:

$$\mathbb{E}_{Z\sim q(Z)} \ln p_\theta(X, Z) \to \max_\theta$$

- Упрощения:
  - обобщённый EM
  - случай независимых наблюдений $\{(x_n, z_n)\}_n$