Базовые рекомендательные системы

Виктор Китов

victorkitov.github.io

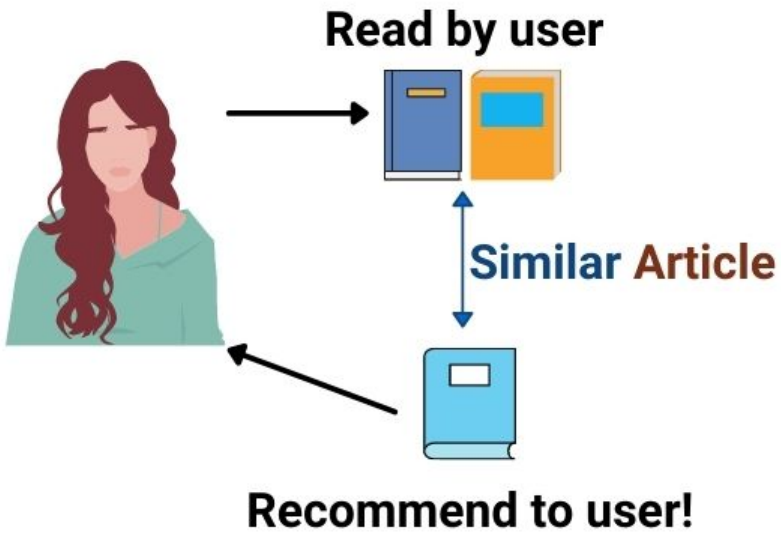

Курс поддержан фондом 'Интеллект'

Победитель конкурса VK среди курсов по IT

Содержание

Постановка задачи

- Задача: рекомендовать пользователю приобрести новые товары/услуги по его интересам.
- Примеры рекомендаций:

сервис	предмет рекомендаций
YouTube, Netflix	видео
last.fm, pandora	музыка
amazon, ozon	товары
Яндекс.Дзен	новости
вконтакте	группы, друзья, посты
TripAdvisor	достопримечательности

Постановка задачи

- Информационный поиск (information retrieval)
  - пользователь знает, что ищет.
  - задача: уточнение поиска
- Рекомендательные системы (recommender systems)
  - пользователь не знает, что ищет.
  - задача: расширение кругозора

Цели рекомендаций

Цели рекомендаций:

Цели рекомендаций

Цели рекомендаций:

- ↑ user experience, ↑ лояльность сервису
  - продать то, что нужно; рекомендовать интересное
- ↑ прибыль
  - продать подороже и доп. опции
- распродать остатки на складе
  - рекомендуем их в первую очередь
- изучить пользователя/товар
  - даём более случайные рекомендации
  - для продвинутых систем - всегда присутствует exploration-exploitation tradeoff.

Виды рекомендаций

Виды рекомендаций:

- Привязанные / не привязанные к пользователю
  - др. название: персональные / не персональные
- Привязанные / не привязанные к текущему товару
  - могут учитывать и более сложный контекст (время, локация, история запросов)

Виды рекомендаций

Виды рекомендаций:

- Привязанные / не привязанные к пользователю
  - др. название: персональные / не персональные
- Привязанные / не привязанные к текущему товару
  - могут учитывать и более сложный контекст (время, локация, история запросов)

В привязке к товару рекомендации бывают:

- более продвинутой версии товара (up-selling)
- более простой версии товара (down-selling)
- дополняющих товаров др. категорий (cross-selling)
- товаров, часто покупаемых вместе

Содержание

Доступная информация

Доступная информация:

- о пользователе: анкетные данные, время регистрации, браузер, ОС, взаимодействие с системой
- о товаре: описание, цена, категория, характеристики, отзывы пользователей
- о контексте: время, погода, запрос пользователя, локация запроса

Доступная информация

Информация о взаимодействии пользователей и товаров:

- бинарная:
- целочисленная:
- вещественная:

Доступная информация

Информация о взаимодействии пользователей и товаров:

- бинарная:
  - искал, смотрел, добавил в корзину, купил, написал отзыв
- целочисленная:
  - поставил рейтинг, количество покупок
- вещественная:
  - объем потраченных денег, время просмотра, количество скачанных данных

Примеры матрицы рейтингов

	GLADIATOR	GODFATHER	BEN-HUR	GOODFELLAS	SCARFACE	SPARTACUS
U_1	1			5		2
U_2		5			4	
U_3	5	3		1		
U_4			3			4
U_5				3	5	
U_6	5		4			

	GLADIATOR	GODFATHER	BEN-HUR	GOODFELLAS	SCARFACE	SPARTACUS
U_1	1			1		1
U_2		1			1	
U_3	1	1		1		
U_4			1			1
U_5				1	1	
U_6	1		1			

- Могут быть и вещественные значения: время просмотра видео, объем скачанной информации.
- По сути задача рекомендации $\sim$ заполнение пропусков в матрице рейтингов (missing value estimation)
  - но матрица очень разреженная

Виды информации о взаимодействии

Виды информации о взаимодействии:

- явные оценки товаров (explicit)
  - оценка, отзыв
- неявные оценки товаров (implicit)
  - бинарные:
    - посмотрел, положил в корзину, купил
  - ранговые:
    - в списке товаров кликнул на предпочтительный

Другая доступная информация

Также могут быть доступны

- взаимодействия пользователей
  - обмениваются комментариями
  - похожие интересы, паттерны поведения
- взаимодействия товаров:
  - субституты
  - более простые/сложные версии
  - дополняющие друг друга товары
  - частота совместной покупки

Содержание

Виды рекомендательных систем

Виды рекомендательных систем

- неперсональные:
  - summary-based: основаны на общей популярности товаров
  - product-based: отталкиваются от текущего товара
    - по смысловой совместимости с товаром
    - по частоте совместной покупки с товаром
- персональные:
  - content-based: основаны на сочетаемости данных о пользователе и товаре
  - collaborative filtering: используют только матрицу рейтингов
  - context-aware: дополнительно учитывают контекст (запрос, время, локацию)
  - knowledge-based: учитывают характеристики товаров
  - hybrid: ансамбль из разных типов рек. систем
    - самый точный подход

Алгоритм общей популярности

- Алгоритм общей популярности (summary-based).
  - неперсональные рекомендации, основанные на средней оценке товара.
- Если оценок мало - доверие к ним меньше, поэтому варианты сортировки:

$$\frac{1}{N}\sum_{i=1}^{N} r_i \to \frac{1}{N+\alpha}\sum_{i=1}^{N} r_i,\ \alpha \sim 100$$

$$\bar{r} - \beta\sqrt{\text{Var}[\bar{r}]},\ \beta > 0$$

Product-based: правиловый алгоритм

- Правиловый алгоритм рекомендует товар, часто покупаемый с заданными
  - неперсональный
  - использует поиск ассоциативных правил вида: (association rules mining)
  - $\{A, B, C\} \Rightarrow D$ (были в одной сессии/чеке)
    - $A \to B \to C \Rightarrow D$ (были последовательно перед)
    - $A \to ... \to B \to ... \to C \to ... \Rightarrow D$ (встретились до)
  - отбор правил:
    - следствие возникает с большой условной вероятностью
    - правило часто встречалось (достоверность)

Контентные рекомендации

Контентные рекомендации (content-based) - используют

- признаки о пользователе $f(u)$
  - как минимум: о просмотренных/купленных товарах
- признаки о товаре $f(i)$
- признаки о прошлом взаимодействии $f(u,i)$
  - например факт просмотра товара
  - hybrid: подставляем оценки рейтинга/эмбеддинги из коллаборативной фильтрации

Прогноз рейтинга - по обучаемой модели:

- (классификация, логистическая регрессия, ordered probit)

$$\widehat{r}_{ui} = G_\theta\left(f(u), f(i), f(u,i)\right)$$

Простейший пример

- Простейший пример контентных рекомендаций:
  - $f(i)$: TF-IDF описания товара
  - $f(u)$: TF-IDF конкатенации описаний ранее купленных товаров

$$\widehat{r}_{ui} = \text{cos-sim}\left(f(u), f(i)\right)$$

Напоминание TF-IDF:

$$w_{x,y} = tf_{x,y} \times \log\left(\frac{N}{df_x}\right)$$

TF-IDF
Вес слова x в описании товара y

$tf_{x,y}$ = частота слова x в описании товара y
df_x = количество товаров, содержащих слово x
N = общее количество товаров

- Здесь вообще не нужна матрица рейтингов.
  Если есть - лучше настроить $\widehat{r}_{ui} = G_\theta\left(f(u), f(i), f(u,i)\right)$

Анализ контентных рекомендаций

Анализ контентных рекомендаций:

- $\oplus$: не нужно статистики взаимодействия, сразу строим прогноз по описанию
- $\ominus$: нужен хороший контент (музыка, видео - сложно)
- $\ominus$: однообразные рекомендации (описание товара статично)
- $\ominus$: хуже коллаборативной фильтрации при наличии статистики

Обозначения

- $R = \{r_{u,i}\}_{i \in I, u \in U}$ - матрица рейтингов
  - $r_{u,i}$ - рейтинг товара i пользователем u
  - u - отдельный пользователь
  - i - отдельный товар
- $(u, i) \in R$ означает, что известен r_{ui}.
- $\widehat{r}_{u,i}$ - предсказанный рейтинг
- U - множество пользователей (users)
- I - множество товаров (items)
- I_u - множество товаров, оцененных пользователем u
- U_i - множество пользователей, оценивших товар i.

Соревнование Netflix - предшественник kaggle

- Netflix - сервис по онлайн-аренде DVD и доступа к цифровым каналам.
- Октябрь 2006 - сентабрь 2009: выложил данные для рекомендаций фильмов клиентам.
  - коллаборативная фильтрация с
    - 480.189 пользователями
    - 17.770 фильмами
    - оценками: 1,2,3,4,5.
  - призовой фонд: 1.000.000 $
- Формат данных (коллаборативная фильтрация+время):

$$< \text{пользователь}, \text{фильм}, \text{датаоценки}, \text{оценка} >$$

Соревнование Netflix - предшественник kaggle

- Netflix - сервис по онлайн-аренде DVD и доступа к цифровым каналам.
- Октябрь 2006 - сентабрь 2009: выложил данные для рекомендаций фильмов клиентам.
  - коллаборативная фильтрация с
    - 480.189 пользователями
    - 17.770 фильмами
    - оценками: 1,2,3,4,5.
  - призовой фонд: 1.000.000 $
- Формат данных (коллаборативная фильтрация+время):

$$< \text{пользователь}, \text{фильм}, \text{датаоценки}, \text{оценка} >$$

- Привлечены аналитики со всего мира.
- Лучший алгоритм - ансамбль большого количества хороших решений (не был внедрен).

Использование R

- Пользователи различаются по средним оценкам и разбросу (пессимисты/оптимисты):

$$u_1 = (1, 3, 1, 3)$$
$$u_2 = (6, 9, 6, 9)$$

- Также товары различаются по средним оценкам и разбросу (модные/не модные)
- Можно нормализовать R перед обработкой, потом денормализовать
  - по μ_u (самое важное)
  - по μ_u, σ_u
  - по $\mu_u, \sigma_u, \mu_i, \sigma_i$

Пример нормализации

- Пример нормализации по u:
  - для каждого u:
    - $\mu_u = \text{mean}\left(r_{u:}\right),\ \sigma_u = \text{std}\left(r_{u:}\right);\ r_{u:} := \frac{r_{u:}-\mu_u}{\sigma_u}$
  - счтиаем похожести u, i; строим прогнозы $\widehat{r}_{ui}$
  - для каждого u:
    - $\widehat{r}_{u:} := \sigma_u \widehat{r}_{u:} + \mu_u$

Простейшие базовые алгоритмы

Простейшие базовые алгоритмы:

- $\widehat{r}_{u,i} = \mu \ (\mu = \frac{1}{K}\sum_{u,i} r_{u,i},\ K = |\{(u,i) : \exists r_{u,i}\}|)$
- $\widehat{r}_{u,i} = \overline{r}_u = \frac{1}{|I_u|}\sum_{i \in I_u} r_{u,i}$
- $\widehat{r}_{u,i} = \overline{r}_i = \frac{1}{|U_i|}\sum_{u \in U_i} r_{u,i}$

Усредняющий алгоритм

- Прогноз базового алгоритма:

$$b_{u,i} := \widehat{r}_{u,i} = \mu + \Delta_u + \Delta_i$$

$$\Delta_u = \frac{1}{|I_u|} \sum_{i \in I_u} (r_{u,i} - \mu)$$

$$\Delta_i = \frac{1}{|U_i|} \sum_{u' \in U_i} \left(r_{u',i} - \mu - \Delta_{u'}\right)$$

- Интуиция:
  - Δ_u насколько u оценивает товары выше среднего
  - Δ_i насколько i в моде.

Усредняющий алгоритм с регуляризацией

- Усредняющий алгоритм с регуляризацией (with damping):

$$\widehat{r}_{u,i} = \mu + \Delta_u + \Delta_i$$

$$\Delta_u = \frac{1}{|I_u| + \alpha} \sum_{i \in I_u} (r_{u,i} - \mu)$$

$$\Delta_i = \frac{1}{|U_i| + \beta} \sum_{u' \in U_i} \left(r_{u',i} - \mu - \Delta_{u'}\right)$$

- $\alpha > 0, \beta > 0$ - сила регуляризации, $\alpha = \beta \approx 25$.

Усредняющий алгоритм с регуляризацией

- Усредняющий алгоритм с регуляризацией (with damping):

$$\widehat{r}_{u,i} = \mu + \Delta_u + \Delta_i$$

$$\Delta_u = \frac{1}{|I_u| + \alpha} \sum_{i \in I_u} (r_{u,i} - \mu)$$

$$\Delta_i = \frac{1}{|U_i| + \beta} \sum_{u' \in U_i} \left(r_{u',i} - \mu - \Delta_{u'}\right)$$

- $\alpha > 0, \beta > 0$ - сила регуляризации, $\alpha = \beta \approx 25$.
- Интуиция: доверяем Δ только когда выборка велика.

$$\Delta = \frac{1}{N + \alpha} \sum_{n=1}^{N} z_n = \begin{cases} \approx 0 & \text{для малых } N \\ \approx \frac{1}{N} \sum_{n=1}^{N} z_n & \text{для больших } N \end{cases}$$

Применения усредняющего алгоритма

Применения усредняющего алгоритма:

- R слишком разреженная для более сложных моделей
- заполнение пропусков для dense SVD
- $\widehat{r}_{u,i}$ - доп. признак для content-based модели
- сложная модель предсказывает $r_{u,i} - \widehat{r}_{u,i}$ вместо $r_{u,i}$
  - концентрируется на сложных случаях

Неявные отклики: алгоритм YouTube

- В YouTube
$$r_{u,i} = \begin{cases} 1, & u \text{ посмотрел } i \\ 0, & u \text{ не посмотрел } i \end{cases}$$
- Рассматриваются просмотры в последние 24часа.
- Первый рекомендательный алгоритм системы.
- Считаем похожесть видео i и j:
$$\text{sim}\,(i,j) = \frac{\sum_u r_{u,i} \cdot r_{u',j}}{\left(\sum_u r_{u,i}\right) \cdot \left(\sum_{u'} r_{u',j}\right)}$$
- Пусть S_u - множество просмотренных u видео, $R(S_u)$ - похожие на них.
- Рекомендации - по принципу "друг моего друга - мой друг":
$$R\,(S) \cup R\,(R\,(S)) \cup ...$$

Рекомендация на основе графа

- Строим двудольный граф пользователи-товары.
- Ребро между (u, i), если $r_{ui} > 0$ (r_{ui} - сила связи)

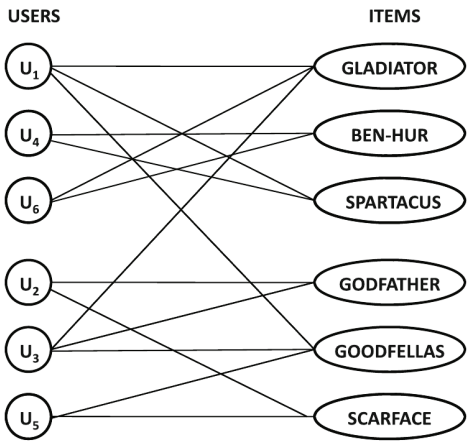

- Запускаем процесс случайного блуждания.
- Обозначим $P(a|b)$=вероятность оказаться в вершине a, если стартовали в b (Personalized PageRank)
- Предсказываем предпочтения, основываясь на

$$\widehat{r}_{ui} = P(i|u)$$

Рекомендация на основе графа

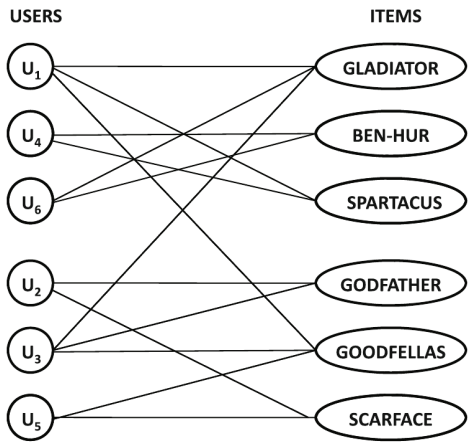

- Также можно считать (для user-based и item-based)

$$\text{sim}\left(u,u'\right)=\frac{1}{2}\left(P(u'|u)+P(u|u')\right)$$

$$\text{sim}\left(i,i'\right)=\frac{1}{2}\left(P(i'|i)+P(i|i')\right)$$

User-based алгоритм

Определим функцию близости между пользователями $s(u_1, u_2)$.

Построения прогноза $\widehat{r}_{u,i}$:

1. Найдем подмножество пользователей U_i, оценивших товар i.
2. Используя $s(u_1, u_2)$ найдем похожих на u пользователей N_u
3. Прогноз-средний рейтинг среди пользователей $U_i \cap N_u$.

User-based алгоритм

Определим функцию близости между пользователями $s(u_1, u_2)$.

Построения прогноза $\widehat{r}_{u,i}$:

1. Найдем подмножество пользователей U_i, оценивших товар i.
2. Используя $s(u_1, u_2)$ найдем похожих на u пользователей N_u
   - альтернатива: кластеризуем пользователей
   - тогда N_u- все пользователи кластера, где u
   - при кластеризации не учитываем пропуски ($r_{ui} = 0$)
3. Прогноз-средний рейтинг среди пользователей $U_i \cap N_u$.
   - лучше взвешенное среднее

User-based алгоритм

Базовый user-based прогноз:

$$\widehat{r}_{u,i} = \frac{\sum_{u' \in U_i \cap N_u} s(u,u') r_{u',i}}{\sum_{u' \in U_i \cap N_u} |s(u,u')|}$$

User-based алгоритм

Базовый user-based прогноз:

$$\widehat{r}_{u,i} = \frac{\sum_{u' \in U_i \cap N_u} s(u,u') r_{u',i}}{\sum_{u' \in U_i \cap N_u} |s(u,u')|}$$

явный учет пользовательских смещений (оптимисты/пессимисты):

$$\widehat{r}_{u,i} = \overline{r}_u + \frac{\sum_{u' \in U_i \cap N_u} s(u,u') \left(r_{u',i} - \overline{r}_{u'}\right)}{\sum_{u' \in U_i \cap N_u} |s(u,u')|}$$

User-based алгоритм

Базовый user-based прогноз:

$$\widehat{r}_{u,i} = \frac{\sum_{u' \in U_i \cap N_u} s(u,u') r_{u',i}}{\sum_{u' \in U_i \cap N_u} |s(u,u')|}$$

явный учет пользовательских смещений (оптимисты/пессимисты):

$$\widehat{r}_{u,i} = \overline{r}_u + \frac{\sum_{u' \in U_i \cap N_u} s(u,u') \left(r_{u',i} - \overline{r}_{u'}\right)}{\sum_{u' \in U_i \cap N_u} |s(u,u')|}$$

явный учет смещений и разбросов:

$$\widehat{r}_{u,i} = \overline{r}_u + \sigma_u \frac{\sum_{u' \in U_i \cap N_u} s(u,u') \left(r_{u',i} - \overline{r}_{u'}\right) / \sigma_{u'}}{\sum_{u' \in U_i \cap N_u} |s(u,u')|}$$

μ_u,σ_u - среднее и стд. отклонение пользователя u.

Выбор пользователей, похожих на u

Выбор пользователей N_u, похожих на u:

- использовать всех: $U \backslash \{u\}$
- использовать K самых похожих на u (обычно $K \in [20, 50]$)
- использовать $\{u' : s(u', u) \geq \text{threshold}\}$

Похожесть пользователей

$$s(u,v) = \frac{\sum_{i \in I_u \cap I_v} (r_{u,i} - \bar{r}_u)(r_{v,i} - \bar{r}_v)}{\sqrt{\sum_{i \in I_u \cap I_v} (r_{u,i} - \bar{r}_u)^2} \sqrt{\sum_{i \in I_u \cap I_v} (r_{v,i} - \bar{r}_v)^2}}$$

- Учитывает только линейную связь (можно считать ранговую корреляцию),
- Если есть нейтральная оценка: $\bar{r} \to r_{neutral}$
- Можно штрафовать похожесть за малое пересечение по товарам:

$$s'(u,v) = s(u,v) \min\{|I_u \cap I_v| / 50, 1\}$$

- Для более сильного учёта мнений пользователей, оценивших мало товаров, можно предварительно

$$\boldsymbol{r}_u \leftarrow \boldsymbol{r}_u / f(\|\boldsymbol{r}_u\|) \text{ для некоторой } \uparrow f(\cdot)$$

$\uparrow \boldsymbol{r}_u$ при малом $\|\boldsymbol{r}_u\|$.

Похожесть пользователей

- Можно сравнивать u, v по мере Жаккарда:

$$s(u, v) = \frac{|I_u \cap I_v|}{|I_u \cup I_v|}$$

- В чем недостаток?

Похожесть пользователей

- Можно сравнивать u, v по мере Жаккарда:

$$s(u,v) = \frac{|I_u \cap I_v|}{|I_u \cup I_v|}$$

- В чем недостаток?
- Отсутствует учет величины рейтингов. Воспользуемся взвешенной мерой Жаккарда:

$$s(u,v) = \frac{\sum_{i \in I_u \cap I_v} \min\{r_{u,i}, r_{v,i}\}}{\sum_{i \in I_u \cap I_v} \max\{r_{u,i}, r_{v,i}\}}$$

  - Применима только для $r_{u,i} \geq 0$. Позволяет оценивать похожесть множеств по степени представленности элементов в множествах.

Item-based алгоритм

Определим похожесть товаров $s(i_1, i_2)$.

Алгоритм определения $\widehat{r}_{u,i}$:

1. Определим подмножество товаров I_u, оцененных u.
2. Используя $s(i_1, i_2)$, определим подмножество товаров S_i, похожих на i.
3. Прогноз=средний рейтинг u по товарам $I_u \cap S_i$:

$$\widehat{r}_{u,i} = \frac{\sum_{i' \in I_u \cap S_i} s(i,i') r_{u,i'}}{\sum_{i' \in I_u \cap S_i} |s(i,i')|}$$

+поправка на среднее & разброс:

$$\widehat{r}_{u,i} = \mu_i + \sigma_i \frac{\sum_{i' \in I_u \cap S_i} s(i,i') \left(r_{u,i'} - \mu_{i'}\right) / \sigma_{i'}}{\sum_{i' \in I_u \cap S_i} |s(i,i')|}$$

Item-based алгоритм

Определим похожесть товаров $s(i_1, i_2)$.

Алгоритм определения $\widehat{r}_{u,i}$:

1. Определим подмножество товаров I_u, оцененных u.
2. Используя $s(i_1, i_2)$, определим подмножество товаров S_i, похожих на i.
   - альтернатива: кластеризуем товары, S_i-все товары кластера, где i. При кластеризации не учитываем пропуски.
3. Прогноз=средний рейтинг u по товарам $I_u \cap S_i$:

$$\widehat{r}_{u,i} = \frac{\sum_{i' \in I_u \cap S_i} s(i,i') r_{u,i'}}{\sum_{i' \in I_u \cap S_i} |s(i,i')|}$$

+поправка на среднее & разброс:

$$\widehat{r}_{u,i} = \mu_i + \sigma_i \frac{\sum_{i' \in I_u \cap S_i} s(i,i') \left(r_{u,i'} - \mu_{i'}\right) / \sigma_{i'}}{\sum_{i' \in I_u \cap S_i} |s(i,i')|}$$

Особенность item-based алгоритма

- Необходимо быстро пересчитывать рекомендации по динамически наполняемой корзине товаров в магазине.
- Использовать user-based или item-based алгоритм?

Особенность item-based алгоритма

- Необходимо быстро пересчитывать рекомендации по динамически наполняемой корзине товаров в магазине.
- Использовать user-based или item-based алгоритм?
- Профиль пользователя динамически меняется.
  - User-based: нужно пересчитывать похожих пользователей, долго.
  - Item-based: $s(i, i') \approx const$, предпосчитаем их вместе с S_i $\forall i$. Меняется только I_u и $r_{u,i'}$, поэтому item-based быстро пересчитать.

Похожесть товаров

$$s(i,j) = \frac{\langle \boldsymbol{r}_i, \boldsymbol{r}_j \rangle}{\|\boldsymbol{r}_i\| \, \|\boldsymbol{r}_j\|} = \frac{\sum_{u \in U_i \cap U_j} r_{u,i} r_{u,j}}{\sqrt{\sum_{u \in U_i \cap U_j} r_{u,i}^2} \sqrt{\sum_{u \in U_i \cap U_j} r_{u,j}^2}}$$

$$s(i,j) = \frac{\sum_{u \in U_i \cap U_j} (r_{u,i} - \overline{r}_i)(r_{u,j} - \overline{r}_j)}{\sqrt{\sum_{u \in U_i \cap U_j} (r_{u,i} - \overline{r}_i)^2} \sqrt{\sum_{u \in U_i \cap U_j} (r_{v,j} - \overline{r}_j)^2}}$$

Можем использовать корреляцию между рангами, штрафовать малые $|U_i \cap U_j|$.

Комментарии

- User-based или item-based более применим в онлайн-режиме?

Комментарии

- User-based или item-based более применим в онлайн-режиме?

$\oplus$: простые методы, не надо обучать

$\ominus$: много вычислений для $s(u, u')$, $s(i, i')$

$\ominus$: приходится хранить всю матрицу рейтингов